



PROYEK AKHIR

**RANCANG BANGUN ALAT DETEKSI
STROKE DINI NON-INVASIF DENGAN
METODE REGRESI LOGISTIK
BERBASIS IOT**

**Rizka Sugiharto
NRP. 2122600008**

**DOSEN PEMBIMBING
Ir. Moch. Rochmad, M.T.
NIP. 196203041991031002**

**Agrippina Waya Rahmaning Gusti, S.T,M.T.
NIP. 199409072022032012**

**PROGRAM STUDI SARJANA TERAPAN
TEKNIK ELEKTRONIKA
JURUSAN TEKNIK ELEKTRO**

**POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2025**



PROYEK AKHIR

RANCANG BANGUN ALAT DETEKSI STROKE DINI NON-INVASIF DENGAN METODE REGRESI LOGISTIK BERBASIS IOT

Rizka Sugiharto
NRP.2122600008

DOSEN PEMBIMBING
Ir. Moch. Rochmad, M.T.
NIP. 196203041991031002

Agrippina Waya Rahmaning Gusti, S.T,M.T.
NIP. 199409072022032012

PROGRAM STUDI SARJANA TERAPAN
TEKNIK ELEKTRONIKA
JURUSAN TEKNIK ELEKTRO

POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2025

**Rancang Bangun Alat Deteksi Stroke Dini Non-invasif Dengan Metode Regresi
Logistik Berbasis Iot**

Oleh:

Rizka Sugiharto
NRP. 2122600008

**Proyek Akhir ini Diajukan sebagai Salah Satu Syarat untuk
Memperoleh Gelar Sarjana Terapan Teknik (S.Tr.T.)
di
Program Studi Sarjana Terapan Teknik Elektronika
Jurusan Teknik Elektro
Politeknik Elektronika Negeri Surabaya**

Disetujui dan disahkan pada tanggal 06 Juli 2026 oleh:

Dosen Pembimbing:

1. **Ir. Moch. Rochmad, MT**
NIP. 196203041991031002
2. **Agrippina Waya Rahmaning Gusti, S.T, M.T**
NIP. 199409072022032012

Dosen Penguji:

1. **Ir. Kemalasari, MT**
NIP. 196303142000032001
2. **Dr., Ir. Hary Oktavianto, ST, M.Eng**
NIP. 197610012002121001



Mengetahui,
Koordinator Program Studi Sarjana Terapan Teknik Elektronika



Hendhi Hermawan, S.ST., M.T
NIP. 198802152020121002

PERNYATAAN ORISINALITAS

Dengan ini saya menyatakan bahwa bagian atau keseluruhan proyek akhir ini:

1. Adalah hasil karya sendiri dan tidak mengandung unsur plagiat dari pihak lain,
2. Tidak pernah diajukan untuk mendapatkan gelar akademis pada suatu Perguruan Tinggi,
3. Tidak pernah dipublikasikan atau ditulis oleh pihak lain
4. Mencantumkan rujukan dan kutipan dengan jujur dan benar terhadap sumber referensi lain yang menunjang pembahasan pada proyek akhir ini.

Apabila ditemukan bukti bahwa pernyataan saya di atas tidak benar, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Politeknik Elektronika Negeri Surabaya.

Surabaya, 10 Juli 2026

Rizka Sugiharto
NRP. 2122600008

PERNYATAAN PENGALIHAN HAK CIPTA

Dengan ini, saya yang bertanda tangan di bawah ini:

Nama : Rizka Sugiharto

NRP : 2122600008

Judul Proyek Akhir : Rancang Bangun Alat Deteksi Stroke Dini Non-Invasif Dengan Metode Regresi Logistik Berbasis IOT

Tanggal : Surabaya, 10 Juli 2026

menyatakan bahwa saya selaku penulis (dan/atau mewakili seluruh penulis) secara sadar dan sukarela mengalihkan hak cipta (*copyright*) atas proyek akhir tersebut kepada Politeknik Elektronika Negeri Surabaya.

Demikian pernyataan ini saya buat dengan sebenar-benarnya dan tanpa paksaan dari pihak mana pun.

Hormat saya,

[Materai]

Rizka Sugiharto

ABSTRAK

Stroke merupakan penyakit tidak menular yang menjadi penyebab utama kematian dan kecacatan di Indonesia. Banyak penderita tidak menyadari gejala awal karena pemeriksaan medis yang umumnya bersifat invasif, mahal, dan tidak praktis. Oleh karena itu, diperlukan solusi teknologi untuk memudahkan deteksi dini secara mandiri, akurat, dan nyaman digunakan. Proyek akhir ini merancang dan membangun alat deteksi stroke dini non-invasif yang mengukur tiga parameter utama risiko stroke, yaitu tekanan darah, gula darah, dan kolesterol, menggunakan sensor optik MAX30105. Sensor ini memanfaatkan prinsip *photoplethysmography* (PPG) untuk membaca sinyal inframerah (IR) dari ujung jari pengguna, kemudian data yang diperoleh dikalibrasi menggunakan *multi-layer perceptron* dengan tools Matlab agar dapat dipetakan ke dalam nilai medis. Hasil pengukuran tersebut selanjutnya diproses menggunakan metode regresi logistik, untuk mengklasifikasikan status risiko stroke dalam bentuk "Iya/Tidak". Dalam pelaksanaannya, proyek ini juga mencakup tahap kalibrasi data dengan alat invasif sebagai pembandingan, pengolahan data, dan pengujian terhadap responden berusia 20–70 tahun. Hasil penelitian menunjukkan bahwa data kesehatan dikalibrasi menggunakan metode Multi-Layer Perceptron (MLP) dan diklasifikasikan dengan regresi logistik menjadi kategori risiko stroke “Iya/Tidak”. Sistem berbasis ESP32 terintegrasi Internet of Things (IoT) dengan tampilan data secara real-time melalui LCD dan aplikasi Android. Pengukuran kadar gula darah menggunakan sensor MAX30105 menunjukkan tingkat akurasi sebesar 86,79%, sedangkan pengukuran kolesterol sebesar 95,07%, tekanan darah sistolik sebesar 92,75%, dan tekanan darah diastolik sebesar 97,24%. Selain itu, tingkat presisi alat ditunjukkan oleh nilai koefisien variasi yang berada di bawah 2% pada seluruh parameter pengukuran, sehingga menunjukkan hasil yang stabil dan konsisten. Hasil pengujian klasifikasi risiko stroke memperoleh akurasi sebesar 85,71%.

Kata Kunci: Stroke Dini, Non-Invasif, MAX30105, *Multi-layer perceptron*, Regresi Logistik.

ABSTRACT

Stroke is a non-communicable disease that is a major cause of death and disability in Indonesia. Many sufferers are unaware of the early symptoms because medical examinations are generally invasive, expensive, and impractical. Therefore, a technological solution is needed to facilitate early detection independently, accurately, and comfortably. This final project designs and builds a non-invasive early stroke detection tool that measures three key parameters of stroke risk, namely blood pressure, blood sugar, and cholesterol, using the MAX30105 optical sensor. This sensor utilizes the principle of photoplethysmography (PPG) to read infrared (IR) signals from the user's fingertips, then the obtained data is calibrated using a multi-layer perceptron with Matlab tools so that it can be mapped into medical values. The measurement results are then processed using the logistic regression method, to classify stroke risk status in the form of "Yes/No". In its implementation, this project also includes the data calibration stage with an invasive tool as a comparison, data processing, and testing on respondents aged 20–70 years. The results showed that health data was calibrated using the Multi-Layer Perceptron (MLP) method and classified using logistic regression into "Yes/No" stroke risk categories. The ESP32-based system is integrated with the Internet of Things (IoT) with real-time data display via LCD and Android application. Measurement of blood sugar levels using the MAX30105 sensor showed an accuracy level of 86.79%, while cholesterol measurements were 95.07%, systolic blood pressure 92.75%, and diastolic blood pressure 97.24%. In addition, the precision level of the device is indicated by the coefficient of variation value which is below 2% for all measurement parameters, thus showing stable and consistent results. The results of the stroke risk classification test obtained an accuracy of 85.71%.

Keywords: *Early Stroke, Non-Invasive, MAX30105, Multi-layer Perceptron, Logistic Regression.*

KATA PENGANTAR

Puji syukur kepada Tuhan yang Maha Esa, atas segala berkat dan penyertaan-Nya, sehingga penulis dapat menyelesaikan proyek akhir ini dengan baik :

RANCANG BANGUN ALAT DETEKSI STROKE DINI NON- INVASIF DENGAN METODE REGRESI LOGISTIK BERBASIS IOT

Pembuatan dan penyusunan proyek akhir ini diajukan sebagai salah satu syarat untuk menyelesaikan studi D4 dan memperoleh gelar Sarjana Terapan (S.Tr.T) program studi D4 Teknik Elektronika di Politeknik Elektronika Negeri Surabaya.

Penulis berusaha secara optimal dengan segala pengetahuan dan informasi yang didapatkan dalam menyusun laporan proyek akhir ini. Namun penulis juga menyadari berbagai keterbatasannya. Oleh karena itu, penulis memohon maaf atas keterbatasan materi pada laporan proyek akhir ini. Penulis sangat mengharapkan masukan berupa saran dan kritik yang membangun demi kesempurnaan laporan proyek akhir ini.

Demikian besar harapan penulis agar laporan proyek akhir ini dapat bermanfaat bagi pembaca, khususnya dalam bidang pengembangan teknologi kesehatan berbasis sensor PPG untuk deteksi dini risiko stroke secara noninvasif dan real-time.

Surabaya, 10 Juli 2026

Penulis

UCAPAN TERIMA KASIH

Puji syukur kepada Tuhan yang Maha Esa, atas segala limpahan rahmat serta hidayah yang diberikan sehingga proyek akhir ini dapat terselesaikan sesuai dengan jadwal yang telah ditentukan. Pada kesempatan ini penulis hendak menyampaikan ucapan terima kasih kepada semua pihak yang telah memberikan bantuan, bimbingan, motivasi, serta fasilitas sarana dan prasarana, baik material maupun spiritual sehingga penulis dapat menyusun buku laporan proyek akhir ini tepat pada waktunya, ucapan terima kasih kami sampaikan kepada:

1. Kedua orang tua, adik, mas dan semua keluarga yang selalu memberikan dukungan serta motivasi selama menempuh pendidikan D4 di PENS.
2. Bapak Dr.Arif Irwansyah,S.T., M.Eng selaku Direktur PENS.
3. Bapak Ahmad Zainudin, S.ST., M.T., Ph.D., selaku Kepala Departemen Teknik Elektro PENS.
4. Bapak Hendhi Hermawan, S.ST., M.T selaku Ketua Program Studi Sarjana Terapan Teknik Elektronika PENS.
5. Bapak Ir. Moch. Rochmad, M.T. dan Ibu Agrippina Waya Rahmaning Gusti, S.T., M.T., selaku dosen pembimbing proyek akhir saya.
6. Seluruh Bapak dan Ibu Dosen Pengajar Program Studi D3 dan D4 Teknik Elektronika Politeknik Elektronika Negeri Surabaya yang telah banyak memberikan ilmu dan pengetahuan selama masa perkuliahan kepada penulis.
7. Teman-teman kelas STr EA Angkatan 2022 yang telah memberikan semangat untuk menyelesaikan tugas akhir ini.
8. Teman-teman, kakak dan adik tingkat di lab PS 04.07 yang juga berusaha bersama untuk menyelesaikan tugas akhir.
9. Semua pihak yang tidak dapat penulis sebutkan yang telah membantu penulis hingga terselesaikannya proyek akhir ini.

Penulis menyadari bahwa masih banyak kekurangan pada perancangan dan pembuatan proyek akhir ini. Oleh karena itu, besar harapan kami untuk menerima saran dan kritik dari para pembaca. Semoga buku ini dapat memberikan manfaat bagi para Mahasiswa Politeknik Elektronika Negeri Surabaya dan Allah SWT selalu memberikan perlindungan, rahmat, dan nikmat-Nya bagi kita semua. Aamiin.

DAFTAR ISI

COVER.....	4
PERNYATAAN ORISINALITAS.....	iii
PERNYATAAN PENGALIHAN HAK CIPTA	iv
ABSTRAK	v
ABSTRACT.....	vi
KATA PENGANTAR.....	vii
UCAPAN TERIMA KASIH	viii
DAFTAR ISI.....	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiv
BAB 1 PENDAHULUAN	1
1.1 LATAR BELAKANG	1
1.2 PERMASALAHAN	2
1.3 BATASAN MASALAH	2
1.4 TUJUAN	2
1.5 MANFAAT	3
1.6 SISTEMATIKA PENULISAN	3
BAB 2 KAJIAN PUSTAKA.....	5
2.1 DESKRIPSI PERMASALAHAN	5
2.2 TEORI PENUNJANG	5
2.2.1 Stroke	5
2.2.2 Tekanan Darah	6
2.2.3 Gula Darah	7
2.2.4 Kolesterol	8
2.2.5 <i>Photoplethysmography</i>	8

2.2.6	Sensor MAX30105.....	9
2.2.7	ESP32	11
2.2.8	<i>Battery Shield V1</i> 18650.....	12
2.2.9	Baterai Li-Ion LG 18650.....	12
2.2.10	LCD 16x2 dengan Modul I2C.....	13
2.2.11	Regresi Logistik	15
2.2.12	<i>Multi-Layer Perceptron</i>	18
2.2.13	Skala RACE	21
2.3	PENELITIAN TERKAIT	24
BAB 3 DESAIN SISTEM		27
3.1	DESKRIPSI SOLUSI.....	27
3.2	PERANCANGAN SISTEM.....	27
3.2.1	<i>Flowchart</i> Sistem	28
3.3	PERANCANGAN <i>HARDWARE</i>	30
3.3.1	Perancangan Desain PCB.....	31
3.3.2	Perancangan Elektrik.....	32
3.3.3	Pembuatan Alat	33
3.4	KALIBRASI SENSOR	34
3.4.1	Pengambilan Nilai Inframerah dan detak Jantung	34
3.4.2	Membandingkan Nilai Detak Jantung dengan Tensimeter	34
3.5	PENGUMPULAN DATA SAMPEL.....	34
3.6	PERANCANGAN PENGUJIAN DAN PENGAMBILAN DATA	35
3.6.1	Perumusan <i>Multi-layer Perceptron</i> Regresi Tekanan Darah, Kolesterol, dan Gula Darah.....	36
3.6.2	Perancangan metode regresi logistik.....	38
3.6.3	Pengujian Alat	40
3.7	PERANCANGAN <i>PERANGKAT LUNAK</i>	40

3.7.1	Tampilan Aplikasi	40
3.7.2	Blok Diagram Basis Data Sistem	42
3.8	PEMBUATAN APLIKASI	43
3.9	INTEGRASI SISTEM	43
3.10	PENGUJIAN SISTEM KESELURUHAN	44
BAB 4 EKSPERIMEN DAN ANALISIS.....		45
4.1	PENGUJIAN SENSOR MAX30105	45
4.2	PENGUMPULAN DATA TRAINING	51
4.3	PENCARIAN MODEL <i>MULTI-LAYER PERCEPTRON</i>	53
4.4	PENGUJIAN NILAI GULA DARAH, KOLESTROL, TEKanan DARAH SISTOLIK DAN DIASTOLIK.....	60
4.5	PENGUJIAN PRESISI.....	64
4.6	PENGAMBILAN DATA SAMPEL.....	67
4.6.1	Pengambilan Data dan Skala Race.....	67
4.6.2	Penentuan Koefisien Beta untuk Regresi Logistik.....	70
4.6.3	Pengujian Regresi Logistik dari Data Sampel.....	71
4.6.4	Implementasi Regresi Logistik dengan JupyterLab	73
4.7	PENGUJIAN PENGIRIMAN DATA KE BASIS DATA	74
4.8	PENGUJIAN APLIKASI	76
BAB 5 PENUTUP		78
5.1	KESIMPULAN	78
5.2	SARAN	78
DAFTAR PUSTAKA		80
LAMPIRAN		82

DAFTAR GAMBAR

Gambar 2.1 Mode Konfigurasi	9
Gambar 2.2 Sensor MAX30105	9
Gambar 2.3 ESP32	11
Gambar 2.4 <i>Battery Shield V1</i>	12
Gambar 2.5 Baterai Li-Ion 18650	13
Gambar 2.6 Tampilan Fisik LCD 16x2 dengan Modul 12C	14
Gambar 2.7 Kurva Regresi Logistik dan Regresi Linier	16
Gambar 2.8 MLP Topology	18
Gambar 3.1 Blok Diagram Sistem	28
Gambar 3.2 <i>Flowchart</i> Sistem	29
Gambar 3.3 Desain Alat	30
Gambar 3.4 Desain <i>Final Prototype</i>	31
Gambar 3.5 Desain <i>Schematic Prototype</i>	32
Gambar 3.6 Desain <i>Board PCB Prototype</i>	32
Gambar 3.7 Racangan Elektrik Seluruh Komponen	33
Gambar 3.8 Proses <i>Multi-Layer Perceptron</i>	36
Gambar 3.9 Proses Regresi Logistik	38
Gambar 3.10 Model Regresi Logistik	39
Gambar 3.11 Desain Tampilan Aplikasi	40
Gambar 3.12 <i>Page Home</i> Utama	41
Gambar 3.13 <i>Page Profile</i>	42
Gambar 3.14 Blok Diagram Database Sistem	43
Gambar 4.1 Setup Pengujian	47
Gambar 4.2 Posisi Jari Pada Sensor	47
Gambar 4.3 Pengujian Dengan Tensi Digital	48
Gambar 4.4 Pembacaan heart rate (HR) sensor Dan Tensimeter	49
Gambar 4.5 Grafik Perbandingan Pengukuran HR	49
Gambar 4.6 Alur Pencarian Model	54
Gambar 4.7 Varian Performa Korelasi Model Gula Darah	56

Gambar 4.8 Varian Performa Korelasi Model Kolestrol	57
Gambar 4.9 Varian Performa Korelasi Model Tekanan Darah Sistolik	58
Gambar 4. 10 Varian Performa Korelasi Model Tekanan Darah Diastolik	59
Gambar 4.11 Dokumentasi Pengujian.....	64
Gambar 4.12 Hasil Inisialisasi dan Pelatihan Model Regresi Logistik.....	70
Gambar 4.13 Dokumentasi Pengambilan Sampel pada Naracoba	73
Gambar 4.14 Data Tersimpan di Firebase.....	75
Gambar 4.15 Implementasi Filter Data Berdasarkan User ID	77

DAFTAR TABEL

Tabel 2.1 Faktor Resiko Stroke	6
Tabel 2.2 Klasifikasi Hipertensi	7
Tabel 2.3 Diagnosis Diabetes Mellitus (DM) pada pemeriksaan laboratorium	7
Tabel 2.4 Kadar kolesterol darah	8
Tabel 2. 5 Spesifikasi MAX30105	10
Tabel 2.6 Konfigurasi Pin Sensor MAX30105	10
Tabel 2.7 Spesifikasi ESP32	11
Tabel 2.8 Spesifikasi Baterai LG 18650	13
Tabel 2.9 Spesifikasi LCD 16x2 I2C	14
Tabel 2.10 Konfigurasi Pin Modul I2C LCD.....	15
Tabel 2.11 Tabel Skor dari Skala RACE	23
 Tabel 3.1 Detail desain alat	 31
 Tabel 4.1 Hasil Pengujian Sensor MAX30105	 50
Tabel 4.2 Data Training Model Gula Darah	52
Tabel 4.3 Data Training Model Kolestrol	52
Tabel 4.4 Data Training Model Tekanan Darah Sistolik	53
Tabel 4.5 Data Training Model Tekanan Darah Diastolik.....	53
Tabel 4.6 Komparasi Prediksi Model dan Pengukuran Invasif.....	63
Tabel 4.7 Data Pengujian Presisi.....	66
Tabel 4.8 Data Sampel Laki Laki.....	68
Tabel 4.9 Data Sampel Perempuan	69
Tabel 4.10 Hasil Koefisien Pemodelan Regresi Logistik.....	71
Tabel 4.11 Pengujian Regresi Logistik Sampel Perempuan	72
Tabel 4.12 Pengujian Regresi Logistik Sampel Laki-Laki	72
Tabel 4.13 Hasil Pengujian menggunakan JupyterLab Portable.....	74

BAB 1

PENDAHULUAN

1.1 LATAR BELAKANG

Stroke merupakan salah satu penyakit tidak menular yang menjadi penyebab kematian dan kecacatan utama di dunia. Setiap tahunnya hampir 15 juta orang didunia mengalami stroke. Di Indonesia sendiri jumlah penderita stroke mencapai 500.000 orang dan diprediksi akan terus mengalami peningkatan setiap tahunnya. Berdasarkan data dari Yayasan Stroke Indonesia pada tahun 2009 jumlah penderita stroke di Indonesia menempati peringkat pertama di Indonesia. Stroke di Indonesia kebanyakan menyerang 35,8% pasien usia lanjut dan 12,9% meninggal dunia [1].

Stroke didefinisikan sebagai defisit (gangguan) fungsi sistem saraf yang terjadi mendadak dan disebabkan oleh gangguan peredaran darah otak. Stroke terjadi akibat gangguan pembuluh darah di otak. Gangguan peredaran darah otak dapat berupa tersumbatnya pembuluh darah otak atau pecahnya pembuluh darah di otak [2]. Faktor risiko stroke dibagi menjadi dua, yaitu faktor risiko yang tidak dapat diubah dan yang dapat diubah. Faktor risiko yang tidak dapat diubah antara lain usia, jenis kelamin, ras, riwayat keluarga, dan riwayat stroke sebelumnya. Sementara itu, faktor risiko yang dapat diubah meliputi hipertensi, diabetes, kebiasaan merokok, obesitas, dan dislipidemia [3]. Hal ini menunjukkan bahwa tekanan darah, diabetes, dan kadar gula darah merupakan parameter penting yang dapat dijadikan tolak ukur tubuh dalam memprediksi kemungkinan seseorang mengalami stroke.

Kesadaran masyarakat saat ini masih rendah untuk memantau kondisi kesehatan secara berkala. Banyak individu tidak menyadari kondisi medis mereka hingga gejala serius muncul, termasuk stroke. Alat deteksi kadar gula darah yang beredar di pasaran bersifat invasif. Selain itu metode deteksi juga dapat dilakukan melalui uji laboratorium. Namun ketidaknyamanan pasien terhadap jarum suntik, hasil uji lab yang membutuhkan waktu lama, dan biaya yang tinggi menjadi faktor penyebab masyarakat enggan untuk memeriksa kesehatannya terhadap faktor risiko ini secara rutin [4].

Berdasarkan dari permasalahan tersebut maka diperlukan alat pengukur tekanan darah, kolestrol dan gula darah non-invasif menggunakan sensor sebagai deteksi awal untuk pencegahan penyakit mematikan. Sensor MAX30105 merupakan sensor yang dapat membaca nilai *heart rate*, SpO₂, dan IR. Keluaran dari *output* sensor ini kemudian akan di proses menggunakan model *multi-layer perceptron* untuk memprediksi nilai tekanan darah, kolestrol dan gula darah dengan mengkonversi data inframerah dan detak jantung. Selanjutnya hasil pengukuran tersebut akan diolah oleh regresi logistik untuk disimpulkan menjadi kondisi Iya/Tidak terhadap kemungkinan terkena resiko dan gejala stroke dini. Data hasil pengukuran dan kesimpulan pemeriksaan akan disimpan ke dalam *server* dan ditampilkan melalui aplikasi agar mudah diakses.

1.2 PERMASALAHAN

Berdasarkan latar belakang yang telah disampaikan, rumusan masalah yang diangkat pada Proyek Akhir ini adalah sebagai berikut:

- a. Bagaimana akurasi tekanan darah, kolesterol dan kadar gula darah menggunakan sensor *optic* MAX30105 dibanding dengan alat invasif
- b. Bagaimana memanfaatkan metode *multi-layer perceptron* dan sensor MAX30105 untuk mendeteksi tekanan darah, kolesterol dan gula darah
- c. Bagaimana pembacaan dari Regresi Logistik terhadap kondisi kemungkinan stroke dini.

1.3 BATASAN MASALAH

Proyek akhir yang akan dilaksanakan memiliki cakupan batasan masalah, berikut batasan masalah proyek akhir dari judul yang diangkat:

- a. Deteksi yang dilakukan terhadap seseorang dengan rentang usia 20-70 tahun untuk dideteksi tekanan darah, kadar kolesterol, dan kadar gula darah sebagai faktor utama dalam risiko stroke.
- b. Pemeriksaan *glukosa* dilakukan saat naracoba tidak berpuasa
- c. Input Data usia, jenis kelamin dan berat badan diinputkan dari hasil wawancara dengan naracoba
- d. Deteksi yang dilakukan dengan responden tidak harus penderita stroke
- e. Metode prediksi yang digunakan adalah Regresi Logistik, tanpa membandingkan dengan metode kecerdasan buatan lainnya seperti *deep learning* atau *machine learning* lanjutan.
- f. Sistem IoT yang dikembangkan hanya mencakup pengiriman data kesehatan ke *platform digital* tanpa fitur konsultasi langsung dengan tenaga medis.

1.4 TUJUAN

Tujuan dari Proyek Akhir ini adalah merancang bangun alat untuk mendeteksi stroke dini berbasis non-invasif dengan mengukur tekanan darah, kadar kolesterol, dan kadar gula darah seseorang normal atau mengarah pada penyakit stroke. Serta dari integrasi teknologi IoT untuk memudahkan pengguna dalam memantau data kesehatan secara *real-time* melalui perangkat digital. Hasil dari alat pemantau stroke dini ini berupa prediksi kemungkinan Iya atau Tidak dalam kemungkinan terkena resiko dan gejala stroke dini.

1.5 MANFAAT

Adapun manfaat dari proyek akhir ini sebagaimana dari permasalahan yang telah diketahui adalah sebagai berikut :

a. Bagi Masyarakat Umum

- Membantu individu dalam mendeteksi faktor risiko stroke secara mandiri dengan metode non-invasif.
- Memberikan kemudahan dalam pemantauan kondisi kesehatan melalui aplikasi berbasis IoT.
- Meningkatkan kesadaran masyarakat akan pentingnya deteksi dini dalam mencegah stroke.

b. Bagi Mahasiswa

- Meningkatkan ilmu dan pengetahuan di bidang teknologi dengan menerapkan ilmu pengetahuan dan teknologi yang ada untuk diterapkan di masyarakat.
- Memberikan wawasan dan pengalaman dalam merancang serta mengembangkan alat kesehatan berbasis teknologi (IoT)
- Menciptakan inovasi baru di bidang teknologi kesehatan yang dapat di kembangkan lebih lanjut kedepannya.

1.6 SISTEMATIKA PENULISAN

Sistematika penulisan dalam buku Proyek Akhir ini disusun untuk memberikan alur pembahasan yang terstruktur. Sistematika pembahasan dalam buku proyek akhir yang meliputi :

Bab 1 : Pendahuluan

Bab ini berisi gambaran umum mengenai latar belakang munculnya permasalahan, perumusan masalah, batasan masalah, tujuan penelitian, manfaat yang diperoleh, serta sistematika penulisan. Bab ini menjadi dasar untuk memahami urgensi dan arah penyusunan proyek akhir.

Bab 2 : Kajian Pustaka

Bab ini memuat teori-teori penunjang yang relevan dengan topik penelitian, meliputi konsep dasar stroke, sensor optik, *photoplethysmography* (PPG), model regresi logistik, dan *multi-layer perceptron*. Selain itu, disertakan penelitian-penelitian terdahulu yang berkaitan sebagai landasan untuk merumuskan solusi dan metode yang digunakan dalam proyek akhir.

Bab 3 : Desain Sistem

Bab ini menjelaskan secara detail mengenai solusi yang ditawarkan, perancangan sistem, desain perangkat keras dan perangkat lunak, perancangan PCB, alur kerja sistem (*flowchart*),

serta metode yang digunakan dalam mengolah data. Bab ini menggambarkan bagaimana konsep teori diimplementasikan dalam bentuk sistem nyata.

Bab 4 : Eksperimen dan Analisis

Bab ini berisi proses pengujian sistem dan sensor, parameter eksperimen, tempat serta waktu pengujian, karakteristik data, hasil eksperimen, serta analisis terhadap performa sistem. Pada bab ini dilakukan pembahasan mengenai tingkat akurasi alat, keandalan pembacaan sensor, serta evaluasi model prediksi yang digunakan.

Bab 5 : Penutup

Bab ini berisi kesimpulan dari keseluruhan hasil proyek yang telah dilakukan serta saran untuk pengembangan lebih lanjut. Kesimpulan disusun berdasarkan hasil analisis dan pemenuhan tujuan proyek akhir.

BAB 2

KAJIAN PUSTAKA

2.1 DESKRIPSI PERMASALAHAN

Stroke merupakan penyakit yang banyak terjadi di Indonesia dan sering terlambat terdeteksi karena gejala awalnya tidak disadari. Salah satu penyebabnya adalah proses pemeriksaan kesehatan yang masih bergantung pada alat invasif, seperti pengecekan gula darah dengan jarum, pengukuran kolesterol melalui uji laboratorium, serta pemeriksaan tekanan darah konvensional. Metode ini dianggap tidak nyaman, membutuhkan biaya, dan tidak praktis, sehingga masyarakat jarang melakukan pemeriksaan rutin.

Tiga parameter kesehatan penting seperti tekanan darah, gula darah, dan kolesterol merupakan indikator utama risiko stroke. Keterlambatan dalam mengetahui kondisi tersebut menyebabkan meningkatnya kasus stroke yang baru terdeteksi setelah gejala berat muncul. Sementara itu, sensor optik seperti MAX30105 sebenarnya mampu melakukan pengukuran non-invasif, namun sinyal mentah tersebut tidak bisa langsung digunakan tanpa proses kalibrasi dan pemodelan yang tepat.

Permasalahan lain adalah belum adanya sistem yang dapat mengolah data sensor menjadi nilai medis yang akurat serta belum ada metode otomatis untuk mengklasifikasikan risiko stroke. Selain itu, alat konvensional tidak menyediakan pencatatan data atau pemantauan jarak jauh, sehingga pengguna tidak dapat memantau perubahan kondisi kesehatannya secara berkelanjutan. Oleh karena itu, permasalahan utama yang ingin diselesaikan adalah kebutuhan akan alat deteksi stroke dini yang non-invasif, mampu mengestimasi tiga parameter kesehatan menggunakan pemodelan seperti *Multi-Layer Perceptron* dan mengklasifikasikan risiko stroke menggunakan Regresi Logistik, serta terintegrasi dengan aplikasi *Internet of Things* IoT untuk menampilkan hasil pemeriksaan secara *real-time* dan menyimpan riwayat data kesehatan.

2.2 TEORI PENUNJANG

2.2.1 Stroke

Stroke didefinisikan sebagai gangguan fungsi sistem saraf yang terjadi mendadak dan disebabkan oleh gangguan peredaran darah otak. Stroke terjadi akibat gangguan pembuluh darah di otak. Perubahan pola hidup dan kemajuan teknologi kedokteran meningkatkan angka kejadian stroke dan stroke survivors. Peningkatan prevalensi penyakit pembuluh darah dihubungkan dengan peningkatan konsumsi tembakau, obesitas, diabetes, dan dislipidemia.

Peningkatan kejadian penyakit tidak menular berhubungan dengan tingginya angka kejadian merokok, kurangnya aktivitas fisik, dan obesitas. Peningkatan kejadian stroke di Indonesia terkait pula dengan peningkatan prevalensi hipertensi. Stroke dapat menyerang semua usia, namun lebih sering dijumpai pada usia tua. Angka kejadian stroke meningkat dua kali lipat setiap pertambahan 1 dekade usia pada populasi di atas usia 55 tahun. Data penelitian memperlihatkan bahwa 75-89% kejadian stroke terjadi pada individu berusia > 65 tahun, 50% kejadian stroke terjadi pada usia di atas 70 tahun, dan hampir 25% diantaranya terjadi pada usia di atas 85 tahun. Dari laporan CDC , angka prevalensi stroke di usia > 65 tahun adalah 8,1% berbanding 0,8% di usia 18-44 tahun [5].

a. Jenis Stroke [5]

Secara patologi ada 2 macam stroke, yaitu stroke sumbatan (stroke iskemik) terjadi ketika pembuluh darah ke otak mengalami sumbatan dan stroke perdarahan terjadi akibatnya pecahnya pembuluh darah yang menuju ke otak.

b. Faktor Resiko Stroke [5]

Seseorang menderita stroke karena memiliki faktor risiko stroke. Faktor risiko stroke dibagi menjadi 2 dalam tabel berikut, yaitu:

Tabel 2.1 Faktor Resiko Stroke [5]

Yang tidak dapat diubah	Yang dapat diubah
Usia	Hipertensi
Jenis kelamin laki-laki	Diabetes melitus
Ras	Dislipidemia
Riwayat keluarga	Merokok
Riwayat stroke sebelumnya	Obesitas

2.2.2 Tekanan Darah

Tekanan darah adalah ukuran dari tekanan yang diberikan darah terhadap dinding arteri saat jantung memompa (sistolik) dan saat jantung beristirahat di antara dua detakan (diastolik). Hipertensi merupakan penyakit yang terjadi karena terlalu tingginya tekanan di dalam pembuluh darah. Prevalensi hipertensi meningkat, sesuai peningkatan usia. Hipertensi merupakan faktor risiko stroke yang paling utama dan konsisten. Peningkatan tekanan darah sistolik dan diastolik secara konsisten meningkatkan risiko kejadian stroke dan penyakit kardiovaskuler lainnya.

Tabel 2.2 Klasifikasi Hipertensi [5]

Klasifikasi	Tekanan darah sistolik	Tekanan darah diastolik
Normal	<120	<80
Pra hipertensi	120-139	80-89
Hipertensi tingkat 1	140-159	90-99
Hipertensi tingkat 2	>160	>100

Seseorang disebut mengalami hipertensi apabila tekanan darahnya lebih dari 140/90 mmHg, atau lebih dari 135/85 mmHg pada individu yang mengalami gagal jantung, insufisiensi ginjal, atau diabetes melitus. Hipertensi merupakan faktor risiko stroke dan penyakit jantung koroner yang paling konsisten dan penting. Hipertensi meningkatkan risiko stroke 2-4 kali lipat, tidak tergantung pada faktor risiko lainnya.

2.2.3 Gula Darah

Glukosa adalah karbohidrat dalam bentuk monosakarida. Glukosa dalam darah jika tidak diperlukan akan disimpan di dalam hati dalam bentuk glikogen melalui proses glikogenesis. Jika diperlukan glikogen ini dapat diubah kembali menjadi glukosa melalui proses *glikogenolisis*, dan dilepaskan ke dalam darah [6]. Gula darah merupakan parameter yang sangat penting dalam menegakkan diagnosa diabetes. Metode pemeriksaan gula darah yang ada saat ini memerlukan sampel darah untuk dianalisis menggunakan alat *glucose meter* dengan darah sebagai sampelnya yang diambil dari ujung jari [7].

Diabetes merupakan salah satu faktor risiko stroke iskemik yang utama. Diabetes akan meningkatkan risiko stroke 2 kali lipat. Peningkatan kadar gula darah berhubungan lurus dengan risiko stroke (semakin tinggi kadar gula darah, semakin mudah terkena stroke).

Tabel 2.3 Diagnosis Diabetes Mellitus (DM) pada pemeriksaan laboratorium [5]

	Normal	GTT	DM
Gula darah puasa	<110	110-125	≥ 126
2 jam setelah beban glukosa	<140	140-200	≥ 200

GTT: Gangguan toleransi glukosa

2.2.4 Kolesterol

Kolesterol merupakan salah satu jenis lemak yang diproduksi oleh hati dan sangat diperlukan oleh tubuh. Profil lemak seseorang ditentukan oleh kadar kolesterol darah, kolesterol *Low-Density Lipoprotein* (LDL), kolesterol *High-Density Lipoprotein* (HDL), trigliserida, dan *Lipoprotein(a)* (Lp(a)). Kolesterol dibentuk di dalam tubuh, yang terdiri dari 2 bagian utama yaitu kolesterol LDL dan kolesterol HDL. Kolesterol LDL disebut sebagai "kolesterol jahat", yang membawa kolesterol dari hati ke dalam sel. Kolesterol HDL sering pula disebut sebagai "kolesterol baik", yang membawa kolesterol dari sel ke hati. Kadar HDL yang rendah secara konsisten dihubungkan dengan peningkatan risiko penyakit jantung koroner dan stroke.

Profil lemak yang normal adalah sebagai berikut: (1) kadar kolesterol darah dibawah 200 mg/ dl, (2) kadar kolesterol LDL dibawah 150 mg/dl, (3) kadar kolesterol HDL diatas 35 mg/dl, dan (4) kadar trigliserida dibawah 200 mg/dl. Hal yang juga tidak kalah pentingnya adalah rasio kolesterol LDL dan kolesterol HDL yang kurang dari 3,5 [5].

Tabel 2.4 Kadar kolesterol darah [5]

Kadar kolestrol total	Resiko	Rekomendasi
<200 mg/dL	Rendah	-Cek berkala -Cek faktor resiko lain
200-239 mg/dL	Sedang	-Perubahan pola hidup -Cek berkala minimal 1 tahun
>240 mg/dL	Tinggi	-Perubahan pola hidup -Hubungi dokter

2.2.5 Photoplethysmography


Plethysmograph merupakan suatu instrumen yang digunakan untuk mengukur perubahan volume darah di dalam suatu organ atau seluruh tubuh. Biasanya merupakan hasil dari fluktuasi volume darah atau udara yang terkandung di dalamnya. *Photoplethysmograph* (PPG) merupakan instrumen *plesthyismograph* yang bekerja menggunakan sensor optik. Dalam teknik PPG dikenal dua macam mode konfigurasi pemasangan sensor [8]:

a. Mode Transmisi

Sumber cahaya (LED) dipasang berhadapan dengan sensor cahaya. Sensor cahaya mendeteksi perubahan cahaya yang dipancarkan oleh LED akibat penyerapan oleh organ (darah, kulit, dan daging/otot) secara langsung.

b. Mode Refleksi


Dalam mode refleksi Light Emitting Diode (LED) dan Light Dependent Resistor (LDR) dipasang berjajar. Sinyal/perubahan cahaya yang dideteksi oleh LDR adalah sinyal pantulan/refleksi



Gambar 2.1 Mode Konfigurasi (a) Mode Transmisi & (b) Mode Refleksi [8]

2.2.6 Sensor MAX30105

Sensor adalah perangkat yang menerima satu bentuk informasi (fisik, kimia, biologis, dll.) dan mengubahnya menjadi bentuk informasi lain. Dalam penelitian ini digunakan sensor MAX30105, yaitu modul sensor optik partikel dengan sensitivitas tinggi yang memiliki antarmuka I2C dan *output* digital. Sensor ini dapat dihubungkan dengan mikrokontroler yang memiliki antarmuka I2C seperti Arduino, ESP32, STM32, atau lainnya [9].



Gambar 2.2 Sensor MAX30105 [9]

Tabel 2. 5 Spesifikasi MAX30105 [9]


Parameter	Nilai / Keterangan
Catu daya (VDD)	1.8 Volt (Logic)
Catu daya LED Internal (VLED)	3,3 Volt hingga 5,0 Volt
Masukan arus	-20 mA (<i>Typical</i>)
Operating temperature range	-40°C sampai +85°C
LED	Merah (660 nm), IR (880 nm), Hijau (537 nm)
Komunikasi	I2C (hingga 400 kHz)
ADC	18-bit
Ukuran	5.6 mm × 3.3 mm × 1.55 mm

Sensor ini mengintegrasikan tiga LED internal (Merah, Hijau, dan Inframerah), fotodetektor, serta *low noise electronics*. Modul ini beroperasi pada catu daya 1,8V untuk logika sistem dan 3,3V hingga 5,0V untuk driver LED internal. Modul ini juga memiliki antarmuka I2C standar, yang memungkinkan perangkat seluler berkomunikasi dengan mikrokontroler. Selain itu, ada arus siaga nol, yang memungkinkan modul untuk tetap menyala sepanjang waktu.

Tabel 2.6 Konfigurasi Pin Sensor MAX30105 [9]

PIN	NAMA	FUNGSI
1, 5, 6, 7, 8, 14	NC	<i>No connection.</i>
2	SCL	<i>I2C Clock Input.</i> Jalur detak (clock) untuk komunikasi I2C.
3	SDA	<i>I2C Data.</i> Jalur data dua arah (Bidirectional) tipe Open-Drain.
4	PGND	<i>Power Ground.</i> Ground khusus untuk blok driver LED.
9, 10	VLED+	<i>LED Power Supply.</i> Koneksi anoda untuk LED. Gunakan kapasitor bypass ke PGND untuk performa terbaik.
11	VDD	<i>Analog Power Supply Input.</i> Input daya utama untuk sistem analog sensor.
12	GND	<i>Analog Ground.</i> Ground untuk sistem analog.
13	INT	<i>Interrupt.</i> Pin interupsi aktif-rendah (Open-Drain). Hubungkan ke tegangan eksternal dengan resistor <i>pull-up</i> .

2.2.7 ESP32



Gambar 2.3 ESP32 [10]

ESP32 merupakan *board development* yang dikembangkan oleh *Espressif System*. ESP32 pada dasarnya juga sudah mendukung jaringan *Wireless* dengan daya operasi 3.2 Volt hingga 5 Volt. Mikrokontroler ESP-32 memiliki jumlah pin sebanyak 41 pin dan ke 41 pin tersebut adalah pin *analog to digital converter* (ADC). Mikrokontroler ESP-32 ini memiliki modul Wifi sendiri sehingga tidak memerlukan modul Wi-Fi tambahan, dan *flash memory* yang besarnya 4MB memiliki fungsi untuk menyimpan *source code* program dalam jumlah besar dan kompleks [10].

Tabel 2.7 Spesifikasi ESP32 [10]

Mikrokontroler	Xtensa Dual-Core 32-bit LX6
WiFi	802.11 b/g/n tipe HT40
Bluetooth	4.2 dan BLE
Frekuensi	160 MHz
Total GPIO	36
Total SPI-UART- I ² C- I ² S	4-2-2-2
Resolusi ADC	12 bit
Tegangan Operasi	3.4 ~ 5 Volt
Suhu Operasi	-40 ~ 125 Celcius

2.2.8 Battery Shield V1 18650



Gambar 2.4 Battery Shield V1 [11]

Battery Shield V1 18650 merupakan modul catu daya portabel yang dirancang untuk menyediakan suplai energi stabil dari baterai Li-Ion tipe 18650. Modul ini umumnya digunakan pada perangkat IoT, mikrokontroler, serta sistem portabel karena memiliki rangkaian pengisian (*charging*), proteksi (*protection circuit*), dan konversi tegangan (*boost converter*) dalam satu papan.

Secara prinsip kerja, *Battery Shield* memanfaatkan baterai 18650 bertegangan nominal 3.7 V. Tegangan ini kemudian dinaikkan menjadi 5 V menggunakan DC-DC boost converter sehingga dapat digunakan untuk mensuplai mikrokontroler seperti ESP32, Arduino, maupun sensor digital. Selain itu, modul ini dilengkapi IC *charger* (seperti TP4056) yang mengatur proses pengisian baterai, termasuk pembatas arus, proteksi overcharge, dan proteksi over-discharge untuk menjaga umur baterai.

Beberapa versi *Battery Shield* memiliki tombol aktivasi daya (*power switch*) yang berfungsi menyalakan jalur *output* 5 V. Pada kondisi tertentu, modul juga menerapkan *auto-shutoff* ketika arus beban terlalu rendah, yang bertujuan menghemat energi dan mencegah kerusakan baterai. Modul ini umumnya juga dilengkapi LED indikator untuk status pengisian dan *output* daya.

2.2.9 Baterai Li-Ion LG 18650

Untuk mendukung portabilitas alat deteksi stroke dini agar dapat digunakan secara *mobile* tanpa bergantung pada sumber listrik dinding (PLN), dibutuhkan catu daya mandiri yang stabil dan dapat diisi ulang (*rechargeable*). Pada penelitian ini, digunakan baterai jenis Lithium-Ion (Li-Ion) dengan manufaktur LG dan tipe ukuran 18650.

Baterai LG 18650 dipilih karena memiliki densitas energi yang tinggi, *self-discharge* yang rendah, dan siklus hidup yang panjang dibandingkan jenis baterai nikel atau aki kering. Baterai ini menyuplai tegangan nominal sebesar 3.6V hingga 4.2V saat kondisi penuh. Tegangan ini kemudian akan diregulasi oleh modul manajemen daya (seperti TP4056 atau regulator 3.3V pada ESP32) untuk menyuplai mikrokontroler dan sensor MAX30105. pembacaan sensor yang stabil dan mencegah *voltage drop* mendadak saat modul Wi-Fi pada ESP32 melakukan transmisi data.



Gambar 2.5 Baterai Li-Ion 18650 [12]

Adapun spesifikasi teknis dari baterai LG 18650 yang digunakan adalah sebagai berikut:

Tabel 2.8 Spesifikasi Baterai LG 18650 [12]


Parameter	Spesifikasi
Tipe Sel	<i>Lithium-Ion Rechargeable</i>
Model/Manufaktur	LG 18650 (Seri HG2/MJ1/HE4 - <i>sesuaikan</i>)
Ukuran Fisik	Diameter 18mm, Panjang 65mm
Tegangan Nominal	3.60 Volt
Tegangan <i>Cut-off</i> (Habis)	2.50 Volt
Tegangan Pengisian Penuh	4.20 Volt
Kapasitas Standar	3000 mAh (<i>Typical untuk LG HG2</i>)
Arus Keluaran Maksimum	20 Ampere (<i>High Drain</i>)
Berat	± 47 gram

2.2.10 LCD 16x2 dengan Modul I2C

Sebagai media interaksi utama antara alat dengan pengguna (*User Interface*), diperlukan sebuah layar penampil yang mampu menyajikan informasi parameter kesehatan (Tekanan Darah, Gula Darah, Kolesterol) dan status risiko stroke secara jelas dan *real-time*. Pada penelitian ini, digunakan *Liquid Crystal Display* (LCD) tipe karakter 16x2 yang telah terintegrasi dengan modul antarmuka Inter-Integrated Circuit (I2C) .

LCD 16x2 adalah modul tampilan elektronik yang menggunakan kristal cair untuk menghasilkan gambar yang terlihat. 32 karakter. Pemilihan varian yang dilengkapi dengan modul *backpack* I2C (biasanya menggunakan chip PCF8574) didasarkan pada

efisiensi penggunaan pin mikrokontroler. Jika LCD standar membutuhkan setidaknya 6 hingga 12 pin GPIO untuk beroperasi dalam mode paralel, modul I2C memungkinkan LCD dikendalikan hanya dengan 2 pin data (SDA dan SCL) serta 2 pin daya (VCC dan GND). modul ini dilengkapi dengan potensiometer *trimpot* di bagian belakang untuk mengatur kontras karakter agar mudah dibaca pada berbagai kondisi pencahayaan.



Gambar 2.6 Tampilan Fisik LCD 16x2 dengan Modul I2C [13]

Berikut adalah spesifikasi teknis dari modul LCD 16x2 I2C yang digunakan:

Tabel 2.9 Spesifikasi LCD 16x2 I2C [13]

Parameter	ParameterSpesifikasi
Tipe Tampilan	Karakter Alfanumerik (STN/FSTN)
Kapasitas Tampilan	16 Karakter x 2 Baris
Antarmuka Komunikasi	I2C / IIC Serial Interface
Chip Pengendali I2C	PCF8574T / PCF8574AT
Alamat I2C	0x27 (Default) atau 0x3F
Tegangan Operasional	5 Volt DC
Warna Latar (<i>Backlight</i>)	Biru (Karakter Putih) / Hijau (Karakter Hitam)
Dimensi Modul	80 mm x 36 mm x 12.5 mm
Ukuran Area Pandang	64.5 mm x 16.4 mm

Konfigurasi pin untuk menghubungkan LCD ini ke mikrokontroler adalah sebagai berikut:


Tabel 2.10 Konfigurasi Pin Modul I2C LCD [13]

PIN	Label	Fungsi
1	GND	<i>Ground (0V)</i>
2	VCC	<i>Power Supply (+5V)</i>
3	SDA	<i>Serial Data</i> (Terhubung ke pin SDA ESP32/Mikrokontroler)
4	SCL	<i>Serial Clock</i> (Terhubung ke pin SCL ESP32/Mikrokontroler)

2.2.11 Regresi Logistik

Pengertian Regresi dalam statistika adalah salah satu metode untuk menentukan hubungan sebab-akibat antara suatu variabel dengan variabel yang lain. Variabel “penyebab” biasa disebut dengan beberapa istilah seperti misalnya variabel prediktor, variabel penjelas, variabel eksplanatori, variabel independen, variabel bebas, atau variabel X. Sedangkan variabel “terkena akibat” dikenal sebagai variabel yang dipengaruhi dan biasa disebut dengan variabel respon, variabel terikat, variabel dependen, variabel tak bebas atau variabel Y [14].

Perbedaan yang mendasar dengan model regresi linier yaitu pada variabel responnya. Variabel respon pada regresi logistik merupakan variabel biner atau dikotomis. Variabel prediktor dapat berupa variabel polikotomis (kategorik maupun interval). Sedangkan untuk regresi linier, variabel responnya minimal berskala interval. Menurut jenis skala dan variabel respon yang digunakan regresi logistik dibagi menjadi 3 macam, yaitu regresi logistik biner, multinomial dan ordinal. Regresi logistik biner telah banyak digunakan secara luas sebagai salah satu alat analisis pemodelan ketika variabel responnya bersifat biner, yang merujuk pada penggunaan dua buah bilangan 0 dan 1 untuk menggantikan dua kategori pada variabel respon. Contoh variabel respon yang dimaksud adalah kesuksesan (sukses–gagal), kesetujuan (setuju–tidak setuju), keinginan membeli (ya–tidak), terpilih atau tidak terpilih, dan masih banyak lagi [15].



Gambar 2.7 Kurva Regresi Logistik dan Regresi Linier [15]

Selanjutnya, apabila variabel respon memiliki lebih dari dua kategori dan berskala ordinal, maka model yang digunakan adalah regresi logistik ordinal. Skala ordinal merupakan skala pengukuran yang menunjukkan tingkatan atau urutan kategori, namun jarak antar kategori tidak bersifat kuantitatif. Sebagai contoh, tingkat kepuasan pelayanan dapat diklasifikasikan menjadi sangat tidak puas, tidak puas, puas, dan sangat puas. Pada regresi logistik ordinal, variabel respon Y berupa data ordinal, sedangkan variabel prediktor dapat berupa variabel kategorikal, numerik kontinu, maupun kombinasi dari keduanya [14].

Regresi logistik merupakan salah satu metode klasifikasi yang digunakan untuk memodelkan hubungan antara satu atau lebih variabel independen terhadap variabel dependen biner. Dalam konteks deteksi dini risiko stroke, regresi logistik digunakan untuk mengubah nilai-nilai parameter kesehatan seperti tekanan darah, kadar gula darah, dan kolesterol yang telah diperoleh atau diestimasi dari sensor menjadi *output* berupa “Iya” atau “Tidak” terhadap kemungkinan risiko stroke.

Model ini bekerja dengan menghitung peluang atau probabilitas terjadinya suatu kejadian (dalam hal ini, risiko stroke), kemudian mengubahnya menjadi bentuk logit melalui fungsi dibawah ini [16]:

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n \quad (2.1)$$

Keterangan:

- P adalah probabilitas terjadinya stroke,
- X_n adalah variabel prediktor (Usia, Jenis Kelamin, Riwayat Stroke, Jumlah Merokok, Skala RACE, Denyut Jantung, Sistolik, Diastolik, Gula Darah, Kolesterol)
- β_0 adalah koefisien regresi dari masing-masing variabel.

Misal [16]:

$$Z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n \quad (2.2)$$

Misal [16]:

$$\ln \left(\frac{p}{1-p} \right) = z \quad (2.3)$$

$$p = \frac{e^z}{1+e^z} \quad (2.4)$$

Untuk memperoleh nilai probabilitas 0-1, maka digunakan [16]:

$$P(Y=1) = \frac{1}{1+e^{-(\beta_0+\beta_1 X_1+\beta_2 X_2+\dots+\beta_n X_n)}} \quad (2.5)$$

atau bentuk ekuivalennya:

$$P(Y=1) = \frac{e^{(\beta_0+\beta_1 X_1+\beta_2 X_2+\dots+\beta_n X_n)}}{1+e^{(\beta_0+\beta_1 X_1+\beta_2 X_2+\dots+\beta_n X_n)}} \quad (2.6)$$


Probabilitas menjadi hasil klasifikasi:

$$Y^{\wedge} = \begin{cases} 1, & P(Y = 1) \geq 0.5 \\ 0, & P(Y = 1) < 0.5 \end{cases} \quad (2.7)$$

Metode ini dipilih karena sederhana, efisien, dan interpretatif, terutama untuk kasus diagnosis kesehatan berbasis sensor. Sistem cukup membandingkan probabilitas yang dihasilkan terhadap ambang batas tertentu (*threshold*), misalnya 0,5, untuk menghasilkan keputusan “Iya” (berisiko) jika $p \geq 0.5$ atau “Tidak” (tidak berisiko) jika $p < 0.5$. Hasil klasifikasi yang sederhana ini sangat memudahkan pengguna awam untuk memahami kondisi kesehatannya tanpa interpretasi medis yang rumit.

2.2.12 Multi-Layer Perceptron

Multilayer Perceptron (MLP) merupakan salah satu jenis jaringan saraf tiruan yang umum digunakan. MLP terdiri dari beberapa lapisan, yaitu lapisan input, lapisan tersembunyi, dan lapisan *output*, di mana setiap lapisan terdiri dari elemen-elemen perseptron yang dikenal sebagai neuron.



Gambar 2.8 MLP Topology [17]

Gambar diatas menunjukkan ilustrasi MLP menggunakan satu hidden layer dengan variasi jumlah, satu lapisan input, dan satu lapisan *output*. Dalam proses interaksi antar neuron, setiap node memiliki sejumlah bias tertentu. Lapisan input terdiri dari n variabel input $X = \{x_1, x_2, \dots, x_n\}$ dan lapisan *output* terdiri dari m variabel *output* $Y = \{y_1, y_2, \dots, y_m\}$.

Sebelum data diproses oleh *Artificial Neural Network*, dilakukan tahap praproses berupa normalisasi untuk memastikan bahwa seluruh variabel input berada pada skala yang seragam. Dalam penelitian ini, normalisasi dilakukan menggunakan metode *min-max scaling* yang memetakan nilai data ke dalam rentang $[-1,1]$. Secara matematis, proses normalisasi dinyatakan sebagai berikut [18]:

$$x_{\text{norm}} = 2 \cdot \left(\frac{x - x_{\min}}{x_{\max} - x_{\min}} \right) - 1 \quad (2.5)$$

Keterangan:

x_{norm} = nilai hasil normalisasi

x = data asli

$x_{\min}$ = nilai minimum data

$x_{\max}$ = nilai maksimum data

Dalam implementasi menggunakan MATLAB, normalisasi ini direalisasikan melalui fungsi *mapminmax*, yang secara konseptual ekuivalen dengan persamaan di atas. Fungsi tersebut melakukan transformasi linear dengan parameter *offset* dan *gain*, sehingga dapat dinyatakan dalam bentuk:

$$x_{\text{norm}} = (x - x_{\text{offset}}) \cdot \text{gain} + y_{\min} \quad (2.6)$$

Keterangan:

x_{offset} = nilai minimum data

Gain = faktor skala normalisasi

y_{min} = batas minimum rentang normalisasi

dengan $x_{offset} = x_{min}$, $gain = \frac{2}{x_{max} - x_{min}}$, dan $y_{min} = -1$. Dengan demikian, pendekatan teoritis dan implementasi yang digunakan memiliki kesesuaian yang konsisten.

Pada setiap *neuron* dilakukan proses penjumlahan antara input dan bobot, kemudian ditambahkan bias. Proses ini berperan penting dalam meningkatkan stabilitas komputasi dan mempercepat proses konvergensi selama pelatihan jaringan. Proses komputasi dalam MLP dilakukan pada setiap neuron. Secara umum, persamaan *neuron hidden layer* dinyatakan sebagai:

$$Z_j = \sum_{i=1}^n \omega_{ij}x_i + b_j \quad (2.7)$$

Keterangan:

- z_j = input total neuron ke-j
- ω_{ij} = bobot dari input ke-iii menuju neuron ke-j
- x_i = input ke-i
- b_j = bias neuron ke-j
- n = jumlah variabel input

Output *neuron* kemudian diperoleh melalui fungsi aktivasi non-linear:

$$a_j = \tanh(z_j) \quad (2.8)$$

Keterangan:

- a_j = *output neuron*
- z_j = hasil penjumlahan input dan bobot

Fungsi aktivasi digunakan untuk menghasilkan hubungan non-linear antara *input* dan *output*. Tanpa fungsi aktivasi, jaringan saraf hanya akan bekerja seperti model linear biasa dan tidak mampu mempelajari pola kompleks.

Untuk keseluruhan jaringan, hubungan antara input dan output dapat dirumuskan sebagai [19]:

$$y = \omega_2 \cdot \tanh(\omega_1 x + b_1) + b_2 \quad (2.9)$$

Keterangan:

- ω_1 = bobot *input* ke *hidden layer*
- ω_2 = bobot *hidden layer* ke *output*
- b_1 = bias *hidden layer*
- b_2 = bias *output layer*
- x = input jaringan

- y = *output* jaringan
- $\tanh$ = fungsi aktivasi non-linear

Input terlebih dahulu diproses pada hidden layer menggunakan bobot dan bias, kemudian dilewatkan ke fungsi aktivasi $\tanh$. Hasil aktivasi selanjutnya diproses kembali menuju *output layer* untuk menghasilkan prediksi akhir.

Untuk mengevaluasi kinerja model, digunakan fungsi error berupa *Mean Squared Error* (MSE), yang mengukur rata-rata kuadrat selisih antara nilai prediksi dan target [19].

$$E_d = \frac{1}{N} \sum_{i=1}^N (t_i - y_i)^2 \quad (2.10)$$

Keterangan:

- E_d = Mean Squared Error
- N = jumlah data
- t_i = target sebenarnya
- y_i = hasil prediksi model

MSE menghitung rata-rata kuadrat selisih antara nilai target dan prediksi. Nilai MSE yang semakin kecil menunjukkan bahwa hasil prediksi model semakin mendekati nilai target, sehingga performa model dapat dikatakan semakin baik.

Metode *Bayesian Regularization* berfungsi untuk mengatasi masalah *overfitting* dan meningkatkan kemampuan generalisasi model terhadap data baru. Metode ini memodifikasi fungsi error dengan menambahkan komponen penalti terhadap bobot [20].

$$F = \alpha E_d + \beta E_\omega \quad (2.11)$$

dengan:

$$E_\omega = \sum \omega^2 \quad (2.12)$$

Keterangan:

- F = fungsi error total
- E_d = error data
- E_ω = penalti bobot
- α = parameter error data
- β = parameter regularisasi

Bayesian Regularization menambahkan penalti terhadap bobot yang terlalu besar. Penambahan komponen E_ω bertujuan untuk mengontrol besar bobot sehingga model tidak terlalu kompleks. Dengan demikian, model yang dihasilkan lebih stabil dan mampu memberikan prediksi yang lebih baik pada data baru.

Proses pembaruan bobot dan bias dilakukan menggunakan algoritma *Levenberg-Marquardt* (LM), yang merupakan kombinasi antara metode *gradient descent* dan *Gauss-Newton*. Algoritma ini dikenal memiliki kecepatan konvergensi yang tinggi [20].

$$\omega_{\text{new}} = \omega_{\text{old}} - (J^T J + \mu I)^{-1} J^T e \quad (2.13)$$

Keterangan:

- ω_{new} = bobot baru
- ω_{old} = bobot lama
- J = matriks Jacobian
- J^T = transpose Jacobian
- μ = parameter damping
- I = matriks identitas
- e = vektor error

Algoritma LM merupakan kombinasi antara metode *Gradient Descent* dan *Gauss-Newton*. Jacobian digunakan untuk menghitung sensitivitas error terhadap perubahan bobot. Parameter μ berfungsi menjaga stabilitas optimasi. Jika μ besar maka proses menyerupai *gradient descent*, sedangkan jika μ kecil maka proses mendekati *Gauss-Newton* yang lebih cepat konvergen.

2.2.13 Skala RACE

Deteksi dini dan penanganan cepat sangat penting dalam kasus stroke untuk meminimalkan tingkat kecacatan dan meningkatkan peluang kesembuhan pasien. Salah satu alat yang efektif dalam menilai tingkat keparahan stroke di lapangan adalah Skala Evaluasi Oklusi Arteri Cepat (RACE). Skala ini dikembangkan sebagai penyederhanaan dari Skala Stroke Institut Kesehatan Nasional (NIHSS) dengan fokus pada efisiensi dan akurasi dalam lingkungan pra-rumah sakit, seperti saat penanganan oleh tim medis darurat[21].

Skala RACE dirancang untuk membantu tenaga medis, khususnya di unit gawat darurat atau layanan ambulans, dalam menilai secara cepat kemungkinan adanya stroke akibat oklusi arteri besar atau *Large Vessel Occlusion* (LVO). RACE menilai lima aspek utama yang memiliki kekuatan prediksi tinggi terhadap adanya sumbatan pembuluh darah besar, yaitu [21]:

1. Kelumpuhan Wajah (*Facial Palsy*)
2. Paresis Brakialis (Kelemahan Lengan)
3. Paresis Krural (Kelemahan Tungkal)
4. Deviasi Okulefalik (Pergerakan Kepala dan Mata ke Satu Sisi)
5. Afasia atau Agnosia (Gangguan Bicara atau Kesadaran Tubuh)

Masing-masing item dinilai dan diberikan skor, dengan total skor berkisar dari 0 hingga 9. Penilaian dilakukan secara cepat dan sederhana di tempat kejadian, tanpa memerlukan alat khusus. Berdasarkan data dan penelitian yang mendukung penggunaan skala ini, interpretasi skor adalah sebagai berikut:

- Skor RACE > 1: Mengindikasikan adanya kemungkinan stroke.
- Skor RACE > 4: Mengindikasikan kemungkinan kuat adanya oklusi pembuluh darah besar (LVO) yang memerlukan tindakan lebih lanjut di pusat stroke komprehensif.

Skala ini menunjukkan sensitivitas sebesar 85% dan spesifisitas 69% dalam mendeteksi LVO, menjadikannya alat yang andal untuk membantu pengambilan keputusan cepat di lapangan, seperti apakah pasien perlu segera dirujuk ke fasilitas yang mampu melakukan intervensi endovaskular. Dengan penerapan skala RACE, diharapkan deteksi stroke, terutama stroke akibat oklusi besar, dapat dilakukan lebih cepat dan akurat sehingga pasien dapat memperoleh terapi reperfusi tepat waktu dan mengurangi risiko kecacatan jangka panjang [21].

Interpretasi Skor RACE [21]

- Skor 0–1
Menunjukkan kemungkinan stroke rendah. Pada kategori ini, stroke besar atau oklusi pembuluh darah besar relatif kecil kemungkinannya.
- Skor >1
Mengindikasikan kemungkinan terjadinya stroke, sehingga pasien perlu segera mendapatkan evaluasi medis lanjutan.
- Skor >4
Menunjukkan kemungkinan tinggi adanya oklusi pembuluh darah besar (LVO). Berdasarkan studi validasi, nilai ini memiliki sensitivitas sekitar 85% dan spesifisitas 69%, sehingga pasien dengan skor ini berpotensi memerlukan penanganan darurat dan rujukan cepat ke pusat stroke komprehensif untuk mempertimbangkan terapi endovaskular.

Tabel 2.11 Tabel Skor dari Skala RACE [21]

Item	Instruksi		Skor RACE
Kelumpuhan Wajah	Minta pasien untuk memperlihatkan gigi	Tidak ada (gerakan simetris)	0
		Ringan (sedikit asimetris)	1
		Sedang sampai berat (asimetris sepenuhnya)	2
Fungsi motor lengan	Meminta pasien mengangkat lengan 90 derajat (duduk) atau 45 derajat (terlentang)	Normal sampai ringan (lengan terangkat lebih dari 10 detik)	0
		Sedang (lengan terangkat kurang dari 10 detik)	1
		Berat (pasien tidak bisa mengangkat lengan melawan gravitasi)	2
Fungsi motor tungkai	Meminta pasien mengankat tungkai 30 derajat (terlentang)	Normal sampai ringan (tungkai terangkat lebih dari 5 detik)	0
		Sedang (tungkai terangkat kurang dari 5 detik)	1
		Berat (pasien tidak bisa mengangkat tungkai melawan gravitasi)	2
Deviasi kepala dan pandnagan	Amati pergerakan mata dan deviasi kepala ke satu sisi	Tidak ada (pergerakan mata ke kedua sisi bisa dilakukan dan tidak ada deviasi kepala)	0
		Ada (mata dan kepala tampak deviasi ke satu sisi)	1
Afasia (jika hemiparesis kanan)	Meminta pasien melakukan kedua perintah verbal: - “tutup mata” - “kepalkan tangan”	Normal (melakukan kedua tugas dengan benar)	0
		Sedang (melakukan satu tugas dengan benar)	1
		Berat (tidak melakukan kedua tugas)	2
Agnosia (jika hemiparesis kiri)	Tanyakan: - “ini tangan siapa?” sambil menunjukkan lengan paretik pasien (asomatagnosia) - “apakah anda bisa menggerakkan tangan ini dengan baik?” (anosognosia)	Normam (tidak ada asomatognosia atau anosognosia)	0
		Sedang (ada asomatognosia atau anosognosia)	1
		Derat (keduanya ada)	2
Total Skor RACE			0-9

Oklusi adalah kondisi tersumbatnya pembuluh darah yang menyebabkan terhambatnya aliran darah ke jaringan otak. Pada stroke iskemik, oklusi terjadi akibat bekuan darah dan dapat menyebabkan kerusakan sel otak. Oklusi pada pembuluh darah besar menimbulkan gejala neurologis yang berat dan menjadi target utama deteksi dini menggunakan Skala RACE.

2.3 PENELITIAN TERKAIT

2.3.1 Penelitian Agrippina Waya Rahmaning Gusti, Kemalasari, J S Peter Parasian (2025)

Berjudul: "Deteksi Dini Kesehatan Berdasarkan Nilai Kadar Gula Darah, Kolestrol, dan Asam Urat Non-Invasif dengan *Multi-Layer Perceptron*". Jurnal ini membahas tentang pengujian yang dilakukan untuk mengevaluasi kinerja sistem deteksi kesehatan non-invasif yang dikembangkan, meliputi pengujian sensor MAX30105, model *Multi-Layer Perceptron* (MLP), serta pengiriman data. Hasil pengujian sensor menunjukkan tingkat akurasi detak jantung sebesar 98,1%, sehingga sensor dinyatakan layak digunakan sebagai sumber data masukan. Pengujian metode MLP dengan arsitektur lima *hidden layer* dan algoritma *Bayesian regularization backpropagation* menghasilkan akurasi prediksi sebesar 90,4% untuk gula darah, 90,2% untuk kolesterol, dan 87,7% untuk asam urat. Tingkat akurasi tersebut menunjukkan bahwa MLP mampu memodelkan hubungan non-linear antara data inframerah, usia, dan detak jantung secara efektif. Selain itu, pengujian pengiriman data ke *Firestore Realtime Database* menunjukkan bahwa sistem mampu mengirimkan data secara akurat dengan waktu transmisi rata-rata 1,9 detik, sehingga sistem dinilai berjalan sesuai dengan perancangan [22].

2.3.2 Penelitian Michelle Annice Tjitra, Nagisa Eremia Anju, Dodi Sudiana and Mia Rizkinia (2024)

Berjudul: "*A Wireless Noninvasive Blood Pressure Measurement System Using MAX30105 and Random Forest Regressor for Photoplethysmography Signals*". Pada Jurnal ini membahas tentang pengembangan alat pengukuran tekanan darah non-invasif yang bersifat nirkabel menggunakan teknologi *photoplethysmography* (PPG). Sistem ini dirancang untuk mengatasi keterbatasan metode tradisional yang menggunakan manset (*sphygmomanometer*) dengan menghadirkan alat yang lebih nyaman, *real-time*, dan bisa dipantau secara jarak jauh. Perangkat yang digunakan terdiri dari sensor MAX30105 untuk menangkap sinyal PPG, di mana modul ini hanya memanfaatkan cahaya inframerah (IR) untuk mendeteksi perubahan volume darah pada jaringan. Sinyal yang direkam kemudian diproses oleh mikrokontroler ESP-WROOM-32 dan dikirim melalui koneksi Wi-Fi ke *server* berbasis MySQL untuk disimpan dan divisualisasikan. Dataset penelitian diambil dari 6 subjek sehat dengan total 114 rekaman PPG, dan data dibagi menjadi 90% untuk pelatihan dan 10% untuk pengujian. Hasil evaluasi menunjukkan nilai Mean Absolute Error (MAE) sebesar 4.38 mmHg untuk SBP dan 4.49 mmHg untuk DBP dengan koefisien determinasi (R^2) masing-masing 0.37 dan 0.46 pada data pelatihan. Namun, pada data pengujian, model menunjukkan kinerja yang lebih rendah dengan R^2 yang negatif, menunjukkan bahwa model belum optimal dalam generalisasi data baru. Sistem ini juga dilengkapi dengan antarmuka grafis berbasis web yang memungkinkan pengguna untuk melihat grafik sinyal PPG secara *real-time* dan menampilkan hasil prediksi tekanan darah secara otomatis[23].

2.3.3 Penelitian Eko Agus Suprayitno, Akhmad Setiawan, Rohman Dijaya (2018)

Berjudul: "*Design of Instrumentation in Detecting Blood Sugar Levels with Non-Invasive Technique Base on IoT (Internet of Things)*". Pada jurnal ini membahas tentang pengembangan alat pengukur kadar gula darah secara non-invasif, artinya tanpa melukai kulit atau mengambil sampel darah. Alat ini menggunakan sensor MAX30100, yang memanfaatkan sinar inframerah untuk mendeteksi kadar gula melalui ujung jari. Proses pengukuran dilakukan hanya dengan menempelkan jari pada sensor, dan hasilnya ditampilkan pada layar LCD serta aplikasi di *smartphone* Android melalui koneksi IoT (menggunakan *Firestore* dan ESP8266). Sistem ini dirancang untuk membantu pasien diabetes dan tenaga medis dalam melakukan pemantauan jarak jauh. Pengujian dilakukan pada 14 subjek, baik normal maupun penderita diabetes, dan dibandingkan dengan alat pengukur gula darah invasif standar industri. Hasil menunjukkan tingkat akurasi sebesar 90,3%, dengan deviasi pengukuran antara 1,2 hingga 39,6 mg/dL. Alat ini juga terbukti mampu mengirimkan data jarak jauh hingga 823 km, asalkan perangkat terhubung ke internet. Faktor yang memengaruhi keakuratan alat termasuk ketebalan kulit jari pengguna dan kualitas sinyal inframerah yang diterima oleh fotodioda. Masalah pada transmisi data juga ditemukan ketika menggunakan jaringan 3G yang tidak stabil, sehingga 4G LTE lebih direkomendasikan untuk komunikasi data *real-time* yang optimal. Penelitian ini menyimpulkan bahwa sistem pengukuran non-invasif berbasis IoT ini efektif, aman, dan potensial sebagai solusi pemantauan gula darah yang praktis dan efisien untuk penderita diabetes [24].

2.3.4 Penelitian Rika Rokhana, Agrippina Waya Rahmaning Gusti, dan Rizki Umar Salim (2025)

Berjudul: "*Smart System for Early Diagnosis of Gastroesophageal Reflux Disease (GERD)*". Pada jurnal ini membahas tentang pengembangan sistem cerdas berbasis Internet of Things (IoT) untuk diagnosis dini penyakit Gastroesophageal Reflux Disease (GERD) secara non-invasif melalui monitoring pH saliva dan pengisian kuesioner GERD-Q. Latar belakang penelitian ini adalah tingginya prevalensi GERD di Indonesia serta keterbatasan metode diagnosis konvensional seperti endoskopi yang bersifat invasif, mahal, dan menimbulkan ketidaknyamanan bagi pasien. Sistem yang dikembangkan menggunakan sensor pH E-201C untuk mengukur tingkat keasaman saliva sebagai indikator GERD. Sensor dihubungkan dengan mikrokontroler Arduino untuk proses pembacaan data dan konversi Analog-to-Digital Converter (ADC). Data hasil pengukuran kemudian dikirim dan disimpan melalui sistem berbasis website menggunakan framework Vue.js dan Firestore sehingga dapat dipantau oleh dokter maupun pasien secara daring. Selain data pH saliva, sistem juga mengolah parameter lain seperti usia, tinggi badan, berat badan, nilai GERD-Q, dan gaya hidup. Pengolahan data dilakukan menggunakan metode regresi logistik untuk menentukan probabilitas seseorang berisiko mengalami GERD. Persamaan regresi logistik digunakan untuk menghitung nilai probabilitas dengan batas klasifikasi 0,5, di mana nilai di atas 0,5 menunjukkan potensi GERD.

Hasil penelitian menunjukkan bahwa sensor pH memiliki tingkat akurasi sekitar 99,25% dengan sensitivitas yang baik terhadap perubahan pH saliva. Selain itu, individu dengan nilai pH saliva rendah dan skor GERD-Q tinggi cenderung memiliki probabilitas lebih besar terkena GERD. Namun, penelitian ini masih memiliki keterbatasan karena hasil sistem belum dibandingkan secara langsung dengan data rekam medis lengkap maupun pemeriksaan dokter sebagai standar klinis, sehingga sistem ini masih ditujukan sebagai alat deteksi dini dan pendukung diagnosis awal GERD [25].

2.3.5 Penelitian Yana Inayatullah, Almido H. Ginting, Samy Y. Doo (2024)

Berjudul: " Rancang Bangun Sistem Monitoring Detak Jantung Dan Saturasi Oksigen Menggunakan Oximeter Max30105". Pada jurnal ini peneliti ini merancang sistem monitoring detak jantung (BPM) dan saturasi oksigen (SpO₂) berbasis *Internet of Things* (IoT) menggunakan sensor MAX30105, NodeMCU ESP8266, dan aplikasi Blynk. Data *heart rate* (HR) dan SpO₂ ditampilkan pada LCD I2C serta dikirim ke *smartphone* dan PC secara nirkabel melalui *platform* Blynk. Sistem ini bertujuan untuk memudahkan pemantauan kesehatan secara *real-time* dan mengurangi ketergantungan pada alat medis konvensional. Pengujian alat dilakukan terhadap 10 subjek dengan perbandingan menggunakan oximeter standar (YX102). Hasil menunjukkan tingkat akurasi tinggi, dengan rata-rata error hanya 0,4% untuk *heart rate* (HR) dan 0,2% untuk SpO₂. Rata-rata detak jantung terukur 85 bpm dan saturasi oksigen 99% pada subjek berusia 20–26 tahun, menunjukkan kondisi kesehatan normal. Sistem juga terbukti stabil dalam konektivitas dan pengiriman data ke *platform* Blynk. Penelitian ini menyimpulkan bahwa alat yang dirancang berhasil memberikan pengukuran akurat, dapat digunakan secara non-invasif tanpa risiko infeksi, dan praktis untuk pemantauan kesehatan pribadi[26].

BAB 3

DESAIN SISTEM

3.1 DESKRIPSI SOLUSI


Solusi yang ditawarkan dalam proyek akhir ini adalah pengembangan alat deteksi dini stroke secara non-invasif berbasis IoT menggunakan metode regresi logistik. Alat ini mengintegrasikan sensor MAX30105 untuk membaca sinyal inframerah dari ujung jari, yang kemudian diolah menggunakan model *Multi-Layer Perceptron* (MLP) untuk memperkirakan tiga parameter utama risiko stroke, yaitu tekanan darah, kadar kolesterol, dan kadar gula darah. Hasil estimasi parameter ini kemudian dianalisis dengan regresi logistik untuk menentukan status risiko stroke dalam bentuk “Iya/Tidak”.

Fitur utama alat ini mencakup tampilan LCD untuk melihat hasil pengukuran secara langsung, tombol untuk mengirim data ke database, dan aplikasi Android untuk pemantauan *real-time* serta penyimpanan riwayat pemeriksaan. Alat ini juga dilengkapi kuesioner gejala stroke berbasis Skala RACE, yang memperkuat akurasi prediksi risiko. Desain alat yang portable dan antarmuka aplikasi yang *user-friendly* memudahkan pengguna dalam memeriksa kondisi kesehatannya secara mandiri.

Secara garis besar, penggunaan sensor optik MAX30105 dengan MLP memungkinkan prediksi parameter kesehatan tanpa metode invasif, sedangkan regresi logistik menyederhanakan hasil menjadi keputusan biner yang mudah dipahami pengguna. Integrasi IoT memberikan akses data *real-time*, sehingga solusi ini efektif untuk deteksi dini, monitoring berkelanjutan, dan pencegahan risiko stroke di masyarakat.

3.2 PERANCANGAN SISTEM

Perancangan sistem yang dilakukan meliputi proses perancangan *hardware*, pemrograman mekanik alat yang akan dibuat. Dalam tahap ini dilakukan perancangan sistem kerja alat yang akan dibuat. Terdapat beberapa komponen yang digunakan seperti sensor, sumber tegangan, dan mikrokontroler untuk implementasi dari proyek akhir ini.




Gambar 3.1 Blok Diagram Sistem

Sistem monitoring ini terdiri dari tiga bagian utama, yaitu input, proses, dan *output*. Pada bagian input terdapat sensor MAX30105 untuk mendeteksi nilai IR dan HR dari sensor. Selain itu sistem ini menggunakan satu baterai 18650 sebagai sumber daya utama. Tegangan baterai dinaikkan menjadi 5V menggunakan *Battery Shield V1* untuk memenuhi kebutuhan tegangan masukan sensor dan layar Liquid Crystal Display (LCD) 16x2. Data dari sensor dikirim ke ESP32 sebagai pusat pemrosesan. ESP32 mengolah data dan menampilkan hasilnya pada LCD serta mengirimkan ke database. Dari hasil sensor akan memunculkan data tekanan darah, kolesterol, gula darah pada LCD dan pada aplikasi yang akan ditambah dengan kemungkinan Iya atau Tidak dari prediksi terhadap stroke dini.

3.2.1 Flowchart Sistem

Dalam tahap ini akan dirancang tahapan dalam penyelesaian misi yang berupa logika sistem. Berikut merupakan *flowchart* sistem yang akan dibuat.




Gambar 3.2 *Flowchart* Sistem

Pada Gambar 3.2 ditunjukkan *flowchart* dari sistem proyek akhir ini. Proses dimulai dari tahap inisialisasi, di mana sensor MAX30105 dan LCD diaktifkan. Setelah inisialisasi selesai, sistem menampilkan halaman WiFi Setup untuk memungkinkan pengguna memasukkan SSID dan *password* melalui browser. Sistem kemudian memeriksa status koneksi, dan apabila perangkat belum terhubung, proses akan kembali ke halaman WiFi Setup hingga koneksi berhasil. Setelah perangkat berhasil terhubung ke jaringan, sistem menampilkan menu *Start Measurement* untuk memulai proses pengukuran. Pada tahap ini pengguna diminta melakukan sensor dengan meletakkan jari pada sensor, sehingga MAX30105 dapat membaca nilai intensitas sinyal inframerah (IR) dan *heart rate* (HR). Setelah pembacaan selesai, pengguna memasukkan umur sebagai parameter tambahan. Data IR dan umur tersebut diproses menggunakan metode *Multilayer Perceptron* (MLP) untuk menghasilkan estimasi tekanan darah, kadar kolesterol, dan kadar gula darah. Ketiga

hasil estimasi tersebut dan *heart rate* (HR) dari pengukuran kemudian ditampilkan pada LCD. Selanjutnya pengguna diberi pilihan untuk mengulangi proses pengukuran. Jika memilih untuk mengulang, sistem kembali ke tahap pemindaian jari. Jika tidak, pengguna diminta memasukkan ID agar data dapat diidentifikasi sebelum dikirimkan ke database. Setelah data terkirim, memasukkan data pendukung lain seperti Skala RACE, jumlah rokok yang dikonsumsi serta riwayat keluarga kemudian aplikasi memprosesnya menggunakan metode Regresi Logistik untuk menentukan kondisi risiko stroke dengan keluaran “iya” atau “tidak.” Nilai tekanan darah, kolesterol, gula darah, serta hasil prediksi risiko stroke kemudian ditampilkan pada aplikasi. Proses sistem berakhir ketika seluruh tahapan selesai dan pengguna tidak lagi memilih untuk mengulangi pengukuran.


3.3 PERANCANGAN *HARDWARE*

Desain proyek akhir ini dapat dilihat pada gambar berikut. Pada bagian kotak terdiri dari mikrokontroler ESP32, baterai, modul *charger*. Selanjutnya pada bagian atas kotak terdapat 3 lubang, pertama untuk LCD, 2 lubang bulat sebagai *push button*. Dibagian samping kotak terdapat 3 lubang, digunakan sebagai kabel untuk menyambungkan mikrokontroler pada dengan sensor, 1 lubang sebagai *switch on/off* dan 1 lubang sebagai kabel *charger*. Kotak alat yang akan dibuat sebagai berikut.



Gambar 3.3 Desain Alat

Detail desain alat akan dilampirkan pada Tabel dibawah:




Gambar 3.4 (a) Tampak Samping Kiri (b) Tampak Samping Kanan Desain *Final Prototype*

Tabel 3.1 Detail desain alat


Komponen	Deskripsi
LCD	Menampilkan informasi status alat atau hasil pemindaian sidik jari.
Button Merah	<i>Button Select</i> , memilih menu yang ada pada sistem
Button Kuning	<i>Button Enter</i> , untuk mengeksekusi perintah atau option menu yang dipilih
<i>Fingerprint</i>	Sensor digunakan untuk memindai dan mengenali sidik jari pengguna.
Switch	Saklar untuk menghidupkan atau mematikan perangkat
<i>Port Charger</i>	<i>Port</i> pengisian daya, kemungkinan menggunakan USB

3.3.1 Perancangan Desain PCB

Dalam proyek akhir ini, Printed Circuit Board (PCB) dirancang sebagai media penghubung antar komponen agar sistem dapat beroperasi secara optimal. Penempatan komponen dilakukan secara hati-hati untuk meminimalkan risiko terjadinya hubungan pendek akibat tegangan. Selain itu, lebar jalur pada PCB disesuaikan dengan ukuran komponen, sehingga tidak terlalu sempit atau terlalu lebar, agar aliran arus tetap stabil. Desain PCB yang digunakan dalam proyek ini dapat dilihat pada gambar berikut:



Gambar 3.5 Desain *Schematic Prototype*




Gambar 3.6 Desain *Board PCB Prototype*


3.3.2 Perancangan Elektrik

Rangkaian sistem elektrik pada proyek ini menggunakan mikrokontroler ESP32 sebagai pusat pengolahan yang terhubung dengan sensor MAX30105 untuk membaca sinyal inframerah dan detak jantung. Sistem mendapat suplai daya dari baterai 3,7V yang dinaikkan menjadi 5V melalui modul *batteryshield*. Selama proses pengukuran, ESP32 hanya berfokus pada pembacaan data dari sensor agar

hasilnya stabil dan akurat. Seluruh nilai keluaran kemudian ditampilkan pada LCD 16x2, sehingga pengguna dapat melihat hasil pengukuran secara langsung dari perangkat.



Gambar 3.7 Racangan Elektrik Seluruh Komponen



Gambar 3.8 Elektrikal Sistem

3.3.3 Pembuatan Alat

Pembuatan alat dimulai dengan proses perakitan, yang melibatkan penggabungan berbagai komponen elektronik secara sistematis sesuai dengan desain dan skema rangkaian yang telah dirancang sebelumnya. Proses ini mencakup beberapa tahap penting. Pertama, komponen-komponen dipasang pada papan sirkuit tercetak (PCB) dengan posisi yang telah ditentukan agar jalur koneksi dapat bekerja optimal. Selanjutnya, dilakukan penyolderan setiap komponen secara hati-hati untuk memastikan sambungan listrik yang stabil dan mengurangi risiko terjadinya hubungan pendek. Tahap berikutnya adalah penyambungan kabel penghubung antar komponen dengan PCB, sehingga aliran listrik dan sinyal dapat berjalan secara efisien tanpa gangguan.

Setelah seluruh komponen terpasang dengan rapi, mereka kemudian ditata secara terorganisir ke dalam kotak atau *casing* pelindung. *Casing* ini berfungsi tidak hanya untuk menjaga kestabilan fisik sistem, tetapi juga untuk melindungi

komponen dari gangguan eksternal, seperti debu, benturan, atau interferensi elektromagnetik. Tahap akhir dari proses pembuatan fisik adalah kalibrasi sensor, di mana parameter sensor disesuaikan agar dapat memberikan hasil pengukuran yang akurat dan konsisten sesuai dengan kondisi yang diharapkan dalam pengoperasian alat. Dengan melalui seluruh rangkaian tahapan ini, alat siap digunakan dengan performa yang optimal dan aman.

3.4 KALIBRASI SENSOR

3.4.1 Pengambilan Nilai Inframerah dan detak Jantung

Kalibrasi sensor dilakukan untuk memastikan hasil bacaannya sesuai dengan kebutuhan sistem. Prosesnya dimulai dengan mengambil data langsung dari keluaran sensor, yaitu nilai inframerah dan detak jantung. Pengambilan sampel dilakukan pada responden laki-laki dan perempuan dengan rentang usia 20 sampai 70 tahun. Cara pengujiannya cukup sederhana dengan cara meletakkan ujung jari di atas sensor, lalu nilai inframerah dan detak jantung yang muncul dari sensor MAX30105 dicatat. Data inilah yang kemudian digunakan untuk menyesuaikan sensor agar pembacaannya lebih stabil dan akurat.

3.4.2 Membandingkan Nilai Detak Jantung dengan Tensimeter

Sampel data nilai detak jantung yang terbaca dari sensor MAX30105 dibandingkan dengan nilai acuan yang dihasilkan oleh tensimeter OMRON. Perbandingan ini dilakukan untuk melihat seberapa dekat hasil pembacaan sensor dengan alat medis yang sudah umum digunakan dan dianggap lebih akurat.

Prosesnya dilakukan dengan cara mengukur detak jantung responden menggunakan sensor MAX30105 dan pengukuran menggunakan tensimeter OMRON diwaktu bersamaan pada kondisi yang sama. Hasil kedua pengukuran tersebut dicatat dan dibandingkan satu per satu. Melalui perbandingan ini, dapat diketahui tingkat keakuratan sensor MAX30105 serta seberapa besar selisih pembacaan yang mungkin terjadi. Data ini menjadi dasar untuk menyimpulkan bahwa pembacaan sensor akurat dan memastikan bahwa nilai *heart rate* (HR) yang dihasilkan cukup dapat diandalkan untuk kebutuhan sistem.

3.5 PENGUMPULAN DATA SAMPEL

Proses pengumpulan data sampel dilakukan di lingkungan rumah yang beralamat di Jl. Parang Ukel, Kadipaten, Babadan, Ponorogo, Jawa Timur 63491. Dalam kegiatan ini, tim peneliti berhasil memperoleh sebanyak 50 data dari responden dengan rentang usia antara 20 hingga 60 tahun. Untuk memastikan kualitas dan konsistensi data, seluruh proses pengambilan data dilakukan dalam kondisi lingkungan yang tenang dan terkendali. Pengukuran sinyal inframerah serta


detak jantung dilakukan menggunakan sensor MAX30105. Kedua parameter tersebut digunakan sebagai fitur masukan (*input*) dalam model *multi-layer perceptron*.

Selain itu, usia responden juga turut dimasukkan sebagai variabel input dalam model. Sebagai data acuan (*target*), dilakukan pengukuran kadar gula darah, kolesterol, tekanan darah sistol dan diastol menggunakan alat invasif Elvasense 3in1 dan tensi darah digital OMRON. Data hasil pengukuran ini digunakan sebagai nilai keluaran (*output*) dalam proses pelatihan model *multi-layer perceptron*. Seluruh proses pengambilan data dilakukan di dalam ruangan dengan pencahayaan yang memadai untuk mendukung keakuratan pembacaan sensor dan alat ukur yang digunakan. Selain itu, dalam pengumpulan data dilakukan beberapa pengamatan terhadap variabel ras, riwayat keluarga terhadap stroke, serta jumlah rokok per hari pada perokok aktif. Data tersebut yang akan dimasukkan sebagai variabel input dalam model regresi logistik untuk menghitung persentase kemungkinan stroke serta potensi beresiko atau tidak beresiko.

3.6 PERANCANGAN PENGUJIAN DAN PENGAMBILAN DATA

Dalam melakukan pengujian pengambilan data terdapat beberapa hal yang perlu diperhatikan. Mulai dari penggunaan sensor sampai pengolahan data sensor untuk mendapatkan nilai tekanan darah, kolestrol dan kadar gula darah dari hasil pengujian. Selain itu terkait data data pendukung terhadap faktor pengaruh stroke yang akan diolah untuk mendapatkan hasil dari kemungkinan stroke.

3.6.1 Perumusan *Multi-layer Perceptron* Regresi Tekanan Darah, Kolesterol, dan Gula Darah



Gambar 3.9 Proses *Multi-Layer Perceptron*

Proses perumusan dilakukan dengan pencarian arsitektur model *Multi-Layer Perceptron* yang optimal dilakukan menggunakan *Neural Network Toolbox* pada perangkat lunak MATLAB. Proses pelatihan model menerapkan pendekatan pembelajaran terarah dengan algoritma *Bayesian Regularization Backpropagation*. Data masukan dinormalisasi ke dalam rentang nilai -1 hingga 1. Setiap lapisan pada arsitektur menggunakan fungsi aktivasi *hyperbolic tangent* (tanh) untuk memodelkan hubungan nonlinear antara data masukan dan keluaran. Fungsi aktivasi ini dipilih karena menghasilkan keluaran pada rentang -1 hingga 1 sehingga sesuai dengan hasil normalisasi menggunakan *mapminmax*. Selain itu, keluaran yang bersifat simetris terhadap nol membantu meningkatkan stabilitas proses pelatihan, mempercepat konvergensi, serta memudahkan jaringan dalam mempelajari hubungan nonlinier antarvariabel. Evaluasi performa model didasarkan pada fungsi galat *mean squared*

error (MSE), sedangkan pembaruan bobotnya diatur oleh algoritma *Levenberg-Marquardt*. Selama proses pelatihan, Bayesian Regularization menambahkan penalti terhadap besar bobot untuk mengurangi kompleksitas model dan meningkatkan kemampuan generalisasi terhadap data baru.


Model dengan performa terbaik kemudian diekspor dalam bentuk fungsi MATLAB untuk keperluan implementasi lebih lanjut. Pemilihan model dilakukan berdasarkan nilai MSE yang rendah, koefisien korelasi (R) yang tinggi, serta konsistensi performa pada data *training*, *testing*, dan *additional test*. Pendekatan ini menghasilkan representasi hubungan nonlinier yang lebih baik dibandingkan model linier, sehingga mampu meningkatkan akurasi prediksi parameter tekanan darah, kadar gula darah, dan kolesterol berdasarkan fitur masukan berupa detak jantung inframerah dan usia.

Model yang dihasilkan berupa empat persamaan nonlinear yang menjadi acuan untuk mengonversi nilai keluaran sensor menjadi nilai parameter kesehatan terukur, yaitu:

1. Persamaan nonlinier untuk tekanan darah sistolik.
2. Persamaan nonlinier untuk tekanan darah diastolik.
3. Persamaan nonlinier untuk kolestrol.
4. Persamaan nonlinier untuk gula darah.

Selanjutnya, keempat persamaan tersebut diimplementasikan pada mikrokontroler untuk mengonversi data keluaran sensor menjadi nilai parameter kesehatan yang sesungguhnya.

3.6.2 Perancangan metode regresi logistik



Gambar 3.10 Proses Regresi Logistik

Proses klasifikasi menggunakan metode Regresi Logistik yang digunakan untuk memprediksi risiko stroke berdasarkan 10 parameter masukan. Perancangan ini menggambarkan urutan proses yang akan diimplementasikan dalam program, mulai dari tahap persiapan data hingga menghasilkan prediksi dan evaluasi model. Proses diawali dengan mengimpor library yang diperlukan, yaitu *pandas*, *numpy*, *scikit-learn* (*sklearn*), *matplotlib*, dan *seaborn*. Selanjutnya, dataset *dataolah_reglogistik.xlsx* dimuat ke dalam sistem sebagai data penelitian. Setelah data berhasil dibaca, dilakukan tahap persiapan data dengan memisahkan variabel masukan (X) yang terdiri atas 10 fitur dan variabel target (y) berupa status stroke. Data kemudian dibagi menjadi data latih sebesar 75% dan data uji sebesar 25% menggunakan metode train-test split.


Tahap berikutnya pada perancangan adalah inisialisasi model Regresi Logistik dan proses pelatihan (*fitting*) menggunakan data latih. Pada proses ini, sistem mengestimasi nilai koefisien (β) dan intersep (β₀) yang membentuk persamaan

regresi logistik. Nilai hasil persamaan tersebut kemudian diproses menggunakan fungsi sigmoid untuk menghasilkan probabilitas seseorang mengalami stroke.

Berdasarkan probabilitas yang diperoleh, sistem melakukan proses klasifikasi menggunakan nilai ambang (*threshold*) sebesar 0,5. Apabila probabilitas lebih besar atau sama dengan 0,5 maka sistem memberikan prediksi Stroke (Positif), sedangkan apabila probabilitas kurang dari 0,5 maka sistem memberikan prediksi Tidak Stroke (Negatif).

Sebagai tahap akhir, hasil prediksi dievaluasi menggunakan metrik akurasi (*accuracy*), presisi (*precision*), recall, F1-score, dan *classification report* untuk mengetahui performa model. Selain itu, hasil evaluasi divisualisasikan menggunakan diagram batang akurasi dan *confusion matrix*, serta ditampilkan nilai koefisien masing-masing variabel dan intersep untuk mengetahui kontribusi setiap fitur terhadap hasil prediksi. Dengan demikian, flowchart ini menjadi acuan dalam implementasi algoritma Regresi Logistik pada sistem prediksi risiko stroke yang dikembangkan.

Pada proyek akhir ini menerapkan metode regresi logistik untuk menentukan hasil dari pengambilan data. Regresi logistik ini dilakukan setelah mendapatkan hasil nilai setiap percobaan dari pengambilan data sensor, data pribadi, dan pengisian kuesioner gejala stroke. Kaitannya dengan pengembangan ini, karena alat ini membutuhkan pengolahan data dari setiap prosedur yang sudah dilakukan, agar mengetahui kemungkinan subjek yang mendapatkan Stroke tinggi, dengan pengaruhnya terhadap hasil pengukuran tekanan darah, kolestrol dan gula darah dari hasil pengujian sensor alat.



Gambar 3.11 Model Regresi Logistik

Pada awal proses, naracoba melakukan *scan* di sesor pada ujung jari pada sensor kemudian nilai dari sensor di olah data untuk mendapatkan value tekanan darah, kolestrol dan gula darah. Selanjutnya, naracoba diminta untuk mengisi kuesioner data pribadi dan melakukan beberapa hal sesuai dengan skala RACE. Pada proses, data tekanan darah, kolestrol, gula darah dan skor skala Race dimasukkan ke dalam model regresi logistik. Model regresi logistik adalah model statistik yang digunakan untuk memprediksi probabilitas terjadinya suatu peristiwa. Dalam hal ini, model regresi logistik digunakan untuk memprediksi probabilitas terjadinya Stroke.


3.6.3 Pengujian Alat

Pada tahap ini, dilakukan pengujian alat untuk memeriksa prediksi gula darah, kolestrol, tekanan darah sistolik dan diastolik yang dihasilkan oleh model *multi-layer perceptron*, dengan menggunakan data input yang diperoleh dari pembacaan sensor. Kesimpulan terkait kondisi terhadap kemungkinan stroke kemudian ditentukan dari model yang diperoleh dari regresi logistik. Pengujian dilakukan pada beberapa naracoba dengan kondisi punya riwayat stroke dan tidak pada pria dan wanita berusia dengan rentan 20 - 70 tahun. Data yang diperoleh kemudian dicatat dan dihitung persentase error-nya untuk mengetahui akurasi yang dihasilkan oleh alat.

3.7 PERANCANGAN *PERANGKAT LUNAK*

3.7.1 Tampilan Aplikasi


Aplikasi yang digunakan dalam sistem ini yaitu dengan menggunakan Aplikasi *Smart Phone*. Aplikasi yang dirancang berfungsi untuk menampilkan hasil value dari pengukuran tekanan darah, kolesterol, dan gula darah, serta prediksi risiko stroke dalam bentuk status (iya/tidak) yang telah diklasifikasi dengan menggunakan regresi logistik. Desain tampilan Aplikasi yang dirancang sebagai berikut.



Gambar 3.12 Desain Tampilan Aplikasi (a) *Page Login* (b) *Page Regist*

Halaman login dan registrasi berfungsi sebagai gerbang awal sebelum pengguna dapat mengakses aplikasi. Pada halaman login, pengguna yang sudah

memiliki akun dapat masuk ke sistem, sedangkan halaman registrasi digunakan untuk membuat akun baru. Kedua halaman ini memastikan bahwa setiap data dan fitur aplikasi hanya dapat diakses oleh pengguna yang terverifikasi.



Gambar 3.13 Page Home Utama

Halaman *Health Data* ini menampilkan informasi kesehatan pengguna dalam bentuk yang sederhana dan mudah dibaca. Di bagian paling atas terdapat bagian *Early Stroke Risk* pada halaman ini berfungsi untuk menunjukkan apakah pengguna berpotensi mengalami risiko stroke dini berdasarkan data kesehatan yang sudah dimasukkan sebelumnya. Di bagian ini ada dua tombol: *YES* dan *NO* serta diberi keterangan nilai persentase kemungkinan.


- Jika sistem menampilkan *YES*, artinya data terbaru seperti tekanan darah, kolesterol, dan gula darah menunjukkan pola yang mengarah pada kemungkinan risiko stroke.
- Jika yang muncul *NO*, berarti tidak ada tanda-tanda yang mengarah pada risiko tersebut berdasarkan data yang tersedia.

Bagian ini dibuat agar pengguna bisa langsung mengetahui kondisi mereka tanpa harus menganalisis angka-angka sendiri. Jadi cukup melihat indikator ini untuk memahami apakah perlu waspada atau tidak. Ini semacam ringkasan cepat dari hasil analisis sistem terhadap data kesehatan pengguna. Tombol ini menunjukkan apakah sistem mendeteksi adanya potensi risiko stroke berdasarkan data kesehatan terbaru yang dimasukkan pengguna.

Di bawahnya ada bagian *Latest Data*, yang menampilkan tiga parameter penting:

- *Blood Pressure* (tekanan darah), misalnya 120/80 mmHg
- *Cholesterol*, misalnya 180 mg/dL
- *Blood Glucose*, misalnya 90 mg/dL

Bagian ini berfungsi sebagai ringkasan cepat agar pengguna langsung bisa melihat kondisi kesehatan terakhir. Selanjutnya terdapat daftar riwayat data kesehatan harian. Setiap kartu data menampilkan tanggal dan tiga nilai utama: tekanan darah, kolesterol, dan gula darah. Secara keseluruhan, halaman ini dirancang untuk memudahkan pengguna memantau kondisi kesehatan mereka dari waktu ke waktu. Tampilan dibuat sederhana, informatif, dan langsung ke poin, sehingga pengguna bisa cepat memahami apakah ada perubahan yang perlu diperhatikan.




Gambar 3.14 *Page Profile*

Halaman profil menampilkan data pribadi pengguna yang sebelumnya diisi saat registrasi. Pada halaman ini juga terdapat ID pengguna yang menjadi identitas unik. ID tersebut digunakan sebagai penghubung antara aplikasi dan perangkat *hardware*, sehingga data yang dikirim dari alat dapat masuk ke database sesuai dengan akun pengguna yang benar.

3.7.2 Blok Diagram Basis Data Sistem

Berdasarkan blok diagram arsitektur sistem, proses kerja dimulai dari tahap akuisisi data yang dilakukan oleh mikrokontroler ESP32. Perangkat ini berfungsi untuk mengukur gula darah, kolesterol, tekanan darah sistolik dan diastolik, kemudian menyimpan hasil pengukuran tersebut ke dalam memori *Flash internal*. Selanjutnya, data yang telah tersimpan dikirimkan melalui koneksi Wi-Fi menuju firebase *realtime* database sebagai media penyimpanan berbasis *cloud*. Platform ini memungkinkan data disimpan dan diperbarui secara *real-time* sehingga dapat diakses kapan saja.

Data yang berada pada Firebase kemudian diambil oleh sistem berbasis aplikasi yang berperan sebagai antarmuka pengguna. Pada aplikasi tersebut, informasi data ditampilkan dalam bentuk tabel histori yang memberikan informasi rinci dari setiap hasil pengukuran secara berurutan, untuk pengecekan analisis persentase kemungkinan stroke pada tiap data terakhir pengukuran dari waktu ke waktu.



Gambar 3.15 Blok Diagram Database Sistem

Dengan alur tersebut, sistem mampu bekerja secara terintegrasi mulai dari proses pengambilan data oleh perangkat, pengiriman dan penyimpanan di *cloud*, hingga penyajian informasi yang informatif dan mudah dipahami oleh pengguna.

3.8 PEMBUATAN APLIKASI

Tahapan selanjutnya adalah pengembangan aplikasi mobile. Aplikasi ini dibangun menggunakan *framework Flutter* dengan bahasa pemrograman Dart. Proses pengembangan dilakukan dengan mengacu pada desain *mockup* yang telah dirancang sebelumnya, sehingga tampilan antarmuka dan pengalaman pengguna sesuai dengan kebutuhan sistem. Integrasi dengan firebase *realtime* database juga diterapkan untuk mendukung proses pengolahan dan penyimpanan data secara *real-time*. Seluruh struktur data dan alur komunikasi aplikasi disesuaikan dengan perancangan basis data yang telah ditentukan, sehingga aplikasi dapat berjalan dengan optimal dan menghasilkan output yang sesuai dengan tujuan sistem.

3.9 INTEGRASI SISTEM

Integrasi sistem dilakukan dengan menyatukan komponen perangkat keras dan perangkat lunak agar dapat bekerja secara terpadu. Data hasil pengukuran yang meliputi kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik yang telah diolah oleh mikrokontroler ESP32 kemudian dikirimkan ke firebase *realtime* database melalui koneksi WiFi. Data yang tersimpan pada basis data tersebut

selanjutnya diakses dan ditampilkan melalui halaman aplikasi mobile sebagai antarmuka pengguna. Informasi dari hasil pengukuran terbaru kemudian digunakan untuk menganalisis dan menampilkan persentase kemungkinan risiko terjadinya stroke.

3.10 PENGUJIAN SISTEM KESELURUHAN

Pengujian sistem secara keseluruhan dilakukan dengan melibatkan aspek perangkat keras dan perangkat lunak yang telah terintegrasi. Tujuan dari pengujian ini adalah untuk memastikan bahwa seluruh komponen sistem, mulai dari proses akuisisi, pengiriman, hingga visualisasi data, dapat berfungsi dengan baik tanpa adanya kesalahan. Pengujian dilakukan dengan membandingkan data hasil pengukuran kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik, serta hasil analisis kondisi kesehatan yang diproses oleh mikrokontroler ESP32 dengan data yang tersimpan pada firebase *realtime* database dan yang ditampilkan pada aplikasi. Selain itu, hasil pengukuran terbaru juga diperiksa kesesuaiannya dengan nilai persentase risiko stroke yang dihasilkan oleh sistem. Apabila seluruh data yang ditampilkan pada perangkat keras, basis data, serta antarmuka pengguna menunjukkan kesamaan, maka dapat disimpulkan bahwa sistem telah bekerja secara optimal dan sesuai dengan perancangan.

BAB 4

EKSPERIMEN DAN ANALISIS

4.1 PENGUJIAN SENSOR MAX30105

1. Tujuan

Tujuan utama dari pengujian sensor MAX30105 adalah untuk menilai kemampuan sensor dalam menangkap dan mengolah sinyal inframerah yang digunakan untuk mendeteksi aktivitas biologis, khususnya detak jantung manusia. Pengujian ini dilakukan untuk memastikan bahwa sensor dapat bekerja secara konsisten, stabil, dan memberikan hasil pembacaan yang tepat ketika digunakan dalam kondisi pemakaian yang beragam. Selain itu, proses pengujian juga bertujuan untuk menilai tingkat keakuratan sensor dengan cara membandingkan data yang dihasilkan oleh MAX30105 dengan data yang diambil menggunakan alat medis standar. Melalui perbandingan tersebut, dapat diketahui sejauh mana keandalan sensor dalam aplikasi nyata serta apakah sensor layak digunakan sebagai komponen utama dalam sistem pendeteksian yang dirancang.

2. Metode Pengujian

Pengujian ini menggunakan metode komparatif, yaitu dengan melakukan perbandingan langsung antara data yang dihasilkan oleh sensor MAX30105 dan data dari alat medis standar, dalam hal ini tensimeter digital OMRON. Prosedur pengujian dilakukan sebanyak 22 kali pada beberapa subjek dengan rentang usia 20 hingga 70 tahun. Seluruh peserta diuji dalam kondisi fisik yang stabil, tenang, dan tidak sedang melakukan aktivitas berat.

Pengujian dilaksanakan di dalam ruangan tertutup dengan pencahayaan yang konsisten untuk memastikan bahwa sensor MAX30105 tidak terpengaruh oleh perubahan intensitas cahaya yang dapat mengganggu pemrosesan sinyal *inframerah*. Dengan pengaturan kondisi lingkungan yang terkontrol tersebut, hasil perbandingan antara pembacaan sensor dan alat medis standar diharapkan dapat memberikan gambaran yang lebih akurat mengenai kemampuan sensor dalam mengukur detak jantung secara tepat dan dapat diandalkan.

3. Karakteristik Data

Data yang digunakan berupa sinyal *inframerah* (IR) dan detak jantung (HR) dari sensor MAX30105, diambil melalui metode PPG dengan merekam perubahan volume darah di ujung jari. Heart Rate (HR) diperoleh menggunakan sensor MAX30105 yang bekerja berdasarkan prinsip Photoplethysmography (PPG), yaitu dengan memancarkan cahaya inframerah (IR) ke jaringan jari dan mendeteksi perubahan intensitas cahaya yang dipantulkan akibat perubahan volume darah pada setiap denyut jantung. Selama proses pengukuran, pengguna diminta meletakkan jari pada sensor dalam posisi stabil selama 30 detik. Mikrokontroler ESP32 membaca

sinyal IR secara kontinu dan mendeteksi setiap puncak gelombang PPG sebagai satu denyut jantung, kemudian menghitung nilai Beats Per Minute (BPM) berdasarkan selang waktu antar denyut (*Inter Beat Interval/IBI*).

$$HR = \frac{60}{IBI}$$

Keterangan:

HR = Heart Rate (BPM)

IBI = Waktu antar denyut jantung (detik)

Oleh karena itu, seluruh nilai BPM yang valid selama 30 detik disimpan dan dihitung nilai rata-ratanya (*average BPM*), sehingga diperoleh nilai Heart Rate yang lebih stabil, representatif, dan memiliki tingkat keandalan yang lebih baik dibandingkan menggunakan satu kali hasil pembacaan.

$$HR_{avg} = \frac{\sum_{i=1}^n HR_i}{n}$$

Keterangan:

H_{avg} = nilai rata rata Heart Rate

H_{Ri} = nilai BPM hasil deteksi denyut ke-i

n = jumlah nilai BPM yang berhasil diperoleh selama waktu pengukuran

4. Tempat Ujicoba

Pengujian dilakukan di lingkungan kampus Politeknik Elektronika Negeri Surabaya (PENS)

5. Waktu Ujicoba

Ujicoba dilakukan pada tanggal 03-05 Desember 2025

6. Setting Pengujian

Alat dan Bahan yang diperlukan:

- a) *Prototype hardware*
- b) Tensimeter Digital OMRON
- c) Laptop

7. Prosedur Pengujian

Pada pengujian sensor MAX30105 dilakukan dengan prosedur sebagai berikut:

- a) Menghubungkan rangkaian *prototype* ke laptop melalui kabel USB untuk memastikan perangkat memperoleh suplai daya dan dapat berkomunikasi dengan komputer.




Gambar 4.1 Setup Pengujian

- b) Membuka dan menjalankan program pembacaan sensor pada Arduino IDE, sehingga data sinyal inframerah dan estimasi detak jantung dapat muncul secara *real-time* di serial monitor.
- c) Memastikan jari telunjuk subjek berada dalam kondisi bersih dan kering, untuk menghindari gangguan sinyal akibat minyak, debu, atau kelembapan pada permukaan kulit.
- d) Meletakkan jari telunjuk secara perlahan di atas sensor dengan posisi stabil tanpa banyak pergerakan. Subjek diminta tetap tenang dan tidak berbicara agar pembacaan sensor lebih konsisten.



Gambar 4.2 Posisi Jari Pada Sensor


- e) Melakukan pengukuran dalam posisi duduk, dengan tangan diletakkan di atas meja pada posisi *relaks* dan sejajar dengan dada untuk menjaga kestabilan selama proses pengambilan data.
- f) Pengambilan data dilakukan dalam waktu 30 detik
- g) Mencatat nilai sinyal inframerah dan hasil estimasi detak jantung yang ditampilkan melalui serial monitor Arduino IDE sebagai data pembacaan sensor MAX30105.
- h) Melakukan pengukuran detak jantung menggunakan tensimeter digital sesuai dengan petunjuk pemakaian perangkat medis tersebut. Pengukuran dilakukan secara bersamaan.



Gambar 4.3 Pengujian Dengan Tensi Digital

- i) Mencatat hasil detak jantung dari tensimeter digital dan membandingkannya dengan data yang diperoleh dari sensor MAX30105 untuk kebutuhan analisis akurasi.


8. Hasil dan Analisa



Gambar 4.4 Pembacaan heart rate (HR) sensor Dan Tensimeter

Dari hasil perbandingan data pada lima belas subjek uji, diperoleh bahwa sensor MAX30105 mampu membaca detak jantung dengan tingkat akurasi sebesar 99,126%. Angka ini diperoleh dari rata-rata selisih antara hasil pembacaan sensor dengan hasil dari tensimeter digital sebagai alat acuan. Dengan akurasi tersebut, dapat disimpulkan bahwa sensor MAX30105 bekerja cukup baik dan mampu memberikan data yang mendekati alat medis standar.

Selama proses pengujian, tidak ditemukan hasil yang menyimpang jauh yang dapat memengaruhi penilaian. Pembacaan sensor juga terlihat stabil dari satu pengukuran ke pengukuran lainnya. Hal ini menunjukkan bahwa sensor MAX30105 dapat digunakan dengan cukup andal dalam proyek akhir ini.



Gambar 4.5 Grafik Perbandingan Pengukuran HR

Tabel 4.1 Hasil Pengujian Sensor MAX30105

NO	UMUR	SENSOR		HR REFERENSI	%ERROR
		IR	HR (bpm)		
1	21	101030	60	61	1,639344262
2	21	108011	83	83	0
3	20	96660	67	66	1,515151515
4	20	99097	66	65	1,538461538
5	20	101956	61	61	0
6	20	98603	86	86	0
7	54	112313	87	86	1,162790698
8	22	96257	72	71	1,408450704
9	22	85310	75	75	0
10	22	93150	86	85	1,176470588
11	22	92844	86	85	1,176470588
12	23	73147	69	68	1,470588235
13	23	93453	98	98	0
14	22	124771	72	72	0
15	22	110967	104	102	1,960784314
16	22	112287	107	106	0,943396226
17	22	124365	94	93	1,075268817
18	22	8866	83	84	1,19047619
19	22	105529	86	86	0
20	49	78140	66	66	0
21	57	77473	96	95	1,052631579
22	49	82401	111	109	1,834862385
RATA- RATA ERROR (%)					0,870233984
AKURASI (%)					99,12976602

Pada tabel diatas menunjukkan hasil pengujian sensor MAX30105 dalam pengukuran denyut jantung (HR) yang dibandingkan dengan alat referensi berupa tensimeter. Pengujian dilakukan pada beberapa responden dengan rentang umur yang berbeda. Hasil pengukuran HR dari sensor MAX30105 memiliki nilai yang relatif mendekati hasil HR tensi, dengan persentase error yang kecil pada setiap pengujian. Rata-rata error yang diperoleh sebesar 0,87%, sehingga tingkat akurasi sensor mencapai 99,13%. Hal ini menunjukkan bahwa sensor MAX30105 memiliki kinerja yang baik dan cukup akurat dalam mengukur denyut jantung, sehingga layak digunakan sebagai perangkat monitoring denyut jantung.

4.2 PENGUMPULAN DATA TRAINING

1. Tujuan

Tujuan dari proses pengumpulan data training adalah mendapatkan data pelatihan model *multi-layer perceptron*, khususnya data inframerah, detak jantung dari sensor MAX30105 serta data gula darah, kolesterol, tekanan darah sistolik dan diastolik sebagai target pada pengolahan *multi-layer perceptron*.

2. Metode Pengumpulan

Metode pengumpulan data training dilakukan pengukuran langsung terhadap naracoba dengan rentang usia 20 – 70 tahun. Pengambilan data dilakukan secara bergantian antara data input (sensor MAX30105 dan usia) serta data target (alat Elvasense 3in1). Semua pengukuran dilakukan dalam kondisi fisik naracoba yang tenang untuk meminimalkan noise pada hasil data.

3. Tempat Pengumpulan

Pengumpulan data dilakukan di lingkungan rumah penulis (Kadipaten, Babadan, Ponorogo, Jawa Timur)

4. Waktu Pengumpulan

Pengumpulan data dilakukan pada tanggal 02-23 Januari 2026

5. Setting Pengumpulan

Alat dan bahan yang diperlukan:

- a) *Prototype hardware*
- b) Elvasense 3in1
- c) Tensimeter digital
- d) Strip gula darah dan kolesterol
- e) Laptop

6. Prosedur Pengumpulan

Proses pengumpulan data sampel dilakukan dengan prosedur sebagai berikut:

- a) Meminta naracoba duduk dalam posisi *rileks*
- b) Memastikan kondisi ujung jari pasien bersih dan kering, untuk menghindari gangguan pembacaan akibat debu.
- c) Meletakkan ujung jari di atas sensor MAX30105 untuk merekam data inframerah dan detak jantung selama 30 detik.
- d) Mencatat usia sebagai salah satu input model
- e) Mengambil sampel darah menggunakan Elvasense 3in1 untuk memperoleh gula darah dan kolesterol
- f) Mengambil nilai tekanan darah sistolik dan diastolik menggunakan tensimeter digital
- g) Mencatat data dan menyimpan dalam format data sampel untuk proses pelatihan model *multi-layer perceptron*.

7. Hasil Pengumpulan

Penulis berhasil mengumpulkan data training sebagai berikut: 41 data gula darah, 45 data kolesterol, 40 data tekanan darah sistolik dan 36 data tekanan darah diastolik. Masing- masing data tersebut mencakup tiga fitur input: inframerah, detak jantung, dan usia. Data yang berhasil dikumpulkan nantinya akan digunakan untuk pelatihan model menggunakan algoritma *bayesian regularization backpropagation* melalui aplikasi MATLAB.

Tabel 4.2 Data Training Model Gula Darah

Catatan: Data lengkap tersaji pada Lampiran

NO	IR	USIA (tahun)	Detak Jantung	Gula Darah
1	99163	22	79	124
2	106829	28	77	119
3	89149	25	83	135
4	91945	21	102	146
5	94921	66	88	134
6	111360	52	83	120
7	118148	28	85	124
8	85908	58	75	120
9	83614	25	71	87
10	103494	50	83	124

Tabel 4.3 Data Training Model Kolestrol

Catatan: Data lengkap tersaji pada Lampiran

NO	IR	USIA (tahun)	Detak Jantung	Kolestrol
1	99163	22	79	166
2	106829	28	77	164
3	89149	25	83	206
4	94921	66	88	184
5	111360	52	83	192
6	118148	28	85	188
7	83614	25	71	162
8	103494	50	83	188
9	97649	28	87	206
10	82800	58	73	169

Tabel 4.4 Data Training Model Tekanan Darah Sistolik
Catatan: Data lengkap tersaji pada Lampiran

NO	IR	USIA (tahun)	Detak Jantung	Tekanan Darah Sistolik
1	99163	22	79	118
2	106829	28	77	111
3	89149	25	83	129
4	91945	21	102	134
5	111360	52	83	121
6	118148	28	85	121
7	85908	58	75	136
8	83614	25	71	111
9	97649	28	87	125
10	82800	58	73	138

Tabel 4.5 Data Training Model Tekanan Darah Diastolik
Catatan: Data lengkap tersaji pada Lampiran

NO	IR	USIA (tahun)	Detak Jantung	Tekanan Darah Diastolik
1	99163	22	79	80
2	106829	28	77	79
3	89149	25	83	82
4	91945	21	102	84
5	94921	66	88	87
6	111360	52	83	83
7	118148	28	85	80
8	85908	58	75	85
9	83614	25	71	80
10	103494	50	83	94

4.3 PENCARIAN MODEL *MULTI-LAYER PERCEPTRON*


1. Tujuan

Tujuan dari proses ini adalah untuk memperoleh nilai bobot, bias, serta konfigurasi *neuron hidden layer* yang paling optimal. Parameter tersebut selanjutnya akan digunakan dalam persamaan arsitektur model *multi-layer perceptron* untuk melakukan prediksi terhadap kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik secara akurat.

2. Metode Pencarian

Penentuan model terbaik dilakukan dengan membandingkan beberapa arsitektur jaringan saraf yang memiliki variasi jumlah *neuron hidden layer* yang berbeda pada jumlah lapisan tersembunyi. Proses pelatihan menggunakan metode *supervised learning* dengan algoritma *Bayesian Regularization Backpropagation*. Sebelum pelatihan, data input dinormalisasi ke dalam rentang -1 hingga 1, dan setiap lapisan menerapkan fungsi aktivasi *tanh* untuk menangani hubungan yang bersifat nonlinier. Evaluasi model dilakukan menggunakan parameter *mean squared error* (MSE), dengan mekanisme pembaruan bobot dan bias yang mengikuti pendekatan *Levenberg-Marquardt*. Pembaruan parameter diterima apabila terjadi peningkatan nilai gradien, sementara nilai lambda akan disesuaikan secara adaptif untuk menjaga kestabilan proses pelatihan sekaligus mempercepat konvergensi.

Proses pelatihan dihentikan apabila salah satu dari tiga kondisi terpenuhi, yaitu nilai gradien telah mencapai batas minimum, nilai lambda menjadi terlalu besar, atau jumlah epoch maksimum telah tercapai. Dari beberapa konfigurasi yang diuji, model dengan nilai koefisien korelasi tertinggi dipilih sebagai model terbaik untuk memprediksi kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik berdasarkan input berupa detak jantung, inframerah dan usia.



Gambar 4.6 Alur Pencarian Model

Proses pencarian model terbaik menggunakan metode *Multilayer Perceptron* dengan algoritma *Bayesian Regularization*. Proses dimulai dari input dataset, kemudian dilakukan *preprocessing* untuk menangani *missing value* dan *outlier*. Setelah itu data dinormalisasi menggunakan metode *mapminmax* agar seluruh variabel berada pada rentang yang seragam. Data kemudian dibagi menjadi data training, validation, testing, dan additional test. Selanjutnya dilakukan inisialisasi jumlah hidden neuron dimulai dari 1 neuron, kemudian model MLP dilatih menggunakan *Bayesian Regularization*. Setelah proses training selesai, performa model dievaluasi menggunakan nilai *Mean Squared Error* (MSE) dan koefisien korelasi R. Hasil evaluasi setiap model disimpan, lalu jumlah *hidden neuron* ditambah dan proses training diulang hingga seluruh konfigurasi neuron selesai diuji. Setelah semua model dibandingkan berdasarkan nilai MSE minimum dan nilai R maksimum, dipilih model dengan performa paling optimal untuk digunakan dalam prediksi parameter kesehatan sebagai output akhir.

3. Setting Pencarian

Alat dan bahan yang diperlukan:

- a) *Software* MATLAB
- b) Laptop

4. Prosedur Pencarian


Proses penentuan nilai bobot dan bias yang optimal dilakukan melalui beberapa tahapan sebagai berikut:

- a) Upload data training terlebih dahulu ke dalam *workspace* MATLAB. Data tersebut terdiri dari data input dan data target, di mana data input meliputi tiga parameter yaitu inframerah, usia dan detak jantung, sedangkan data target berupa salah satu parameter keluaran, yaitu kadar gula darah, kolesterol, tekanan darah sistolik ataupun tekanan darah diastolik.
- b) Selanjutnya, *Neural Network Toolbox* pada MATLAB dibuka untuk melakukan perancangan model, termasuk pengaturan jumlah *neuron* pada *hidden layer* sesuai dengan kebutuhan pengujian.
- c) Proses pelatihan kemudian dijalankan menggunakan algoritma *Bayesian Regularization Backpropagation* hingga diperoleh nilai bobot dan bias yang paling optimal.
- d) Rekap nilai bobot dan bias hasil pelatihan untuk masing-masing parameter *output*, yaitu gula darah, kolesterol, tekanan darah sistolik dan tekanan darah diastolik, pada setiap variasi konfigurasi *neuron hidden layer*.
- e) Tahap berikutnya adalah mengevaluasi performa model berdasarkan nilai koefisien korelasi pada setiap konfigurasi. Konfigurasi dengan nilai korelasi tertinggi dipilih sebagai model terbaik untuk digunakan dalam proses prediksi.

5. Hasil Pencarian

Berdasarkan hasil pengamatan yang telah dilakukan, diketahui bahwa konfigurasi model *multi-layer perceptron* pada setiap data dengan parameter yang berbeda memberikan nilai korelasi R yang berbeda dengan *neuron hidden layer* yang berbeda beda pada tiap parameter.

Berdasarkan hasil pencarian model untuk parameter gula darah, diperoleh bahwa konfigurasi dengan 3 *neuron hidden layer* menghasilkan nilai koefisien korelasi (R) tertinggi dibandingkan konfigurasi lainnya, dengan pertimbangan hasil *mean squared error* (MSE) serta keseimbangan antara hasil *training* dan *testing*. Nilai korelasi yang diperoleh untuk konfigurasi ini adalah sebesar 0.74713, yang sedikit lebih tinggi dibandingkan dengan konfigurasi 5 *neuron hidden layer* sebesar 0.74615. Sementara itu, konfigurasi dengan 10 *neuron hidden layer* memberikan nilai korelasi sebesar 0.74616. Oleh karena itu, konfigurasi dengan nilai korelasi tertinggi dipilih sebagai model terbaik dalam memprediksi kadar gula darah.




Gambar 4.7 Varian Performa Korelasi Model Gula Darah

(a) 10 *Neuron Hidden Layer* (0.74616)

(b) 5 *Neuron Hidden Layer* (0.74615)

(c) 3 *Neuron Hidden Layer* (0.74713)

Berdasarkan hasil pengujian, model dengan 12 *neuron hidden layer* menghasilkan nilai korelasi tertinggi sebesar 0.8338 dibandingkan 8 *neuron hidden layer* (0.7971) dan 10 *neuron hidden layer* (0.7456). Oleh karena itu, konfigurasi 12 *neuron hidden layer* dipilih sebagai model terbaik untuk prediksi kolesterol.




Gambar 4.8 Varian Performa Korelasi Model Kolestrol

(a) 12 *Neuron Hidden Layer* (0.8338)


(b) 10 *Neuron Hidden Layer* (0.7456)

(c) 8 *Neuron Hidden Layer* (0.7971)


Hasil pengujian, model dengan 3 *neuron hidden layer* menghasilkan nilai korelasi tertinggi sebesar 0.65772 dibandingkan 12 *neuron hidden layer* (0.65738) dan 5 *neuron hidden layer* (0.65328). Oleh karena itu, konfigurasi 3 *neuron hidden layer* dipilih sebagai model terbaik untuk prediksi tekanan darah sistolik.



(a)



(b)



(c)


Gambar 4.9 Varian Performa Korelasi Model Tekanan Darah Sistolik

(a) 12 *Neuron Hidden Layer* (0.65738)

(b) 7 *Neuron Hidden Layer* (0.65328)

(c) 3 *Neuron Hidden layer* (0.65772)

Pada parameter tekanan darah diastolik, di mana konfigurasi 9 *neuron hidden layer* memberikan nilai kolerasi R sebesar 0.81427, naik menjadi 0.8155 pada 5 *neuron hidden layer*, dan kembali menunjukkan penurunan pada konfigurasi 3 *neuron hidden layer* dengan nilai kolerasi R sebesar 0.8142. Konfigurasi 5 *neuron hidden layer* dipilih sebagai model terbaik untuk prediksi tekanan darah sistolik.



Gambar 4. 10 Varian Performa Korelasi Model Tekanan Darah Diastolik

(a) 9 Neuron Hidden Layer (0.81427)

(b) 5 Neuron Hidden Layer (0.8155)

(c) 3 Neuron Hidden layer (0.8142)

Dalam evaluasi performa Artificial Neural Network, parameter epoch, Mean Squared Error (MSE), dan koefisien korelasi R digunakan untuk menilai kualitas proses pelatihan serta kemampuan generalisasi model terhadap data baru. Model yang baik umumnya memiliki nilai MSE yang kecil baik pada data training maupun testing, serta selisih keduanya tidak terlalu jauh sehingga menunjukkan model stabil dan tidak mengalami overfitting. Koefisien korelasi R diharapkan mendekati 1 karena menunjukkan hubungan yang kuat antara hasil prediksi dan target sebenarnya, dengan nilai R testing yang tetap tinggi dan tidak berbeda jauh dari training. Selain itu, nilai gradient yang semakin kecil menandakan proses optimasi telah mendekati titik konvergensi sehingga perubahan bobot menjadi semakin stabil.

Parameter jumlah epoch pada algoritma Levenberg–Marquardt digunakan untuk menunjukkan banyaknya iterasi pelatihan, di mana model yang optimal umumnya mampu mencapai performa terbaik sebelum mencapai batas maksimum epoch. Dengan demikian, konfigurasi jaringan yang dipilih adalah model yang

mampu menghasilkan nilai MSE rendah, nilai R tinggi, proses konvergensi stabil, serta performa testing yang konsisten sehingga memiliki kemampuan generalisasi yang baik terhadap data baru.

Pada proses pencarian model Multi-Layer Perceptron, telah dilakukan serangkaian percobaan dengan variasi jumlah neuron hidden layer dari 1 hingga 12 neuron. Seluruh hasil pengujian dan performa masing-masing konfigurasi dilampirkan pada bagian lampiran penelitian. Dari hasil percobaan tersebut kemudian dipilih tiga konfigurasi terbaik untuk masing-masing parameter, yaitu gula darah, kolesterol, tekanan darah sistolik, dan tekanan darah diastolik. Pemilihan model terbaik dilakukan dengan membandingkan kestabilan nilai MSE training dan testing, nilai koefisien korelasi R, serta kemampuan konvergensi model pada setiap konfigurasi neuron hidden layer. Konfigurasi yang memiliki nilai MSE paling kecil, nilai R paling mendekati 1, serta selisih performa training dan testing yang stabil dipilih sebagai model terbaik karena dianggap memiliki kemampuan generalisasi yang lebih baik terhadap data baru.

4.4 PENGUJIAN NILAI GULA DARAH, KOLESTROL, TEKANAN DARAH SISTOLIK DAN DIASTOLIK

1. Tujuan

Tujuan dari pengujian ini adalah untuk mengevaluasi tingkat akurasi model persamaan nonlinear dalam mengestimasi nilai gula darah, kolesterol, tekanan darah sistolik dan diastolik. Estimasi tersebut diperoleh dari data sensor MAX30105, kemudian dibandingkan dengan hasil pengukuran metode invasif sebagai acuan, sehingga dapat diketahui sejauh mana keandalan sistem dalam merepresentasikan kondisi sebenarnya.

2. Metode Pengujian

Metode pengujian pada penelitian ini dilakukan dengan cara membandingkan hasil prediksi kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik yang diperoleh dari model terbaik dengan hasil pengukuran menggunakan alat invasif Elvasense 3in1 dan tensimeter digital sebagai acuan. Proses pengujian dilaksanakan di dalam ruangan dengan melibatkan 50 responden yang memiliki rentang usia antara 20 hingga 70 tahun, sehingga data yang diperoleh cukup merepresentasikan variasi kondisi usia.

Parameter bobot dan bias yang telah melalui proses optimasi kemudian diimplementasikan ke dalam bentuk persamaan non-linear. Persamaan tersebut digunakan untuk menghasilkan prediksi kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik secara lebih akurat berdasarkan data masukan yang diperoleh. Adapun variabel input yang digunakan terdiri dari tiga parameter utama, yaitu nilai sensor inframerah sebagai x_1 , usia pasien sebagai x_2 , dan detak jantung yang juga diperoleh dari sensor inframerah sebagai x_3 . Dengan pendekatan ini, model diharapkan mampu merepresentasikan hubungan kompleks antar variabel input

terhadap kadar biomarker yang diukur. Berikut merupakan empat persamaan non-linear yang digunakan dalam proses prediksi tersebut:

$$Y = (1/\text{gain}) \times (b_2 + a^T \cdot \tanh(W \cdot x + b) + 1) + \text{offset}$$

a) Persamaan nonlinear model gula darah:

$$Y = (1/0.03390) \times (0.3960 + a^T \cdot \tanh(W \cdot x + b) + 1) + 87 \text{ mg/dL}$$

$$W = \begin{bmatrix} -3.427 \times 10^{-4} & -2.945 \times 10^{-4} & 1.079 \times 10^{-4} \\ 3.452 \times 10^{-1} & 1.151 \times 10^{-1} & -9.910 \times 10^{-1} \\ 2.763 \times 10^{-4} & 2.374 \times 10^{-4} & -8.701 \times 10^{-5} \end{bmatrix} \quad b = \begin{bmatrix} 2.528 \times 10^{-4} \\ 1.007 \times 10^{-1} \\ -2.038 \times 10^{-4} \end{bmatrix} \quad a = \begin{bmatrix} -2.362 \times 10^{-3} \\ -8.149 \times 10^{-1} \\ -1.045 \times 10^{-3} \end{bmatrix}$$

b) Persamaan nonlinear model kolesterol:

$$Y = (1/0.02817) \times (0.36485 + a^T \cdot \tanh(W \cdot x + b) + 1) + 151 \text{ mg/dL}$$

$$W = \begin{bmatrix} 9.509 \times 10^{-1} & -4.408 \times 10^{-1} & 1.181 \times 10^{-3} \\ -1.870 \times 10^{-4} & 5.513 \times 10^{-5} & 2.248 \times 10^{-4} \\ 4.378 \times 10^{-1} & 5.208 \times 10^{-1} & 5.283 \times 10^{-1} \\ -2.185 \times 10^{-2} & 3.419 \times 10^{-3} & 5.732 \times 10^{-3} \\ -1.089 \times 10^{-1} & 2.714 \times 10^{-1} & 1.789 \times 10^0 \\ 4.221 \times 10^{-1} & -1.615 \times 10^0 & -8.395 \times 10^{-1} \\ -4.525 \times 10^{-3} & 2.436 \times 10^{-4} & 4.424 \times 10^{-3} \\ 2.075 \times 10^{-1} & 6.127 \times 10^{-1} & -2.031 \times 10^0 \\ -1.216 \times 10^{-3} & -5.984 \times 10^{-4} & 5.739 \times 10^{-4} \\ -6.046 \times 10^{-4} & -4.994 \times 10^{-4} & 5.900 \times 10^{-4} \\ -5.373 \times 10^{-1} & 3.804 \times 10^{-1} & 1.036 \times 10^{-1} \\ -1.478 \times 10^{-4} & -5.485 \times 10^{-5} & 1.059 \times 10^{-4} \end{bmatrix} \quad b = \begin{bmatrix} -5.249 \times 10^{-1} \\ 5.570 \times 10^{-4} \\ -4.385 \times 10^{-1} \\ 4.182 \times 10^{-2} \\ 5.980 \times 10^{-1} \\ 2.642 \times 10^{-1} \\ 1.210 \times 10^{-2} \\ -1.483 \times 10^0 \\ 1.974 \times 10^{-3} \\ 3.104 \times 10^{-3} \\ -4.862 \times 10^{-1} \\ 5.316 \times 10^{-4} \end{bmatrix} \quad a = \begin{bmatrix} -9.593 \times 10^{-1} \\ 6.124 \times 10^{-4} \\ 6.564 \times 10^{-1} \\ 4.510 \times 10^{-2} \\ 1.489 \times 10^0 \\ 1.104 \times 10^0 \\ 1.341 \times 10^{-2} \\ 1.801 \times 10^0 \\ 2.384 \times 10^{-3} \\ 3.228 \times 10^{-3} \\ -6.210 \times 10^{-1} \\ 5.622 \times 10^{-4} \end{bmatrix}$$

c) Persamaan nonlinear model tekanan darah sistolik:

$$Y = (1/0.03390) \times (-0.09215 + a^T \cdot \tanh(W \cdot x + b) + 1) + 106 \text{ mmHg}$$

$$W = \begin{bmatrix} 2.519 \times 10^{-1} & -3.089 \times 10^{-1} & -7.481 \times 10^{-2} \\ -2.356 \times 10^{-1} & 2.941 \times 10^{-1} & 8.410 \times 10^{-2} \\ 2.095 \times 10^{-1} & -2.642 \times 10^{-1} & -8.741 \times 10^{-2} \end{bmatrix} \quad b = \begin{bmatrix} 8.063 \times 10^{-2} \\ -6.744 \times 10^{-2} \\ 5.520 \times 10^{-2} \end{bmatrix} \quad a = \begin{bmatrix} -4.364 \times 10^{-1} \\ 4.025 \times 10^{-1} \\ -3.648 \times 10^{-1} \end{bmatrix}$$

d) Persamaan nonlinear model tekanan darah diastolik:

$$Y = (1/0.125) \times (-0.39449 + a^T \cdot \tanh(W \cdot x + b) + 1) + 78 \text{ mmHg}$$

$$W = \begin{bmatrix} -1.767 \times 10^{-4} & 1.015 \times 10^{-3} & 1.726 \times 10^{-3} \\ 1.653 \times 10^{-1} & -5.337 \times 10^{-1} & -6.653 \times 10^{-1} \\ -1.638 \times 10^{-4} & 9.413 \times 10^{-4} & 1.600 \times 10^{-3} \\ 1.829 \times 10^{-4} & -1.051 \times 10^{-3} & -1.787 \times 10^{-3} \\ -1.833 \times 10^{-4} & 1.053 \times 10^{-3} & 1.791 \times 10^{-3} \end{bmatrix} \quad b = \begin{bmatrix} -8.658 \times 10^{-4} \\ -1.929 \times 10^{-1} \\ -8.026 \times 10^{-4} \\ 8.963 \times 10^{-4} \\ -8.982 \times 10^{-4} \end{bmatrix} \quad a = \begin{bmatrix} 2.888 \times 10^{-3} \\ -8.128 \times 10^{-1} \\ 2.103 \times 10^{-3} \\ -2.553 \times 10^{-3} \\ 2.604 \times 10^{-3} \end{bmatrix}$$

3. Setting Pengujian

Alat dan bahan yang diperlukan:

- a) *Hardware* akhir
- b) Elvasense 3in1
- c) Strip gula darah, kolestrol, tekanan darah sistolik dan diastolik
- d) Tensimeter digital Omron

4. Prosedur Pengujian

Proses pengujian dilakukan melalui beberapa tahapan yang terstruktur sebagai berikut:

1. Menyiapkan seluruh alat dan bahan yang akan digunakan selama proses pengujian.
2. Memastikan ujung jari subjek dalam kondisi bersih untuk menghindari gangguan pada hasil pembacaan sensor.
3. Mengaktifkan perangkat dengan menekan tombol daya hingga sistem siap digunakan.
4. Menempatkan ujung jari telunjuk subjek secara tepat di atas sensor MAX30105 agar pembacaan data optimal.
5. Memilih menu “Mengukur”, kemudian menunggu hingga sistem menampilkan hasil pengukuran berupa kadar gula darah, kolesterol, tekanan darah sistolik dan diaastolik.
6. Mencatat seluruh hasil pengukuran yang ditampilkan pada layar LCD sebagai data pengujian.
7. Melakukan pengukuran pembandingan menggunakan alat invasif pada jari yang sama, guna memperoleh data referensi untuk analisis akurasi.

5. Hasil Pengujian dan Analisa Data

Hasil pengujian secara keseluruhan terhadap alat ukur kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik diperoleh dari pengukuran pada 50 pasien, yang kemudian dibandingkan dengan hasil pengukuran menggunakan alat standar (Elvasense) dan tensimeter digital sebagai acuan.

Tabel 4.6 Komparasi Prediksi Model dan Pengukuran Invasif

Catatan: Data lengkap tersaji pada Lampiran

No	IR	Usia (tahun)	HR (bpm)	ALAT MEDIS				PREDIKSI			
				GLU	CHOL	TD SISTOL	TD DIASTOL	GLU	CHOL	TD SISTOL	TD DIASTOL
1	82800	58	73	119	169	138	85	116	182	140	85
2	79621	57	77	125	169	155	85	122	169	141	85
3	92052	58	75	95	220	134	84	116	188	137	85
4	99609	49	85	274	186	173	84	126	194	131	85
5	102151	54	100	315	190	136	91	142	188	135	88
6	89438	41	96	144	195	119	92	142	199	133	87
7	73264	47	70	120	184	125	83	117	184	138	83
8	112014	36	87	129	217	131	82	125	206	122	83
9	112125	44	73	114	190	106	80	111	193	123	81
10	97148	67	65	114	215	145	83	108	217	137	83
11	110211	64	80	93	201	109	84	115	194	133	86
12	99156	50	84	128	185	152	94	124	192	132	85
13	101714	43	72	116	184	130	81	112	196	126	81
14	99147	40	72	99	180	132	81	113	191	126	81
15	96393	38	75	119	185	131	81	116	185	126	81
16	99876	40	78	99	193	133	82	118	190	126	82
17	89786	23	71	120	151	112	79	116	166	122	79
18	97065	22	79	125	168	119	80	122	175	120	80
19	92546	22	78	126	200	118	80	123	175	121	80
20	89962	22	65	119	204	128	78	111	188	120	78
PERSENTASI RATA-RATA ERROR (%)								13.206	4.930	7.241	2.760
PERSENTASE AKURASI (%)								86.794	95.070	92.759	97.240

Penelitian sebelumnya oleh J S Peter Parasian (2025) juga berfokus pada sistem pengukuran non-invasif untuk kadar gula darah, kolesterol, dan asam urat, dengan menggunakan sensor MAX30105 [17]. Metode yang diterapkan dalam penelitian tersebut adalah regresi linear sederhana, yang menghasilkan akurasi prediksi gula darah sebesar 90,4%, kolesterol 90,2%, dan asam urat 87,7% [17].

Secara keseluruhan, sistem dalam penelitian ini menunjukkan tingkat akurasi 86,79% untuk pengukuran gula darah, 95,07% untuk pengukuran kolesterol, 92,75% untuk pengukuran tekanan darah sistolik dan 97,24% untuk pengukuran tekanan darah diastolik. Metode yang digunakan penelitian ini sama dengan penelitian sebelumnya dengan data training lebih banyak dari sebelumnya guna untuk memperbanyak variasi dataset yang digunakan dalam proses pelatihan model. Untuk persentase kolesterol memperoleh akurasi lebih tinggi dan digunakan dalam pengolahan tekanan darah sistolik dan diastolik juga mendapatkan akurasi yang tinggi.

Perbedaan tingkat akurasi pada parameter gula darah yang cenderung lebih rendah dibandingkan parameter lainnya dapat dijelaskan dari karakteristik data pengujian yang digunakan. Pada penelitian ini, jumlah data pengujian yang digunakan sebanyak 50 sampel dengan rentang usia naracoba yang cukup lebar, yaitu antara 20

hingga 70 tahun. Variasi usia yang besar ini berpengaruh signifikan terhadap kondisi fisiologis masing-masing individu, seperti perbedaan metabolisme, ketebalan jaringan kulit, perfusi darah, serta respons optik terhadap sensor. Parameter gula darah sendiri dikenal memiliki fluktuasi yang lebih dinamis dibandingkan kolesterol atau tekanan darah, karena dipengaruhi oleh banyak faktor seperti pola makan, aktivitas fisik, kondisi hormonal, hingga waktu pengukuran.



Gambar 4.11 Dokumentasi Pengujian
(a) Pengukuran Non-Invasif (b) Pengukuran Invasif

4.5 PENGUJIAN PRESISI

1. Tujuan

Pengujian presisi bertujuan untuk menilai tingkat konsistensi atau keandalan suatu alat dalam menghasilkan data pengukuran secara berulang. Artinya, pengujian ini dilakukan untuk mengetahui seberapa seragam hasil yang diperoleh ketika pengukuran terhadap sampel yang sama dilakukan dalam kondisi yang identik. Alat yang memiliki presisi tinggi akan memberikan hasil yang relatif sama pada setiap pengukuran, sehingga variasi acak yang tidak diinginkan dapat diminimalkan.

2. Metode Pengujian

Untuk mencapai tujuan evaluasi presisi, dilakukan serangkaian pengukuran berulang pada satu subjek atau sampel yang sama dalam waktu yang relatif singkat. Pada pengujian ini, parameter seperti kadar gula darah, kolesterol, tekanan darah sistolik dan diastolik diukur sebanyak 20 kali secara berturut-turut. Jeda antar setiap pengukuran ditetapkan selama satu detik guna mengurangi kemungkinan adanya perubahan kondisi pada subjek atau sampel yang dapat memengaruhi hasil. Metode ini dipilih agar mendekati kondisi penggunaan nyata sekaligus memastikan bahwa variasi data yang diperoleh lebih mencerminkan kinerja alat, bukan dipengaruhi oleh faktor eksternal yang berubah.

3. Setting Pengujian

Alat dan bahan yang diperlukan:

- b) *Hardware* akhir
- c) Laptop

4. Prosedur Pengujian

Pengujian dilakukan dengan prosedur sebagai berikut:

- a) Menyiapkan alat dan bahan
- b) Memastikan ujung jari subjek dalam keadaan bersih
- c) Melakukan pengukuran gula darah, kolesterol, tekanan darah sistolik dan diastolik pada naracoba dengan menekan menu “Mengukur” pada alat
- d) Mencatat hasil pengukuran selama 20 kali dari hasil yang di tampilkan di LCD

5. Hasil Pengujian

Parameter kuantitatif untuk presisi dinyatakan melalui koefisien variasi (KV%), yang merupakan ukuran standar deviasi relatif terhadap rata-rata. Formula matematis untuk Koefisien Variasi adalah:

$$KV \% = \left(\frac{\text{Standar Deviasi}}{\text{Rata-Rata}} \right) 100 \% \quad (4.1)$$

Berdasarkan hasil perhitungan pada Tabel 4.7, berdasarkan pengujian berulang hingga 20 kali seluruh parameter memiliki nilai KV yang sangat kecil, yaitu gula darah sebesar 0,60301%, kolesterol 0,276544%, tekanan darah sistolik 0,378248%, dan tekanan darah diastolik 0,518171%. Nilai KV yang berada jauh di bawah 1% ini menunjukkan bahwa variasi data antar percobaan sangat rendah, sehingga hasil pengukuran dapat dikatakan sangat konsisten atau memiliki tingkat presisi yang baik.

Tabel 4.7 Data Pengujian Presisi

Percobaan	Gula Darah	Kolesterol	TD Sistolik	TD Diastolik
1	119	186	124	79
2	120	185	125	79
3	119	186	124	79
4	118	185	124	80
5	120	186	125	79
6	119	185	124	79
7	119	186	124	79
8	120	185	125	80
9	118	186	124	79
10	119	185	124	79
11	119	186	125	79
12	120	185	124	79
13	119	186	124	80
14	118	185	124	79
15	120	186	125	79
16	119	185	124	79
17	119	186	124	79
18	120	185	125	80
19	118	186	124	79
20	119	185	124	79
Rata - Rata	119,1	185,5	124,3	79,2
Standar Deviasi	0,718185	0,512989	0,470162	0,410391
Koefisien Varian (%)	0,60301	0,276544	0,378248	0,518171

Secara interpretatif, semakin kecil nilai Koefisien Variasi, maka semakin tinggi tingkat kestabilan alat dalam menghasilkan data yang seragam pada pengukuran berulang. Dalam konteks penelitian ini, meskipun terdapat sedikit variasi nilai pada setiap percobaan, penyimpangan tersebut tidak signifikan terhadap rata-rata, sehingga alat mampu memberikan hasil yang reliabel. Hal ini juga menandakan bahwa sistem yang dikembangkan memiliki repeatability yang baik, yaitu kemampuan alat untuk menghasilkan nilai yang hampir sama dalam kondisi pengukuran yang sama.

4.6 PENGAMBILAN DATA SAMPEL

4.6.1 Pengambilan Data dan Skala Race

1. Tujuan

Tujuan dari proses pengumpulan data sampel adalah mendapatkan data pelatihan model regresi logistik, khususnya data inframerah, detak jantung dari sensor MAX30105 serta data gula darah, kolesterol, tekanan darah sistolik dan diastolik serta analisis skala Race.

2. Metode Pengujian

Metode pengumpulan data sampel dilakukan pengukuran langsung terhadap naracoba dengan rentang usia 20 – 70 tahun. Pengambilan data dilakukan secara bergantian. Pengambilan data pertama ini dilakukan mengukur dari gula darah, kolesterol dan tekanan darah naracoba, serta dengan mengumpulkan hasil analisa skala Race, Hasil wawancara terkait riwayat keluarga terhadap stroke dari naracoba.

3. Setting Pengujian

Alat dan bahan yang diperlukan:

- a. Elvasense 3in1
- b. Tensimeter digital
- c. Strip gula darah dan kolesterol
- d. Laptop
- e. Panduan sekala Race

4. Prosedur Pengujian

Proses pengumpulan data sampel dilakukan dengan prosedur sebagai berikut:

- a) Meminta naracoba duduk dalam posisi rileks
- b) Memastikan kondisi ujung jari pasien bersih dan kering, untuk menghindari gangguan pembacaan akibat debu.
- c) Meletakkan ujung jari di atas sensor MAX30105 untuk merekam data inframerah dan detak jantung selama 30 detik.
- d) Mencatat usia sebagai salah satu input model
- e) Mengambil sampel darah menggunakan Elvasense 3in1 untuk memperoleh gula darah dan kolesterol
- f) Mengambil nilai tekanan darah sistolik dan diastolik menggunakan tensimeter digital
- g) Mengamati naracoba untuk penentuan nilai skor pada skala Race
- h) Mewawancarai naracoba terkait riwayat keluarga terhadap stroke dan jumlah rokok perhari untuk perokok aktif.
- i) Mencatat data dan menyimpan dalam format data sampel

5. Hasil Pengujian dan Analisa Data

Pada tahap pengambilan data ini dilakukan pengukuran terhadap parameter fisiologis subjek menggunakan sensor. Selain itu, dicatat juga variabel pendukung seperti usia, jenis kelamin, tekanan darah, gula darah, dan kadar kolesterol serta hasil analisa terhadap skala Race. Data yang diperoleh kemudian digunakan untuk menganalisis faktor-faktor yang berkaitan dengan risiko stroke, sebagaimana ditunjukkan pada tabel berikut ini.

Tabel 4.8 Data Sampel Laki Laki

LAKI-LAKI	Usia (tahun)	Riwayat Keluarga	Rokok	Skala RACE	HR (bpm)	Sistolik	Diastolik	Gula Darah	Kolestrol
	21	0	10	0	102	134	84	146	227
	52	0	36	0	83	121	83	120	192
	28	0	0	0	85	121	80	124	188
	58	1	0	2	75	136	85	120	232
	25	0	10	0	71	111	80	87	162
	28	0	24	0	87	125	82	137	206
	57	0	12	0	77	155	85	125	169
	49	0	12	0	85	173	84	274	186
	44	1	36	0	89	169	101	141	208
	64	0	24	2	74	150	94	116	203
	43	0	30	0	95	129	86	145	205
	49	0	0	0	98	133	92	142	233
	54	0	0	0	100	136	91	315	190
	41	0	10	0	96	119	92	144	195
	47	0	24	0	70	125	83	120	184
	67	1	0	5	65	145	83	114	215
	50	1	36	1	84	152	94	128	185
	40	1	24	0	72	132	81	99	180
	38	1	0	0	75	131	81	119	185
	40	1	12	1	78	133	82	99	193
	22	0	0	0	79	119	80	125	168
	22	0	12	0	78	118	80	126	200
	25	0	12	0	85	124	81	201	192
	38	1	24	0	76	133	82	211	204
	42	0	48	2	71	156	90	226	210
	54	1	0	5	82	157	92	246	181

Tabel 4.9 Data Sampel Perempuan

PEREMPUAN	Usia (tahun)	Riwayat Keluarga	Rokok	Skala RACE	HR (bpm)	Sistolik	Diastolik	Gula Darah	Kolestrol
	22	1	0	0	79	118	80	124	166
	28	0	0	0	77	111	79	119	164
	25	0	0	0	83	129	82	135	206
	66	0	0	0	88	165	87	134	184
	50	0	0	0	83	158	94	124	188
	58	0	0	0	73	138	85	119	169
	58	0	0	0	75	134	84	95	220
	36	0	0	0	87	131	82	129	217
	44	0	0	0	73	106	80	114	190
	64	0	0	0	80	109	84	93	201
	43	1	0	0	72	130	81	116	184
	23	0	0	0	71	112	79	120	151
	22	0	0	0	65	128	78	119	204
	34	0	0	0	75	125	80	119	177
	30	1	0	0	82	134	81	98	205
	27	0	0	0	68	127	91	203	228
	50	1	0	3	78	150	102	255	184
	51	1	0	0	69	146	83	117	204
	52	0	0	0	70	141	82	115	222
	50	1	0	4	75	135	83	118	211
	52	0	0	0	74	134	83	117	184
	53	0	0	0	76	136	84	120	178
	60	0	0	0	83	150	86	217	175
	22	0	0	0	78	117	94	124	165


Berdasarkan perbandingan data sampel laki-laki dan perempuan pada Tabel 4.8 dan 4.9, terlihat adanya perbedaan pola faktor risiko yang cukup jelas, terutama yang berkaitan dengan kebiasaan merokok dan dampaknya terhadap parameter fisiologis. Pada kelompok laki-laki, sebagian besar subjek memiliki riwayat konsumsi rokok dengan variasi jumlah yang cukup tinggi, yang cenderung berkorelasi dengan nilai tekanan darah sistolik dan diastolik yang lebih fluktuatif serta dalam beberapa kasus menunjukkan nilai yang lebih tinggi. Selain itu, nilai gula darah pada laki-laki juga tampak memiliki variasi yang lebih ekstrem, yang mengindikasikan adanya pengaruh gaya hidup terhadap kondisi metabolik.

Sebaliknya, pada kelompok perempuan, mayoritas subjek tidak memiliki kebiasaan merokok, sehingga pola tekanan darah relatif lebih stabil meskipun tetap terdapat beberapa nilai tinggi yang dipengaruhi oleh faktor usia dan riwayat keluarga. Secara umum, data ini menunjukkan bahwa faktor risiko seperti merokok lebih dominan pada laki-laki dan berkontribusi terhadap peningkatan tekanan darah serta variabilitas parameter kesehatan lainnya, sedangkan pada perempuan, faktor usia dan riwayat keluarga menjadi lebih berperan dalam memengaruhi kondisi fisiologis yang berkaitan dengan risiko stroke.

4.6.2 Penentuan Koefisien Beta untuk Regresi Logistik

Pada penentuan ini dilakukan implementasi perhitungan model regresi logistik menggunakan perangkat lunak JupyterLabPortable dengan bahasa pemrograman Python. Tahap awal pengujian dimulai dengan inisialisasi library yang dibutuhkan, seperti *pandas*, *numpy*, *scikit-learn*, *matplotlib*, dan *seaborn*. Selanjutnya data hasil pengukuran dibaca yang kemudian dilakukan pengecekan struktur data untuk memastikan seluruh variabel telah sesuai. Variabel input (X) yang digunakan dalam pemodelan terdiri dari usia, jenis kelamin, riwayat keluarga, rokok, skala Race, detak jantung, tekanan darah sistolik diastolik, gula darah, kolestrol, sedangkan variabel output (y) adalah Stroke sebagai target klasifikasi.

Setelah proses persiapan data selesai, dataset dibagi menjadi data training dan data testing menggunakan metode *train_test_split* dengan komposisi 75% data latih dan 25% data uji, serta *random_state* sebesar 42 agar pembagian data konsisten. Model regresi logistik kemudian diinisialisasi menggunakan solver *lbfgs*, jumlah iterasi maksimum 1000, dan parameter *verbose* bernilai 1 untuk menampilkan proses pelatihan model. Selanjutnya model dilatih menggunakan data training (X_{train} dan y_{train}) sehingga mampu mempelajari hubungan antara variabel input dengan kemungkinan terjadinya stroke.



Gambar 4.12 Hasil Inisialisasi dan Pelatihan Model Regresi Logistik

Setelah proses pemodelan selesai dilakukan, program dijalankan untuk menampilkan nilai-nilai parameter penting dari model regresi logistik yang telah dilatih sebelumnya. Hasil keluaran tersebut berupa nilai β_0 (intercept) serta koefisien regresi (β) pada masing-masing variabel prediktor. Nilai koefisien ini selanjutnya digunakan dalam penyusunan rumus perhitungan regresi logistik dan hasil lengkapnya dapat dilihat pada Tabel 4.10.

Untuk bisa menentukan konstanta atau β_0 koefisien $\beta_1, \beta_2, \dots, \beta_n$ untuk setiap variabel $X_1, X_2, \dots, X_n$ dapat menggunakan pemodelan regresi logistik pada program python, sebagai berikut.

```
# CETAK NILAI KOEFISIEN (BETA)
fitur = [
    'USIA',
    'JENIS KELAMIN',
    'RIWAYAT KELUARGA',
    'ROKOK',
    'SKALA RACE',
    'BPM SENSOR',
    'Sistolik',
```

```

'Diastolik',
'GULA DARAH',
'KOLESTROL'
]
print("\n=== KOEFISIEN REGRESI LOGISTIK ===")

# Intercept
print(f" $\beta_0$  (Intercept) : {model.intercept_[0]:.6f}")

# Koefisien fitur
for i, (nama, coef) in enumerate(zip(fitur, model.coef_[0]), start=1):
    print(f" $\beta_{\{i\}}$  ({nama}) : {coef:.6f}")

```

Tabel 4.10 Hasil Koefisien Pemodelan Regresi Logistik

Nilai Koefisien B0				-95,59786095
Koefisien Regresi				
B1	B2	B3	B4	B5
-0,0811438	0,14541473	0,47194853	0,10920642	0,74655845
B6	B7	B8	B9	B10
-0,24352054	0,16413259	0,88939616	-0,10597514	0,16359861

4.6.3 Pengujian Regresi Logistik dari Data Sampel

Pada pengujian ini ditampilkan hasil spesifik dari perhitungan menggunakan metode regresi logistik. Variabel yang digunakan dalam analisis meliputi usia, jenis kelamin, riwayat keluarga, kebiasaan merokok, serta parameter fisiologis seperti detak jantung (HR), tekanan darah (sistolik dan diastolik), kadar gula darah, dan kolesterol. Berikut merupakan hasil validasi data yang digunakan dalam perhitungan regresi logistik untuk menganalisis risiko stroke.

Tabel di bawah merupakan sebagian dari total 50 data yang telah dikumpulkan. Data ini digunakan untuk menganalisis faktor-faktor yang mempengaruhi risiko stroke, dengan variabel seperti usia, jenis kelamin, riwayat keluarga, kebiasaan merokok, tekanan darah, detak jantung, gula darah, dan kolesterol serta nilai skala Race. Metode regresi logistik digunakan untuk mengetahui hubungan antar variabel tersebut terhadap kemungkinan terjadinya stroke, sehingga dapat membantu dalam menghasilkan analisis yang lebih jelas dan akurat berdasarkan data yang diperoleh.

Tabel 4.11 Pengujian Regresi Logistik Sampel Perempuan
Catatan: Data lengkap tersaji pada Lampiran

PEREMPUAN	Usia	Riwayat Keluarga	Rokok	Skala RACE	HR	Sistol	Diastol	Gula Darah	Kolestrol	Output	Pengujian Diagnosa
	22	1	0	0	79	118	80	124	166	0,000	TIDAK BERISIKO
	28	0	0	0	77	111	79	119	164	0,000	TIDAK BERISIKO
	25	0	0	0	83	129	82	135	206	0,0128	TIDAK BERISIKO
	66	0	0	0	88	165	87	134	184	0,116	TIDAK BERISIKO
	50	0	0	0	83	158	94	124	188	0,999	BERISIKO
	58	0	0	0	73	138	85	119	169	0,008	TIDAK BERISIKO
	58	0	0	0	75	134	84	95	220	0,983	BERISIKO

Tabel 4.12 Pengujian Regresi Logistik Sampel Laki-Laki
Catatan: Data lengkap tersaji pada Lampiran

LAKI-LAKI	Usia	Riwayat Keluarga	Rokok	Skala RACE	HR	Sistol	Diastol	Gula Darah	Kolestrol	Output	Pengujian Diagnosa
	21	0	10	0	102	134	84	146	227	0,073	TIDAK BERISIKO
	52	0	36	0	83	121	83	120	192	0,027	TIDAK BERISIKO
	28	0	0	0	85	121	80	124	188	0,000	TIDAK BERISIKO
	58	1	0	2	75	136	85	120	232	0,998	BERISIKO
	25	0	10	0	71	111	80	87	162	0,000	TIDAK BERISIKO
	44	1	36	0	89	169	101	141	208	1	BERISIKO
	64	0	24	2	74	150	94	116	203	0,999	BERISIKO

Untuk mengimplementasikan perhitungan menggunakan regresi logistik dalam menentukan apakah setiap subjek berpotensi mengalami stroke atau tidak, seluruh data yang telah dikumpulkan dapat dimasukkan ke dalam persamaan regresi logistik berikut.

$$P(Y=1) = \frac{e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}} \quad (4.2)$$

Dengan contoh implementasi perhitungan sebagai berikut :

$$P(Y=1) = \frac{\exp((-95,59 + (-0,08x58) + (0,14x1) + (0,47x1) + (0,10x0) + (0,74x2) + (-0,24x75) +))}{(1 + \exp((-95,59 + (-0,08x58) + (0,14x1) + (0,47x1) + (0,10x0) + (0,74x2) + (-0,24x75) +)))}$$

$$= \frac{(-0,24 \times 75) + (0,16 \times 136) + (0,88 \times 85) + (-0,10 \times 120) + (0,1 \times 232)}{(1 + \text{Exp}((-0,24 \times 75) + (0,16 \times 136) + (0,88 \times 85) + (-0,10 \times 120) + (0,1 \times 232)))}$$

$$= 0,998$$

Berdasarkan hasil pengujian regresi logistik pada sampel perempuan dan laki-laki, dapat disimpulkan bahwa usia merupakan salah satu faktor yang paling berpengaruh terhadap peningkatan risiko stroke. Data menunjukkan bahwa subjek dengan kategori berisiko cenderung berada pada kelompok usia yang lebih tinggi (≥ 50 tahun), yang umumnya juga diikuti oleh peningkatan tekanan darah (sistolik maupun diastolik), serta dalam beberapa kasus disertai kadar gula darah dan kolesterol yang lebih tinggi. Hal ini mengindikasikan adanya hubungan yang saling berkaitan antara usia dengan parameter fisiologis lainnya, di mana semakin bertambah usia, elastisitas pembuluh darah menurun, resistensi pembuluh meningkat, serta kontrol metabolik tubuh menjadi kurang optimal, sehingga meningkatkan kemungkinan terjadinya hipertensi dan gangguan metabolik yang merupakan faktor risiko utama stroke.

Selain itu, pada sampel laki-laki terlihat bahwa kebiasaan merokok turut memperkuat risiko melalui peningkatan tekanan darah dan kerusakan pembuluh darah, sedangkan pada perempuan, faktor usia dan riwayat keluarga tampak lebih dominan. Dengan demikian, dapat disimpulkan bahwa risiko stroke tidak hanya dipengaruhi oleh satu variabel, tetapi merupakan hasil interaksi multifaktor, dengan usia sebagai faktor utama yang memperkuat pengaruh parameter lain seperti tekanan darah, kadar gula, kolesterol, dan gaya hidup.



Gambar 4.13 Dokumentasi Pengambilan Sampel pada Naracoba

4.6.4 Implementasi Regresi Logistik dengan JupyterLab

Tahap prediksi terhadap data testing (X_{test}) menggunakan model yang telah dilatih. Hasil prediksi disimpan pada variabel *predictions*, kemudian dilakukan evaluasi performa model menggunakan nilai *accuracy_score* untuk mengetahui tingkat akurasi prediksi antara data aktual (y_{test}) dengan hasil klasifikasi model. Selain itu, evaluasi juga dilengkapi dengan *classification report* yang menampilkan nilai *precision*, *recall*, dan *f1-score* untuk masing-masing kelas.

Untuk memperjelas hasil pengujian, akurasi model serta tingkat kesalahan dan ketepatan klasifikasi ditampilkan menggunakan *confusion matrix* berbentuk heatmap. Pada tahap akhir, sistem juga menampilkan nilai intercept (β_0) serta koefisien masing-masing variabel independen (β_1 sampai β_{10}). Nilai koefisien tersebut digunakan untuk mengetahui besar pengaruh setiap faktor terhadap prediksi risiko stroke, sehingga model regresi logistik yang dibangun tidak hanya berfungsi sebagai alat prediksi, tetapi juga sebagai analisis hubungan antar variabel pada penelitian proyek akhir ini.

Tabel 4.13 Hasil Pengujian menggunakan JupyterLab Portable

Akurasi model: 0.8571428571428571					
	precision	recall	f1-score	support	
0	0.83	1.00	0.91	5	
1	1.00	0.50	0.67	2	
accuracy			0.86	7	
macro avg	0.92	0.75	0.79	7	
weighted avg	0.88	0.86	0.84	7	

Berdasarkan hasil pengujian, model regresi logistik memperoleh nilai akurasi sebesar 0,8571 atau sekitar 85,7%, yang menunjukkan bahwa sebagian besar data uji berhasil diklasifikasikan dengan benar. Pada kelas 0, model memiliki nilai *precision* 0,83, *recall* 1,00, dan *f1-score* 0,91, sehingga model sangat baik dalam mengenali seluruh data pada kelas ini. Sementara itu, pada kelas 1 diperoleh nilai *precision* 1,00, *recall* 0,50, dan *f1-score* 0,67. Hal ini menunjukkan bahwa prediksi untuk kelas 1 cukup tepat ketika terdeteksi, namun model masih belum mampu mengenali seluruh data positif secara maksimal. Secara keseluruhan, performa model sudah cukup baik, tetapi masih perlu peningkatan terutama pada nilai recall untuk kelas 1.

4.7 PENGUJIAN PENGIRIMAN DATA KE BASIS DATA

1. Tujuan

Pengujian ini bertujuan untuk memastikan bahwa data hasil pengukuran dari perangkat keras dapat dikirim ke firebase *realtime* database secara akurat, tanpa terjadi kehilangan maupun duplikasi data.

2. Metode Pengujian

Metode yang digunakan adalah observasi langsung dengan membandingkan data pada serial monitor dan data yang tersimpan di Firebase. Data hasil pengukuran dikirim melalui koneksi internet, kemudian diverifikasi kesesuaiannya. Jika kedua data identik, maka pengiriman dinyatakan berhasil.

3. Setting Pengujian

Alat dan bahan yang digunakan sebagai berikut:

- Hardware* akhir
- Laptop

4. Prosedur Pengujian


Langkah-langkah pengujian dilakukan sebagai berikut:

- Menyiapkan alat dan bahan.
- Melakukan pengukuran gula darah, kolesterol, tekanan darah sistolik dan diastolik.
- Mencatat data yang muncul pada serial monitor.
- Mengirim data ke Firebase melalui menu “Upload Data”.
- Membandingkan data pada serial monitor dengan data di Firebase.

5. Hasil Pengujian

Hasil pengujian menunjukkan bahwa proses pengiriman data berjalan dengan baik. Data yang ditampilkan pada serial monitor sama dengan data yang tersimpan di Firebase, sehingga tidak ditemukan kehilangan maupun duplikasi data. Sebagai contoh, data dengan *timestamp* tertentu menunjukkan nilai gula darah, kolesterol, tekanan darah (sistolik dan diastolik), dan detak jantung yang sama persis antara perangkat dan database. Konsistensi ini juga terjadi pada pengiriman data berikutnya.

Dari sisi performa, waktu rata-rata pengiriman data adalah sekitar 1,9 detik per data. Hal ini menunjukkan bahwa sistem mampu mengirimkan data secara efisien. Secara keseluruhan, sistem berhasil mengirimkan data dengan akurat dan andal. Proses ini meliputi koneksi WiFi, penyimpanan data dalam format JSON di memori lokal, pengiriman ke Firebase menggunakan fungsi yang sesuai, serta penghapusan data lokal setelah berhasil dikirim untuk mencegah duplikasi.



Gambar 4.14 Data Tersimpan di Firebase

4.8 PENGUJIAN APLIKASI

1. Tujuan

Pengujian aplikasi *mobile* bertujuan untuk mengevaluasi tampilan antarmuka serta memastikan proses pengolahan dan penyajian data berjalan dengan baik. Selain itu, pengujian ini dilakukan untuk menjamin bahwa data setiap pengguna ditampilkan secara terpisah dan tidak tercampur.

2. Metode Pengujian

Metode yang digunakan adalah observasi langsung dengan membandingkan data pada firebase *realtime* database sebagai sumber utama dengan data yang ditampilkan pada aplikasi *mobile*. Setiap data diidentifikasi berdasarkan ID pengguna, kemudian diverifikasi apakah data yang muncul pada aplikasi sudah sesuai dengan pengguna tersebut.

3. Setting Pengujian

Alat dan bahan yang digunakan sebagai berikut:

- a) *Smartphone*
- b) Firebase *Realtime* Database
- c) Hardware akhir

4. Prosedur Pengujian

Langkah-langkah pengujian dilakukan sebagai berikut:

- a) Memastikan *smartphone* terhubung dengan internet yang stabil.
- b) Melakukan login ke aplikasi, atau registrasi jika belum memiliki akun.
- c) Mengamati data hasil pengukuran yang tersimpan di Firebase.
- d) Memeriksa kesesuaian data yang ditampilkan pada aplikasi *mobile* dengan hasil pengukuran di *hardware* sebelum dikirimkan.

5. Hasil Pengujian

Hasil pengujian menunjukkan bahwa aplikasi *mobile* mampu menampilkan data yang tersimpan di Firebase *Realtime* Database dengan baik. Halaman utama menampilkan beberapa data terbaru, seperti nilai gula darah, kolesterol, tekanan darah sistolik dan diastolik, serta detak jantung.

(a)

(b)

Gambar 4.15 Implementasi Filter Data Berdasarkan User ID

(a) Home Page Rizka

(b) Home Page Rebo

Pada aplikasi terdapat form pengisian kondisi pengguna seperti riwayat keluarga terhadap stroke dan rokok pengguna. Dapat dilakukan uji terhadap kemungkinan stroke dari data pengukuran terakhir yang dilakukan pengguna.

Pada bagian riwayat, seluruh data pemeriksaan dapat ditampilkan secara lengkap. Data yang ditampilkan terbukti sesuai dengan masing-masing pengguna, sehingga tidak terjadi pencampuran data antar akun. Proses penyaringan dilakukan berdasarkan *timestamp*, sedangkan pengurutan data memanfaatkan fungsi bawaan pada sistem. Secara keseluruhan, aplikasi *mobile* telah mampu menyajikan data secara akurat, terstruktur, dan personal bagi setiap pengguna.

BAB 5

PENUTUP

5.1 KESIMPULAN

Berdasarkan proses perancangan, pembuatan, dan pengujian alat deteksi stroke dini non-invasif berbasis sensor MAX30105 dan metode regresi logistik, diperoleh beberapa kesimpulan sebagai berikut:

- a) Pengukuran kadar gula darah menggunakan sensor MAX30105 menunjukkan tingkat akurasi sebesar 86,79%, sedangkan untuk kolesterol sebesar 95,07% tekanan darah sistolik sebesar 92,75% dan tekanan darah diastolik sebesar 97,24%. Tingkat presisi alat yang ditunjukkan oleh nilai koefisien variasi di bawah 2% pada keempat parameter tersebut.
- b) Model *multi-layer perceptron* yang dikembangkan menunjukkan bahwa setiap parameter memiliki konfigurasi *neuron hidden layer* optimal yang berbeda. Untuk parameter gula darah, performa terbaik diperoleh pada penggunaan 3 *neuron hidden layer* dengan nilai korelasi sebesar 0,7413. Pada parameter kolesterol, performa tertinggi dicapai dengan 12 *neuron hidden layer* dengan nilai sebesar 0,8338. Parameter tekanan darah sistolik, hasil terbaik diperoleh pada 3 *neuron hidden layer* dengan nilai korelasi sebesar 0,65772, dan tekanan darah diastolik menunjukkan performa optimal dengan nilai sebesar 0,8155 pada 5 *neuron hidden layer*. Hal ini menunjukkan bahwa kompleksitas model yang optimal bergantung pada karakteristik masing-masing parameter yang dianalisis.
- c) Penerapan metode regresi logistik dalam proses diagnosis terhadap stroke dini menunjukkan tingkat akurasi sebesar 85,71%. Model ini mengklasifikasikan kondisi pasien, dari nilai *precision* dan *recall* yang seimbang serta didukung oleh nilai *F1-score*. Berdasarkan hasil evaluasi pada lampiran menggunakan *confusion matrix*, model memperoleh akurasi sebesar 82% dengan tingkat kesalahan 18%. Nilai *recall* ini menunjukkan kemampuan model dalam mendeteksi kasus stroke dini, nilai *specificity* mengindikasikan kemampuan dalam mengenali kondisi normal.

5.2 SARAN

Penelitian ini memiliki beberapa keterbatasan, di antaranya jumlah data latih (*training data*) yang masih relatif sedikit sehingga memengaruhi kemampuan model dalam melakukan generalisasi terhadap data baru. Selain itu, proses pengujian dilakukan pada kondisi yang cenderung terkontrol dan sesuai dengan standar pengukuran parameter kesehatan seperti gula darah, kolesterol, serta tekanan darah sistolik dan diastolik, sehingga hasil yang

diperoleh belum sepenuhnya merepresentasikan kondisi penggunaan di lingkungan nyata yang lebih dinamis. Pada penelitian selanjutnya, penggunaan dataset yang lebih besar dan beragam serta eksplorasi berbagai algoritma machine learning dalam pengolahan keempat parameter (gula darah, kolesterol, tekanan darah sistolik dan diastolik) tersebut berpotensi memberikan model dengan performa dan akurasi prediksi risiko stroke yang lebih optimal.

DAFTAR PUSTAKA

- [1] Syareza, R, S., Oktiasari, R., Madona, P., Susianti, E., & Muzti Sahar. 2018. Alat Bantu Terapi Pasca Stroke Untuk Tangan. Riau: Jurnal Politeknik Caltex. 4(5).
- [2] Pinzon, R.T., 2016. *Awas Stroke*. Yogyakarta: Betha Grafika. Bab1,hlm.1.
- [3] Pinzon, R.T., 2016. *Awas Stroke*. Yogyakarta: Betha Grafika. Bab 2, hlm.5.
- [4] Kusuma, A. (14 Januari 2021). Jutaan Orang Fobia Jarum Suntik, Akankah Jadi Kendala Vaksinasi Covid-19? Kompas. <https://www.kompas.com/sains/read/2021/01/14/100200823/jutaan-orang-fobia-jarum-suntik-akankah-jadi-kendala-vaksinasi-covid-19-?page=all>
- [5] R. T. Pinzon, *Awas Stroke*. Yogyakarta, Indonesia: Betha Grafika, Apr.2016.
- [6] Keputusan Menteri Kesehatan Republik Indonesia Nomor : 1792/MENKES/SK/XII/2010 Tentang Pedoman Pemeriksaan Kimia Klinik .2011.
- [7] Pickering D, Marsden J. How to measure blood glucose.Community Eye Health Journal [Internet]. 2014;27(87). Available from: www.iapb.standardlist.org
- [8] Supriyanto, E. (2018). Rancang Bangun Alat Portabel untuk Memantau dan Menganalisis Detak Jantung Subjek yang Terpengaruh Kafein.
- [9] Analog Devices, *MAX30105 High-Sensitivity Optical Sensor for Smoke Detection*, Datasheet, Rev. 1, 2018. [Online]. Available: <https://www.analog.com/media/en/technical-documentation/data-sheets/MAX30105.pdf>
- [10] Arduino Indonesia. 2019. Arduino Indonesia. [online] Available at: <https://www.arduinoindonesia.id/2019/07> .
- [11] SD Perry, "18650 Battery Shield Keep Alive Circuit." Accessed: Jun. 26, 2025. [Online]. Available: <https://samueldperry.com/2020/11/04/18650-battery-shield-keep-alive-circuit/>
- [12] LG Chem, "*Product Specification: Rechargeable Lithium Ion Batt ery INR18650 M26*," LG Chem Co., Ltd., Datasheet, Apr. 2015. [Online]. Available:<https://www.alldatasheet.com/datasheet.pdf/pdf/2172857/LG/INR18650.html>. Accessed: Oct. 12, 2025.
- [13] Vishay Intertechnology, Inc., "*LCD-016N002B-CFH-ET: 16 × 2 Character LCD*," Datasheet, Vishay, 2016. [Online]. Available: <https://www.vishay.com/docs/37484/lcd016n002bcfh.pdf>. Accessed: Oct. 12, 2025.
- [14] Olah Data Skripsi, Analisis Regresi Logistik SPSS, 17 Maret 2017. [Online]. Available: <https://www.olahdataskripsi.com/2017/03/analisis-regresilogistik-spss.html>

- [15] Ali Ilham Sofiyat, Awaluddin Tjalla, & Mahdiyah. (2023). Pemodelan Regresi Logistik Biner terhadap Penerimaan Pegawai di PT XYZ Jakarta. *Matematika Sains*, 1(1), Tahun 2023. Universitas Islam As-Syafi'iyah & Universitas Negeri Jakarta. Diakses dari: <mailto:alisofiyat.fst@uia.ac.i>
- [16] E. Roflin, F. Riana, E. Munarsih, Pariyana, and I. A. Liberty, *Regresi Logistik Biner dan Multinomial*. Indramayu: Penerbit NEM, 2021.
- [17] K. Y. Chan, B. Abu-Salih, R. Qaddoura, A. M. Al-Zoubi, V. Palade, D.-S. Pham, J. Del Ser, and K. Muhammad, "Deep neural networks in the cloud: Review, applications, challenges and research directions," *Neurocomputing*, vol. 545, p. 126327, May 2023.
- [18] MathWorks. (2026). *mapminmax* — Process matrices by mapping row minimum and maximum values to $[-1, 1]$.
- [19] Hagan, M. T., & Menhaj, M. B. (1994). *Training Feedforward Networks with the Marquardt Algorithm*. *IEEE Transactions on Neural Networks*, 5(6), 989–993. DOI: 10.1109/72.329697.
- [20] C. Yildiz, K. Guney, M. Turkmen, and S. Kaya, "Neural Models for Coplanar Strip Line Synthesis," *Progress In Electromagnetics Research*, vol. 69, pp. 127–144, 2007, doi: 10.2528/PIER06120802.
- [21] Physio-pedia. Stroke: Assessment. [Internet]. [Diakses 4 Juli 2025]. Tersedia dari: https://www.physio-pedia.com/Stroke:_Assessment#:~:text=meminimalkan%20penundaan%20transportasi.,ABCD%20/%20ABCD2,segera%20sebagai%20pasien%20rawat%20inap.
- [22] A. W. R. Gusti, Kemalasar, dan J. S. P. C. Parasian, "Deteksi dini kesehatan berdasarkan nilai kadar gula darah, kolesterol, dan asam urat non-invasif dengan *Multi-Layer Perceptron*," *Jurnal Riset Rekayasa Elektro*, vol. 7, no. 2, pp. 127–136, Dec. 2025, doi: 10.30595/jrre.v7i2.27002.
- [23] Tjitra, M.A., Anju, N.E., Sudiana, D. and Rizkinia, M., 2024. A WirelessNoninvasive Blood Pressure Measurement System Using MAX30102 and Random Forest Regressor for Photoplethysmography Signals. *Computers*, 13(5), Article 125. Available at: <https://doi.org/10.3390/computers13050125>.
- [24] E. A. Suprayitno, A. Setiawan, and R. Dijaya, "Design of Instrumentation in Detecting Blood Sugar Levels with Non-Invasive Technique Base on IoT (Internet of Things)," *International Journal of Engineering & Technology*, vol. 7, no. 4.15, pp. 440–442, 2018
- [25] R. Rokhana, A. W. R. Gusti, dan R. U. Salim, "Smart System for Early Diagnosis of Gastroesophageal Reflux Disease (GERD)," *Journal of Applied Electrical Engineering*, vol. 9, no. 2, pp. 169–175, Dec. 2025.
- [26] Y. Inayatullah, A. H. Ginting, and S. Y. Doo, "Rancang Bangun Sistem Monitoring Detak Jantung dan Saturasi Oksigen Menggunakan Oximeter Max30102," *JTekEL: Jurnal Teknik Elektro*, vol. 1, no. 2, pp. 53–58, 2024.

LAMPIRAN

Lampiran 1. HKI Software NISTRO App


REPUBLIK INDONESIA
KEMENTERIAN HUKUM

SURAT PENCATATAN CIPTAAN

Dalam rangka perlindungan ciptaan di bidang ilmu pengetahuan, seni dan sastra berdasarkan Undang-Undang Nomor 28 Tahun 2014 tentang Hak Cipta, dengan ini menerangkan:

Nomor dan tanggal permohonan : EC002026076388, 2 Juni 2026

Pencipta

Nama : Agrippina Waya Rahmanning Gusti, Moch. Rochmad dkk
Alamat : Siwalankerto Tengah no.98-C, Surabaya 60236
Kewarganegaraan : Indonesia

Pemegang Hak Cipta

Nama : Politeknik Elektronika Negeri Surabaya
Alamat : Jalan Raya ITS Sukolilo Kampus PENS Surabaya 60111
Kewarganegaraan : Indonesia
Jenis Ciptaan : Program Komputer
Judul Ciptaan : NISTRO – Non Invasive Stroke Detector

Tanggal dan tempat diumumkan untuk pertama kali di wilayah Indonesia atau di luar wilayah Indonesia : 26 Mei 2026, di Kota Surabaya

Jangka waktu perlindungan : Berlaku selama 50 (lima puluh) tahun sejak Ciptaan tersebut pertama kali dilakukan Pengumuman.

Nomor Pencatatan : 001258720

adalah benar berdasarkan keterangan yang diberikan oleh Pemohon.
Surat Pencatatan Hak Cipta atau produk Hak terkait ini sesuai dengan Pasal 72 Undang-Undang Nomor 28 Tahun 2014 tentang Hak Cipta.

a.n. MENTERI HUKUM
DIREKTUR JENDERAL KEKAYAAN INTELEKTUAL
u.b
Direktur Hak Cipta dan Desain Industri

Agung Damarsasongko,SH.,MH.
NIP. 196912261994031001





Disclaimer:


1. Dalam hal pemohon memberikan keterangan tidak sesuai dengan surat pernyataan, Menteri berwenang untuk mencabut surat pencatatan permohonan.
2. Surat Pencatatan ini telah diunggah secara elektronik menggunakan segel elektronik yang diterbitkan oleh Balai Besar Sertifikasi Elektronik, Badan Siber dan Sandi Negara.
3. Surat Pencatatan ini dapat dibuktikan keabsahannya dengan memindai kode QR pada dokumen ini dan informasi akan ditampilkan dalam browser.



LAMPIRAN PENCIPTA

No	Nama	Alamat
1	Agrippina Waya Rahmaning Gusti	Siwalankerto Tengah no.98-C, Surabaya 60236
2	Moch. Rochmad	Perum Taman Surya Agung blok N no-30-Wage-Taman 61257
3	Rizka Sugiharto	Jl. Parang Ukel 8.A. Kadipaten, Babadan, Ponorogo 63491








Dislaimer:


1. Dalam hal penuben memberikan keterangan tidak sesuai dengan surat pernyataan, Menteri berwenang untuk mencabut surat pencatatan permohonan.
2. Surat Pencatatan ini telah disegel secara elektronik menggunakan segel elektronik yang diterbitkan oleh Badan Besar Sertifikasi Elektronik, Badan Siber dan Sandi Negara.
3. Surat Pencatatan ini dapat dibuktikan keasliannya dengan memindai kode QR pada dokumen ini dan informasi akan ditunjukkan dalam browser.

Lampiran 2. Prosedur Penggunaan Alat

Penggunaan alat dapat mengikuti langkah-langkah sebagai berikut:

No	Langkah Prosedur	Gambar
1	Tekan Tombil switch ON/OFF untuk menyalakan	
2	Di ponsel/laptop buka pengaturan WiFi dan hubungkan ke jaringan “ESP_Config_AP”	
3	Masukkan jaringan WiFi	
4	Setelah terhubung, liat pada layar LCD akan muncul IP, dan koneksi akan tersimpan.	
5	Tekan Tombol merah untuk memilih menu. Pilih “Mengukur”	

6	Tekan Tombol kuning untuk enter atau eksekusi	
7	Letakkan ujung jari telunjuk yang bersih pada tempat sensor	
8	Tunggu hingga proses pengukuran selesai	
9	Masukkan usia dengan menggunakan tombol merah untuk menaikkan angka di puluhan dan satuan	
10	Tombol enter (kuning) untuk konfirmasi usia	

11	Muncul hasil prediksi, lihat hasil pada layar LCD 16x2	
12	Masukkan ID User dengan tombol merah untuk tambah angka	
13	tombol kuning untuk konfirmasi (OK) kirim ke firebase	
14	Cek nilai gula darah, kolestrol, dan HR pada NistroApp	

15	Lanjutkan isi form untuk menghitung kemungkinan stroke pada NistroApp	
----	---	--

Lampiran 3. Tabel Data Training Gula Darah

NO	IR	USIA (tahun)	Detak Jantung	Gula Darah
1	99163	22	79	124
2	106829	28	77	119
3	89149	25	83	135
4	91945	21	102	146
5	94921	66	88	134
6	111360	52	83	120
7	118148	28	85	124
8	85908	58	75	120
9	83614	25	71	87
10	103494	50	83	124
11	97649	28	87	137
12	82800	58	73	119
13	79621	57	77	125
14	92052	58	75	95
15	87761	44	89	141
16	92079	64	74	116
17	85515	43	95	145
18	100745	49	98	142
19	89438	41	96	144
20	73264	47	70	120
21	112014	36	87	129
22	112125	44	73	114
23	97148	67	65	114
24	110211	64	80	93
25	99156	50	84	128
26	101714	43	72	116
27	99147	40	72	99
28	96393	38	75	119
29	99876	40	78	99
30	89786	23	71	120
31	97065	22	79	125

32	92546	22	78	126
33	89962	22	65	119
34	99371	34	75	119
35	101829	30	82	98
36	82961	51	69	117
37	95637	52	70	115
38	95273	50	75	118
39	96352	52	74	117
40	89542	53	76	120
41	96242	22	78	124

Lampiran 4. Tabel Data Training Kolestrol

NO	IR	USIA (tahun)	Detak Jantung	Kolestrol
1	99163	22	79	166
2	106829	28	77	164
3	89149	25	83	206
4	94921	66	88	184
5	111360	52	83	192
6	118148	28	85	188
7	83614	25	71	162
8	103494	50	83	188
9	97649	28	87	206
10	82800	58	73	169
11	79621	57	77	169
12	99609	49	85	186
13	87761	44	89	208
14	92079	64	74	203
15	85515	43	95	205
16	102151	54	100	190
17	89438	41	96	195
18	73264	47	70	184
19	112014	36	87	217
20	112125	44	73	190
21	97148	67	65	215
22	110211	64	80	201
23	99156	50	84	185
24	101714	43	72	184
25	99147	40	72	180
26	96393	38	75	185
27	99876	40	78	193
28	89786	23	71	151
29	97065	22	79	168
30	92546	22	78	200

31	89962	22	65	204
32	102367	25	85	192
33	90536	38	76	204
34	99371	34	75	177
35	101829	30	82	205
36	100722	42	71	210
37	95175	50	78	184
38	82961	51	69	204
39	95637	52	70	222
40	95273	50	75	211
41	96352	52	74	184
42	89542	53	76	178
43	87639	60	83	175
44	97353	54	82	181
45	96242	22	78	165

Lampiran 5. Tabel Data Training Tekanan Darah Sistol

NO	IR	USIA (tahun)	Detak Jantung	Tekanan Darah Sistolik
1	99163	22	79	118
2	106829	28	77	111
3	89149	25	83	129
4	91945	21	102	134
5	111360	52	83	121
6	118148	28	85	121
7	85908	58	75	136
8	83614	25	71	111
9	97649	28	87	125
10	82800	58	73	138
11	92052	58	75	134
12	85515	43	95	129
13	100745	49	98	133
14	102151	54	100	136
15	89438	41	96	119
16	73264	47	70	125
17	112014	36	87	131
18	112125	44	73	106
19	97148	67	65	145
20	110211	64	80	109
21	101714	43	72	130
22	99147	40	72	132
23	96393	38	75	131
24	99876	40	78	133



25	89786	23	71	112
26	97065	22	79	119
27	92546	22	78	118
28	89962	22	65	128
29	102367	25	85	124
30	90536	38	76	133
31	99371	34	75	125
32	101829	30	82	134
33	89162	27	68	127
34	82961	51	69	146
35	95637	52	70	141
36	95273	50	75	135
37	96352	52	74	134
38	89542	53	76	136
39	87639	60	83	150
40	96242	22	78	117






Lampiran 6. Tabel Data Training Tekanan Darah Diastol






NO	IR	USIA (tahun)	Detak Jantung	Tekanan Darah Diatolik
1	99163	22	79	80
2	106829	28	77	79
3	89149	25	83	82
4	91945	21	102	84
5	94921	66	88	87
6	111360	52	83	83
7	118148	28	85	80
8	85908	58	75	85
9	83614	25	71	80
10	103494	50	83	94
11	97649	28	87	82
12	82800	58	73	85
13	79621	57	77	85
14	92052	58	75	84
15	99609	49	85	84
16	85515	43	95	86
17	97148	67	65	83
18	110211	64	80	84
19	101714	43	72	81
20	99147	40	72	81
21	96393	38	75	81
22	99876	40	78	82
23	89786	23	71	79





24	97065	22	79	80
25	92546	22	78	80
26	89962	22	65	78
27	102367	25	85	81
28	90536	38	76	82
29	99371	34	75	80
30	101829	30	82	81
31	82961	51	69	83
32	95637	52	70	82
33	95273	50	75	83
34	96352	52	74	83
35	89542	53	76	84
36	87639	60	83	86





Lampiran 7. Pencarian model multi-layer perceptron





Pencarian Model Glukosa						
Neuron Hidden Layer	MSE		R (Regretion)			
	Training	Test	Training	Test	Additional Test	
1	61,7399	228,6761	0,8058	0,0366	0,7445	
2	94,4542	17,2053	0,6919	0,9893	0,7499	





3	82,7022	97,5297	0,7304	0,8511	0,7471	
4	78,3664	123,1855	0,7526	0,7144	0,7465	
5	91,6347	46,2866	0,7626	0,9677	0,7461	
6	55,6635	276,8317	0,8018	0,5336	0,7368	
7	84,6338	76,5666	0,7609	0,1602	0,7486	





8	83,5451	90,8492	0,7518	0,7764	0,7463	
9	66,4222	194,9651	0,7547	0,7597	0,7433	
10	91,2819	45,5102	0,7324	0,9766	0,7462	
11	88,2065	56,6958	0,757	0,6086	0,7481	
12	92,8307	31,0449	0,7428	0,9761	0,7484	





Pencarian Model Cholesterol						
Neuron Hidden Layer	MSE		R (Regretion)			
	Training	Test	Training	Test	Additional Test	
1	248,9906	375,7533	0,33075	0,1827	0,2586	
2	303,0298	66,9236	0,2776	-0,1926	0,2597	
3	288,4648	132,7807	0,256	0,7137	0,2635	
4	266,8827	271,3231	-0,2731	-0,2606	-0,2693	




5	263,9458	278,0003	0,1119	- 0,1175	0,073	
6	272,0261	211,9136	0,2935	-0,566	0,2363	
7	276,0754	220,9897	0,217	0,6036	0,2643	
8	78,6549	213,6054	0,8425	0,4983	0,7971	

9	71,802	298,7687	0,866	0,1918	0,7757	
10	136,4171	129,6829	0,7444	0,7926	0,7456	
11	263,1907	285,1849	0,1853	0,6521	0,2669	
12	92,7932	45,026	0,8127	0,929	0,8338	




Pencarian Model Sistolik						
Neuron Hidden Layer	MSE		R (Regretion)			
	Training	Test	Training	Test	Additional Test	
1	82,5029	111,3267	0,5684	0,7397	0,5937	
2	62,0287	97,2472	0,635	0,0741	0,597	
3	84,7176	22,3431	0,6567	0,8617	0,6577	
4	69,8169	64,2836	0,573	0,7915	0,5976	




5	65,842	72,1626	0,6008	0,5955	0,6011	
6	50,4885	183,9851	0,6995	0,1016	0,5807	
7	83,977	31,2178	0,6617	0,7685	0,6533	
8	0,0242	48,7716	0,9999	0,8439	0,9674	

9	69,84862	57,1677	0,57	0,7306	0,602	
10	73,3725	42,2755	0,5416	0,6846	0,603	
11	68,8399	55,6297	0,6159	0,4552	0,6022	
12	82,4478	38,786	0,6349	0,8607	0,6574	

Pencarian Model Diastolik						
Neuron Hidden Layer	MSE		R (Regretion)			
	Training	Test	Training	Test	Additional Test	
1	3,2711	0,1465	0,8037	0,9907	0,815	
2	3,2881	0,1126	0,7857	0,9988	0,814	
3	3,2054	0,5813	0,805	0,9745	0,8142	

4	3,2816	0,2991	0,7916	0,982	0,8131	
5	3,1773	0,6253	0,8101	0,9522	0,8155	
6	3,1336	1,4492	0,8101	0,9391	0,8109	

7	3,2426	0,4043	0,8102	0,9865	0,8138	 Additional Test: $R=0.81379$ Output $\approx 0.65 \cdot \text{Target} + 29$
8	3,3149	0,243	0,805	0,9754	0,8112	 Additional Test: $R=0.81115$ Output $\approx 0.63 \cdot \text{Target} + 31$
9	3,265	0,2057	0,7969	0,9963	0,8143	 Additional Test: $R=0.81427$ Output $\approx 0.64 \cdot \text{Target} + 29$

10	3,3135	0,088	0,8042	0,9808	0,8122	
11	3,3082	0,1599	0,7963	0,9987	0,8119	
12	3,3507	0,1027	0,7898	0,9916	0,81	

Lampiran 8. Komparasi Prediksi Model dan Akurasi Invasif

No	IR	Usia	HR	ALAT MEDIS				PREDIKSI			
				GLU	CHOL	TD SISTOL	TD DIASTOL	GLU	CHOL	TD SISTOL	TD DIASTOL
1	99163	22	79	124	166	118	80	122	172	119	80
2	106829	28	77	119	164	111	79	116	166	119	80
3	89149	25	83	135	206	129	82	130	204	124	82
4	91945	21	102	146	227	134	84	147	227	124	85
5	94921	66	88	134	184	165	87	129	184	141	87
6	111360	52	83	120	192	121	83	119	192	128	84
7	118148	28	85	124	188	121	80	122	191	116	81
8	85908	58	75	120	232	136	85	118	180	139	85
9	83614	25	71	87	162	111	80	117	172	124	80
10	103494	50	83	124	188	158	94	122	193	130	85
11	97649	28	87	137	206	125	82	131	212	123	83
12	82800	58	73	119	169	138	85	116	182	140	85
13	79621	57	77	125	169	155	85	122	169	141	85
14	92052	58	75	95	220	134	84	116	188	137	85
15	99609	49	85	274	186	173	84	126	194	131	85
16	87761	44	89	141	208	169	101	136	196	134	86
17	92079	64	74	116	203	150	94	114	195	139	85
18	85515	43	95	145	205	129	86	142	193	135	87
19	100745	49	98	142	233	133	92	141	191	133	87
20	102151	54	100	315	190	136	91	142	188	135	88
21	89438	41	96	144	195	119	92	142	199	133	87
22	73264	47	70	120	184	125	83	117	184	138	83
23	112014	36	87	129	217	131	82	125	206	122	83
24	112125	44	73	114	190	106	80	111	193	123	81
25	97148	67	65	114	215	145	83	108	217	137	83
26	110211	64	80	93	201	109	84	115	194	133	86
27	99156	50	84	128	185	152	94	124	192	132	85
28	101714	43	72	116	184	130	81	112	196	126	81
29	99147	40	72	99	180	132	81	113	191	126	81
30	96393	38	75	119	185	131	81	116	185	126	81
31	99876	40	78	99	193	133	82	118	190	126	82
32	89786	23	71	120	151	112	79	116	166	122	79
33	97065	22	79	125	168	119	80	122	175	120	80
34	92546	22	78	126	200	118	80	123	175	121	80
35	89962	22	65	119	204	128	78	111	188	120	78
36	102367	25	85	201	192	124	81	128	199	120	81
37	90536	38	76	211	204	133	82	119	187	128	82
38	99371	34	75	119	177	125	80	116	178	123	81
39	101829	30	82	98	205	134	81	123	193	122	81
40	89162	27	68	203	228	127	91	113	183	123	79
41	100722	42	71	226	210	156	90	112	198	126	81

42	95175	50	78	255	184	150	102	119	188	132	84
43	82961	51	69	117	204	146	83	113	201	136	83
44	95637	52	70	115	222	141	82	111	210	132	82
45	95273	50	75	118	211	135	83	116	192	132	83
46	96352	52	74	117	184	134	83	114	195	132	83
47	89542	53	76	120	178	136	84	118	183	135	84
48	87639	60	83	217	175	150	86	126	177	140	87
49	97353	54	82	246	181	157	92	122	186	134	85
50	96242	22	78	124	165	117	94	121	171	120	80
PERSENTASI RATA-RATA ERROR (%)								13.206	4.930	7.241	2.760
PERSENTASE AKURASI (%)								86.794	95.070	92.759	97.240

Lampiran 9. Tabel Pengujian Regresi Logistik Data Sampel

	Usia	Riwayat Keluarga	Rokok	Skala RACE	HR	Sistolik	Diastolik	Gula Darah	Kolestrol	Output	Pengujian Diagnosa
PEREMPUAN	22	1	0	0	79	118	80	124	166	0,00000904	TIDAK BERISIKO
	28	0	0	0	77	111	79	119	164	0,0000009	TIDAK BERISIKO
	25	0	0	0	83	129	82	135	206	0,01286366	TIDAK BERISIKO
	66	0	0	0	88	165	87	134	184	0,11687719	TIDAK BERISIKO
	50	0	0	0	83	158	94	124	188	0,99931442	BERISIKO
	58	0	0	0	73	138	85	119	169	0,00820229	TIDAK BERISIKO
	58	0	0	0	75	134	84	95	220	0,98302443	BERISIKO
	36	0	0	0	87	131	82	129	217	0,03096735	TIDAK BERISIKO
	44	0	0	0	73	106	80	114	190	0,00008331	TIDAK BERISIKO
	64	0	0	0	80	109	84	93	201	0,00951481	TIDAK BERISIKO
	43	1	0	0	72	130	81	116	184	0,00695565	TIDAK BERISIKO
	23	0	0	0	71	112	79	120	151	0,00000074	TIDAK BERISIKO
	22	0	0	0	65	128	78	119	204	0,11235455	TIDAK BERISIKO
	34	0	0	0	75	125	80	119	177	0,00018286	TIDAK BERISIKO
	30	1	0	0	82	134	81	98	205	0,4153472	TIDAK BERISIKO
	27	0	0	0	68	127	91	203	228	0,96155336	BERISIKO
	50	1	0	3	78	150	102	255	184	0,92263871	BERISIKO
	51	1	0	0	69	146	83	117	204	0,93649949	BERISIKO

	52	0	0	0	70	141	82	115	222	0,96581397	BERISIKO
	50	1	0	4	75	135	83	118	211	0,9715602	BERISIKO
	52	0	0	0	74	134	83	117	184	0,01311034	TIDAK BERISIKO
	53	0	0	0	76	136	84	120	178	0,00688708	TIDAK BERISIKO
	60	0	0	0	83	150	86	217	175	0,00000089	TIDAK BERISIKO
	22	0	0	0	78	117	94	124	165	0,57003126	BERISIKO

LAKI-LAKI	Usia	Riwayat Keluarga	Rokok	Skala RACE	HR	Sistolik	Diastolik	Gula Darah	Kolestrol	Output	Pengujian Diagnosa
	21	0	10	0	102	134	84	146	227	0,073376 86	TIDAK BERISIKO
	52	0	36	0	83	121	83	120	192	0,027149 9	TIDAK BERISIKO
	28	0	0	0	85	121	80	124	188	0,000055 65	TIDAK BERISIKO
	58	1	0	2	75	136	85	120	232	0,998771 6	BERISIKO
	25	0	10	0	71	111	80	87	162	0,000888 23	TIDAK BERISIKO
	28	0	24	0	87	125	82	137	206	0,025086 3	TIDAK BERISIKO
	57	0	12	0	77	155	85	125	169	0,111278 3	TIDAK BERISIKO
	49	0	12	0	85	173	84	274	186	0,000000 6	TIDAK BERISIKO
	44	1	36	0	89	169	101	141	208	1	BERISIKO
	64	0	24	2	74	150	94	116	203	0,999999 5	BERISIKO
	43	0	30	0	95	129	86	145	205	0,048920 8	TIDAK BERISIKO
	49	0	0	0	98	133	92	142	233	0,968646 8	BERISIKO
	54	0	0	0	100	136	91	315	190	0	TIDAK BERISIKO
	41	0	10	0	96	119	92	144	195	0,044458 76	TIDAK BERISIKO
	47	0	24	0	70	125	83	120	184	0,122377 5	TIDAK BERISIKO
	67	1	0	5	65	145	83	114	215	0,999725	BERISIKO
	50	1	36	1	84	152	94	128	185	0,999970 7	BERISIKO
	40	1	24	0	72	132	81	99	180	0,383203 6	TIDAK BERISIKO

	38	1	0	0	75	131	81	119	185	0,005876 83	TIDAK BERISIKO
	40	1	12	1	78	133	82	99	193	0,663581 6	BERISIKO
	22	0	0	0	79	119	80	125	168	0,000009 59	TIDAK BERISIKO
	22	0	12	0	78	118	80	126	200	0,006460 66	TIDAK BERISIKO
	25	0	12	0	85	124	81	201	192	0,000000 58	TIDAK BERISIKO
	38	1	24	0	76	133	82	211	204	0,000280 94	TIDAK BERISIKO
	42	0	48	2	71	156	90	226	210	0,998695	BERISIKO
	54	1	0	5	82	157	92	246	181	0,013915 4	TIDAK BERISIKO

Lampiran 10. Rekap Data Skala Race

Jenis Kelamin	Usia	Skala RACE						Total Skor
		Kelumpuhan Wajah	Fungsi motor lengan	Fungsi motor tungkai	Deviasi kepala dan pandnagan	Afasia (jika hemiparesis kanan)	Agnosia (jika hemiparesis kiri)	
Laki-Laki	58	2						2
Laki-Laki	64	1	1					2
Laki-Laki	67	2	1	1		1		5
Laki-Laki	50	1						1
Laki-Laki	40	1						1
Laki-Laki	42	2						2
Perempuan	50	2	1					3
Perempuan	50	2	1	1				4
Laki-Laki	54	2	2			1		5

Laki laki 67 tahun

Item	Skor
Kelumpuhan Wajah	Kelumpuhan wajah sedang sampai berat (asimetris sepenuhnya) 2
Fungsi Motor Lengan	Lengan terangkat kurang dari 10 detik 1
Fungsi Motor Tungkai	Tungkai terangkat kurang dari 5 detik 1
Afasia (jika)	Hanya melakukan satu tugas dengan 1

hamiparesis kanan)	benar dari dua perintah	
Total		5

Lampiran 11. Program JupyterLab Regresi Logistik

```

import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (
    accuracy_score,
    precision_score,
    recall_score,
    f1_score,
    classification_report
)
# LOAD DATA
file_path = "dataolah_reglogistik.xlsx"
data = pd.read_excel(file_path)
# Cek struktur data
print(data)
# PISAHKAN FITUR (X) & TARGET (Y)
X = data[
    [
        'USIA',
        'JENIS KELAMIN',
        'RIWAYAT KELUARGA',
        'ROKOK',
        'SKALA RACE',
        'BPM SENSOR',
        'Sistolik',
        'Diastolik',

```

```

        'GULA DARAH',
        'KOLESTROL'
    ]
]

y = data['Stroke']
# SPLIT DATA TRAINING & TESTING
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.25,
    random_state=42
)
# INISIALISASI MODEL
model = LogisticRegression(
    solver="lbfgs",
    max_iter=1000,
    verbose=1
)
# LATIH MODEL
model.fit(X_train, y_train)
# PREDIKSI DATA TESTING
predictions = model.predict(X_test)
# EVALUASI MODEL
accuracy = accuracy_score(y_test, predictions)
print("Akurasi model:", accuracy)
# Laporan klasifikasi lengkap
print(classification_report(y_test, predictions))
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.metrics import confusion_matrix, accuracy_score
# AKURASI MODEL
accuracy = accuracy_score(y_test, predictions)

```

```

# PLOT AKURASI MODEL
plt.figure(figsize=(6, 4))
plt.bar(['Akurasi Model'], [accuracy], color='blue')
plt.ylim(0, 1)
plt.ylabel('Akurasi')
plt.title('Akurasi Model Logistic Regression')
plt.show()

# CONFUSION MATRIX
conf_matrix = confusion_matrix(y_test, predictions)
# Plot confusion matrix
plt.figure(figsize=(6, 6))
sns.heatmap(
    conf_matrix,
    annot=True,
    fmt='d',
    cmap='Blues',
    xticklabels=['Negatif', 'Positif'],
    yticklabels=['Negatif', 'Positif']
)
plt.xlabel('Prediksi')
plt.ylabel('Aktual')
plt.title('Confusion Matrix')
plt.show()

# CETAK NILAI KOEFISIEN (BETA)
fitur = [
    'USIA',
    'JENIS KELAMIN',
    'RIWAYAT KELUARGA',
    'ROKOK',
    'SKALA RACE',
    'BPM SENSOR',
    'Sistolik',

```

```

'Diastolik',
'GULA DARAH',
'KOLESTROL'
]
print("\n=== KOEFISIEN REGRESI LOGISTIK ===")
# Intercept
print(f" $\beta_0$  (Intercept) : {model.intercept_[0]:.6f}")
# Koefisien fitur
for i, (nama, coef) in enumerate(zip(fitur, model.coef_[0]), start=1):
    print(f" $\beta_{i}$  ({nama}) : {coef:.6f}")

```

Lampiran 12. Surat Validasi Alat dari Dokter

SURAT PERNYATAAN VALIDASI INSTRUMEN PENELITIAN

Saya yang bertanda dibawah ini :

Nama : dr. Ridhwan Biosia Wiratama
Jabatan : Dokter Penanggung Jawab Klinik
Alamat : Jl. Raya ITS - Kampus Pens Surabaya (Klinik Pens)

Menyatakan instrumen penelitian Tugas Akhir atas nama :

Nama : Rizka Sugiharto
NIM : 2122600008
Program studi : Sarjana Terapan Teknik Elektronika
Judul TA : Rancang Bangun Alat Deteksi Stroke Dini Non-Invasif dengan Metode Regresi Logistik Berbasis IoT

Dengan ini saya menyatakan alat yang bernama NISTRO (Non-Invasive stroke Detector) bahwa alat tersebut ter-VALIDASI dan dapat digunakan sebagai deteksi dini stroke. Untuk Project tugas akhir mahasiswa Politeknik Elektronika Negeri Surabaya jurusan Teknik Elektronika.

Surabaya, 29 Juni 2026



dr. Ridhwan Biosia Wiratama

Lampiran 13. Perhitungan

Parameter	Simbol	Nilai
Nilai Inframerah	X1	82800
Usia	X2	58 tahun
Detak Jantung	X3	78 bpm

Perhitungan Gula Darah

Vektor input dituliskan sebagai

$$X = \begin{bmatrix} 82800 \\ 58 \\ 78 \end{bmatrix}$$

a) Normalisasi Input

$$x_n = (x - x_{\text{offset}}) \times \text{gain} + y_{\text{min}}$$

parameter normalisasi:

$$x_{\text{offset}} = \begin{bmatrix} 73264 \\ 21 \\ 65 \end{bmatrix}$$

$$\text{gain} = \begin{bmatrix} 4.45593 \times 10^{-5} \\ 0.04347 \\ 0.05405 \end{bmatrix}$$

$$y_{\text{min}} = -1$$

- Normalisasi nilai IR

$$\begin{aligned} \text{Irn} &= (82800 - 73264) \times 4.45593 \times 10^{-5} - 1 \\ &= 9536 \times 0.0000445593 - 1 \\ &= 0.424434 - 1 \\ &= -0.575566 \end{aligned}$$

- Normalisasi Usia

$$\begin{aligned} \text{Usian} &= (58 - 21) \times 0.04347 - 1 \\ &= 37 \times 0.04347 - 1 \\ &= 1.608696 - 1 \\ &= 0.608696 \end{aligned}$$

- Normalisasi Detak Jantung

$$\begin{aligned} \text{HRn} &= (73 - 65) \times 0.05405 - 1 \\ &= 37 \times 0.05405 - 1 \\ &= 0.432432 - 1 \end{aligned}$$

$$= -0.567568$$

$$X_n = \begin{bmatrix} -0.575566 \\ 0.608696 \\ -0.567568 \end{bmatrix}$$

b) Menghitung WX

$$WX = X \times X_n$$

$$WX = \begin{bmatrix} -0.0000432 \\ 0.433881 \\ 0.0000349 \end{bmatrix}$$

- Neuron ke-1

$$\begin{aligned} Z_1 &= (-0.0003427484)(-0.575566) + (-0.0002944833)(0.608696) + (0.0001079477) \\ &\quad (-0.567568) \\ &= -0.0000432 \end{aligned}$$

- Neuron ke-2

$$\begin{aligned} Z_2 &= (0.3452489791)(-0.575566) + (0.1151086239)(0.608696) + (-0.9910418840) \\ &\quad (-0.567568) \\ &= 0.433881 \end{aligned}$$

- Neuron ke-3

$$\begin{aligned} Z_3 &= (0.0002762571)(-0.575566) + (0.0002373529)(0.608696) + (-0.0000870127) \\ &\quad (-0.567568) \\ &= 0.0000349 \end{aligned}$$

c) Menambahkan Bias

$$b = \begin{bmatrix} 0.000252845 \\ 0.100669941 \\ -0.000203791 \end{bmatrix}$$

$$WX + b = \begin{bmatrix} 0.000209620 \\ 0.534551202 \\ -0.000168887 \end{bmatrix}$$

d) Menghitung Fungsi Aktivasi

$$\text{tansig}(n) = \frac{2}{1 + e^{-2n}} - 1$$

$$a1 = \begin{bmatrix} 0.000210 \\ 0.488800 \\ -0.000169 \end{bmatrix}$$

e) Menghitung Output Layer

$$LW = [-0.002361747 \quad -0.814908777 \quad -0.001044618]$$

Ditambahkan bias output

$$b2 = 0.396063376$$

menggunakan persamaan

$$a2 = b2 + LW \times a1$$

hasilnya

$$a2 = -0.00234$$

f) Denormalisasi Output

$$Y = \frac{a2 - y_{min}}{gain} + x_{offset}$$

Dengan

$$y_{min} = 1, \text{ gain} = 0.0338983050847458, x_{offset} = 87$$

sehingga

$$\begin{aligned} Y &= \frac{-0.00234 + 1}{0.0338983050847458} + 87 \\ &= \frac{0.99766}{0.0338983050847458} + 87 \\ &= 29.43 + 87 \\ &= 116.43 \text{ mg/dL} \end{aligned}$$

Perhitungan Kolestrol

a) Normalisasi Input

$$X = \begin{bmatrix} 82800 \\ 58 \\ 78 \end{bmatrix} \quad X_n = \begin{bmatrix} -0.575566 \\ 0.608696 \\ -0.567568 \end{bmatrix}$$

b) Nilai WX

$$WX = W \times X_n$$

$$WX = \begin{bmatrix} -0.812392 \\ 0.000019 \\ -0.226289 \\ 0.011516 \\ -0.745419 \\ -0.756480 \\ 0.000349 \\ 1.350840 \\ 0.00029 \\ -0.000272 \\ 0.481282 \\ -0.000005 \end{bmatrix}$$

c) Menambahkan bias

$$WX + b = \begin{bmatrix} -1.337308 \\ 0.000576 \\ -0.664809 \\ 0.053339 \\ -0.147458 \\ -0.492249 \\ 0.012450 \\ -0.132518 \\ 0.002003 \\ 0.002832 \\ -0.004949 \\ 0.000526 \end{bmatrix}$$

d) Fungsi Aktivasi

$$\text{tansig}(n) = \frac{2}{1+e^{-2n}} - 1$$

$$a1 = \begin{bmatrix} -0.871081 \\ 0.000576 \\ -0.581588 \\ 0.053289 \\ -0.146399 \\ -0.455997 \\ 0.012450 \\ -0.131748 \\ 0.002003 \\ 0.002832 \\ -0.004949 \\ 0.000526 \end{bmatrix}$$

e) Menghitung Output Layer

$$b2 = 0.3648476869$$

menggunakan persamaan

$$a2 = b2 + LW \times a1$$

hasilnya

$$a2 = -0.134054$$

f) Denormalisasi Output

$$Y = \frac{a2 - y_{min}}{gain} + x_{offset}$$

$$Y = \frac{-0.134054 + 1}{0.028169014084507} + 151$$

$$= \frac{0.865946}{0.028169014084507} + 151$$

$$= 30.7411 + 151$$

$$= 181.74 \text{ mg/dL}$$

Perhitungan Tekanan Darah Sistolik

a) Normalisasi Input

$$X = \begin{bmatrix} 82800 \\ 58 \\ 78 \end{bmatrix} \quad X_n = \begin{bmatrix} -0.575566 \\ 0.608696 \\ -0.567568 \end{bmatrix}$$

b) Nilai WX

$$WX = W \times X_n$$

$$WX = \begin{bmatrix} -0.291214 \\ 0.267302 \\ -0.231593 \end{bmatrix}$$

c) Menambahkan bias

$$B = \begin{bmatrix} 0.080630 \\ -0.067441 \\ 0.055198 \end{bmatrix}$$

$$WX + b = \begin{bmatrix} -0.210584 \\ 0.199861 \\ -0.176395 \end{bmatrix}$$

d) Fungsi Aktivasi

$$\text{tansig}(n) = \frac{2}{1+e^{-2n}} - 1$$

$$a1 = \begin{bmatrix} -0.207527 \\ 0.197241 \\ -0.174587 \end{bmatrix}$$

e) Menghitung Output Layer

$$b2 = -0.092147471479254$$

$$LW = [-0.436350767664 \quad 0.402545874896 \quad -0.364771806799]$$

menggunakan persamaan

$$a2 = b2 + LW \times a1$$

hasilnya

$$a2 = -0.092147 + (-0.436351)(-0.207527) + (0.402546)(0.197241) + (-0.364772)(-0.174587)$$

$$a2 = 0.141489$$

f) Denormalisasi Output

$$Y = \frac{a2 - y_{min}}{gain} + x_{offset}$$

Ymin = -1 , gain = 0.0338983050847458, xoffset = 106

$$Y = \frac{0.141489 + 1}{0.0338983050847458} + 106$$

$$= \frac{1.141489}{0.0338983050847458} + 106$$

$$= 33.6749 + 106$$

$$= 139.67 \text{ mmHg}$$

Perhitungan Tekanan Darah Diastolik

a) Normalisasi Input

$$X = \begin{bmatrix} 82800 \\ 58 \\ 78 \end{bmatrix} \quad X_n = \begin{bmatrix} -0.575566 \\ 0.608696 \\ -0.567568 \end{bmatrix}$$

b) Nilai WX

$$WX = W \times X_n$$

$$WX = \begin{bmatrix} -0.000592 \\ -0.078853 \\ -0.000549 \\ 0.000613 \\ -0.000614 \end{bmatrix}$$

c) Menambahkan bias

$$B = \begin{bmatrix} -0.000866 \\ -0.192855 \\ -0.000803 \\ 0.000896 \\ -0.000898 \end{bmatrix}$$

$$WX + b = \begin{bmatrix} -0.001458 \\ -0.271708 \\ -0.001352 \\ 0.001509 \\ -0.001512 \end{bmatrix}$$

d) Fungsi Aktivasi

$$\text{tansig}(n) = \frac{2}{1+e^{-2n}} - 1$$

$$a1 = \begin{bmatrix} -0.001458 \\ -0.265209 \\ -0.001352 \\ 0.001509 \\ -0.001512 \end{bmatrix}$$

e) Menghitung Output Layer

$$b2 = -0.394485154186$$

menggunakan persamaan

$$a2 = b2 + LW \times a1$$

hasilnya

$$\begin{aligned}a2 &= -0.394485154186 + (0.002888472342)(-0.001458) + (-0.812827415282) \\ &(-0.265209) + (0.002103292989)(-0.001352) + (-0.002553133847)(0.001509) + (0.00260 \\ &3885987)(-0.001512) \\ a2 &= -0.178924\end{aligned}$$

f) Denormalisasi Output

$$Y = \frac{a2 - y_{min}}{gain} + x_{offset}$$

$$Y_{min} = -1, \text{ gain} = 0.125, \text{ xoffset} = 78$$

$$Y = \frac{-0.178924 + 1}{0.125} + 78$$

$$= \frac{0.821076}{0.125} + 78$$

$$= 6.568608 + 78$$

$$= 84.57 \text{ mmHg}$$

Perhitungan Kemungkinan stroke dengan Regresi Logistik

$$P(Y=1) = \frac{1}{1+e^{-(\beta_0+\beta_1X_1+\beta_2X_2+\dots+\beta_nX_n)}}$$

atau bentuk ekuivalennya:

$$P(Y=1) = \frac{e^{(\beta_0+\beta_1X_1+\beta_2X_2+\dots+\beta_nX_n)}}{1+e^{(\beta_0+\beta_1X_1+\beta_2X_2+\dots+\beta_nX_n)}}$$

Probabilitas menjadi hasil klasifikasi:

$$Y^{\wedge} = \begin{cases} 1, & P(Y = 1) \geq 0.5 \\ 0, & P(Y = 1) < 0.5 \end{cases}$$

- X_n adalah variabel prediktor (Usia, Jenis Kelamin, Riwayat Stroke, Jumlah Merokok, Skala RACE, Denyut Jantung, Sistolik, Diastolik, Gula Darah, Kolesterol)
 $X_1= 58, X_2=0, X_3=0, X_4=0, X_5=0, X_6=73, X_7=138, X_8=85, X_9=119, X_{10}=169$
- β_0 adalah koefisien regresi dari masing-masing variabel.

Nilai Koeffisien B0				-95,59786095
Koefisien Regresi				
B1	B2	B3	B4	B5
-0,0811438	0,14541473	0,47194853	0,10920642	0,74655845
B6	B7	B8	B9	B10
-0,24352054	0,16413259	0,88939616	-0,10597514	0,16359861

$$\begin{aligned}
 P(Y=1) &= \frac{\exp((-95,59+(-0,08x58)+(0,14x0)+(0,47x0)+(0,10x0)+(0,74x0)+ \\
 &\quad (-0,24x73)+(0,16x138)+(0,88x85)+(-0,10x119)+(0,1x169))}{(1+Exp((-95,59+(-0,08x58)+(0,14x0)+(0,47x0)+(0,10x0)+(0,74x0)+ \\
 &\quad (-0,24x73)+(0,16x138)+(0,88x85)+(-0,10x119)+(0,1x169)))} \\
 &= 0,00819
 \end{aligned}$$

$P(Y=1) 0.00819 < 0,5$, sehingga termasuk tidak beresiko

$$\begin{aligned}
 \text{Persentase kemungkinan stroke} &= P(Y=1) \times 100\% \\
 &= 0.00819 \times 100\% \\
 &= 0,819 \%
 \end{aligned}$$

$$\begin{aligned}
 \text{Persentase kemungkinan tidak stroke} &= (1- P(Y=1)) \times 100\% \\
 &= (1-0,00819) \times 100\% = 0,99181 \times 100\% \\
 &= 99,181\%
 \end{aligned}$$

Lampiran 14. Draft Tugas Akhir



BIODATA PENULIS



NAMA	:	Rizka Sugiharto	
Nama Panggilan	:	Rizka	
Tempat, Tanggal Lahir	:	Ponorogo, 29 Mei 2003	
Jenis Kelamin	:	Perempuan	
Agama	:	Islam	
Kewarganegaraan	:	WNI	
Alamat Asal	:	Kadipaten, Babadan Ponorogo	
No. Telp	:	089523288157	
Email	:	rizkasgh@gmail.com	
Pendidikan	:	SMPN 2 Ponorogo	1016 – 2019
	:	SMK Telkom Sidoarjo	2019 – 2022
	:	Politeknik Elektronika Negeri Surabaya	2022 - 2026
	:		